

# System SARA: semantyczna eksploracja i adaptacyjna reprezentacja naukowców w przestrzeni embeddingów

Patryk Żywica<sup>1</sup>   Daria Dworzyńska-Wujec<sup>1</sup>   Michał Wujec<sup>1</sup>  
Miłosz Rolewski<sup>1</sup>   Jakub Paszke<sup>1</sup>

<sup>1</sup>Wydział Matematyki i Informatyki, Uniwersytet im. Adama Mickiewicza w Poznaniu  
patryk.zywica@amu.edu.pl

**Streszczenie.** Dynamiczny wzrost liczby publikacji naukowych wymaga narzędzi umożliwiających automatyczną eksplorację zarówno pojedynczych artykułów, jak i profili badawczych ich autorów. W niniejszym artykule prezentujemy system SARA (Search and Research Assistant) — dwupoziomową platformę semantycznej eksploracji zbudowaną na danych Wydziału Matematyki i Informatyki UAM ( $N = 3440$  publikacji, 115 autorów, 14 zakładów). Na poziomie publikacji przeprowadzamy systematyczne porównanie ośmiu metod redukcji wymiarowości (t-SNE, UMAP, PaCMAP, Spectral Embedding, PCA, Isomap, LDA, PCA 8D+log) z wykorzystaniem siedmiu metryk jakości projekcji oraz autorskiego wskaźnika Composite Score. Na poziomie autorów proponujemy adaptacyjną reprezentację, w której decyzja o liczbie punktów reprezentujących badacza (jeden centroid vs. wiele klastrów) podejmowana jest per autor na podstawie diagnostyki stabilności centroidu oraz automatycznej dekompozycji multi-cluster. Model embeddingowy BGE-base został dostrojony funkcją straty CoSENTLoss z hierarchiczną odległością kategorii ArXiv, co poprawiło wariancję wyjaśnioną w PCA 2D z 33,11% do 54,71% na profilach autorów. 85,2% autorów z co najmniej pięcioma publikacjami wykazuje wieloklastrową strukturę profilu badawczego (średnio  $k = 2,59$  klastrów).

**Słowa kluczowe:** embeddingi tekstowe, redukcja wymiarowości, profilowanie naukowców, reprezentacja adaptacyjna, fine-tuning, wizualizacja danych naukowych

## 1 Wprowadzenie

Współczesna nauka generuje publikacje w tempie przekraczającym możliwości ręcznej analizy. Tylko w roku 2024 w bazie OpenAlex zarejestrowano

ponad 200 milionów prac naukowych. Dla badacza szukającego potencjalnych współpracowników, recenzenta oceniającego dorobek czy administratora jednostki potrzebne są narzędzia umożliwiające szybką eksplorację przestrzeni tematycznej — zarówno na poziomie pojedynczych artykułów, jak i całych profili badawczych.

Standardowym podejściem jest reprezentacja tekstu za pomocą embeddingów — gęstych wektorów w przestrzeni  $\mathbb{R}^d$ , wytwarzanych przez pretrenowane modele językowe. Naturalnym pytaniem staje się wówczas: *jak zredukować  $d = 768$  wymiarów do dwóch, zachowując semantyczną strukturę danych?* Oraz, na wyższym poziomie agregacji: *czy naukowca można wiarygodnie reprezentować pojedynczym punktem w przestrzeni embeddingów, czy też należy traktować go jako obiekt potencjalnie wielomodalny?*

Niniejszy artykuł prezentuje system SARA — dwupoziomową platformę semantycznej eksploracji, opracowaną na danych Wydziału Matematyki i Informatyki (WMI) Uniwersytetu im. Adama Mickiewicza w Poznaniu. System obejmuje:

1. systematyczne porównanie ośmiu metod redukcji wymiarowości na zbiorze 3440 publikacji z użyciem siedmiu metryk jakości projekcji oraz autorskiego wskaźnika Composite Score,
2. adaptacyjną reprezentację 115 autorów WMI, łączącą diagnostykę stabilności centroidu z automatyczną dekompozycją wieloklastrową,
3. dostrojenie modelu embeddingowego z wykorzystaniem hierarchicznej taksonomii kategorii ArXiv.

Artykuł ma następującą strukturę. Sekcja 2 opisuje źródła danych i proces generowania embeddingów. Sekcje 3 i 4 przedstawiają odpowiednio analizę na poziomie publikacji i autorów. Sekcja 5 integruje wyniki obu warstw, a sekcja 6 podsumowuje pracę.

**Tabela 1:** Porównanie modeli embeddingowych (top 5 z 9 testowanych, ArXiv  $n = 2397$ ,  $k = 118$ ).

| Model             | $d$  | Purity |
|-------------------|------|--------|
| BGE-base-en-v1.5  | 768  | 70,55% |
| BGE-large-en-v1.5 | 1024 | 69,63% |
| Nomic-embed-v1.5  | 768  | 69,50% |
| SPECTER           | 768  | 68,88% |
| all-mpnet-base-v2 | 768  | 68,09% |

## 2 Dane i embeddingi

### 2.1 Źródła danych

Dane pozyskano z Portalu Badawczego UAM oraz interfejsu OpenAlex API. Pipeline zbierania obejmuje cztery etapy: (1) scraping profili pracowników WMI z ekstrakcją identyfikatorów ORCID i Scopus, (2) pobieranie metadanych publikacji z OpenAlex na podstawie ORCID, (3) uzupełnianie brakujących abstraktów przez bezpośredni scraping witryn wydawców (16 wariantów selektorów CSS), (4) filtrowanie i deduplikacja. Wynikowy zbiór liczy  $N = 3440$  publikacji przypisanych do 115 autorów z 14 zakładów WMI. Średnia liczba publikacji na autora wynosi 29,9 (mediana 19).

Dodatkowo, jako korpus referencyjny do fine-tuningu, pobrano 18 880 artykułów z ArXiv API — po 200 z każdej ze 118 podkategorii. 63,8% artykułów w tym zbiorze posiada więcej niż jedną kategorię (średnio 2,06).

### 2.2 Generowanie embeddingów

Dla każdej publikacji generowany jest embedding na podstawie konkatencji tytułu i abstraktu: "{title}. {abstract}". Wektory mają wymiar  $d = 768$  i są normalizowane  $L^2$ , dzięki czemu odległość euklidesowa staje się monotoniczna względem podobieństwa kosinusowego:

$$\|e_i - e_j\|^2 = 2(1 - e_i \cdot e_j). \quad (1)$$

Jako bazowy model embeddingowy wybrano BAAI/bge-base-en-v1.5 na podstawie porównania dziewięciu modeli (Tab. 1) na zbiorze 2397 artykułów ArXiv, gdzie osiągnął najwyższą main-category purity (70,55% dla  $k = 118$  klastrów).

### 2.3 Ograniczenie Johnsona–Lindenstraussa

Lemat Johnsona–Lindenstraussa gwarantuje, że wierna projekcja (z dokładnością  $\varepsilon$ )  $n$  punktów wymaga co najmniej  $d_{\min} = O(\varepsilon^{-2} \ln n)$  wymiarów. Dla  $n = 3440$  i  $\varepsilon = 0,1$  daje to  $d_{\min} \approx 1200$ . Redukcja do 2 wymiarów jest zatem  $600\times$  poniżej tego

minimum — co motywuje potrzebę rygorystycznej oceny jakości projekcji, przedstawionej w sekcji 3.

## 3 Wizualizacja publikacji: redukcja wymiarowości

### 3.1 Metody redukcji wymiarowości

Porównano osiem metod DR, podzielonych na dwie grupy ze względu na charakter zachowywanych relacji.

**Metody lokalne** koncentrują się na zachowaniu sąsiedztw:

- **t-SNE** — minimalizuje dywergencję KL między rozkładami prawdopodobieństwa sąsiedztw w przestrzeni oryginalnej i docelowej; inicjalizacja PCA, perplexity = 35;
- **UMAP** — modeluje strukturę danych jako ważony graf simpleksów rozmytych; metryka kosinusowa,  $n\_neighbors = 20$ ;
- **PaCMAP** — optymalizuje trzy typy par (bliższe, średnie, dalekie) z adaptacyjnymi wagami;  $n\_neighbors = 10$ ;
- **Spectral Embedding** — wykorzystuje wektory własne laplasjanu grafu sąsiedztwa; 50D PCA preprocessing.

**Metody globalne/liniowe** zachowują relacje na większą skalę:

- **PCA** — maksymalizuje wariancję wzdłuż głównych osi;
- **Isomap** — zachowuje odległości geodezyjne na rozmaitości;
- **LDA** — maksymalizuje separację klas (metoda nadzorowana);
- **PCA 8D+log** — pipeline: podobieństwo kosinusowe do centroidów klastrów, transformacja logarytmiczna, PCA do 2D.

### 3.2 Metryki jakości projekcji

Jakość projekcji oceniono siedmioma metrykami, podzielonymi na lokalne i globalne.

**Metryki lokalne:** (1) *kNN Recall@100* — odsetek prawdziwych sąsiadów w 768D zachowanych w 2D; (2) *Trustworthiness* — odsetek sąsiadów w 2D, którzy są rzeczywistymi sąsiadami w 768D; (3) *Neighbourhood Hit* — odsetek  $k$ -sąsiadów w 2D należących do tego samego klastra.

**Metryki globalne:** (4) *korelacja rang Spearmana* ( $\rho$ ) — monotoniczność relacji odległości; (5) *korelacja Pearsona* ( $r$ ) — liniowość zachowania odległości; (6) *Kruskal Stress* ( $\sigma$ ) — znormalizowany błąd odwzorowania odległości; (7) *SPDE* — skalowana różnica odległości parami.

**Tabela 2:** Porównanie ośmiu metod DR na zbiorze  $N = 3440$  publikacji ( $k = 9$  klastrów). CS — Composite Score, kNN — kNN Recall@100, Trust — Trustworthiness, NH — Neighbourhood Hit,  $\rho$  — Spearman.

| Metoda   | CS           | kNN          | Trust        | NH           | $\rho$       |
|----------|--------------|--------------|--------------|--------------|--------------|
| UMAP     | <b>0,727</b> | 0,587        | 0,961        | 0,908        | 0,679        |
| PaCMAP   | 0,725        | 0,573        | <b>0,963</b> | 0,908        | <b>0,709</b> |
| t-SNE    | 0,724        | <b>0,611</b> | 0,972        | <b>0,918</b> | 0,563        |
| Isomap   | 0,605        | 0,319        | 0,868        | 0,747        | 0,716        |
| PCA      | 0,576        | 0,260        | 0,855        | 0,711        | 0,685        |
| LDA      | 0,575        | 0,216        | 0,879        | 0,878        | 0,773        |
| Spectral | 0,536        | 0,314        | 0,850        | 0,800        | 0,741        |
| 8D+log   | 0,530        | 0,197        | 0,816        | 0,498        | 0,770        |

### 3.3 Composite Score

Zaproponowano autorski wskaźnik Composite Score ( $CS$ ), łączący metryki lokalne i globalne w jedną miarę jakości projekcji. Wagi wyznaczono empirycznie poprzez analizę korelacji między metrykami i minimalizację redundancji, a następnie zwalidowano przez porównanie rankingu metod z niezależną oceną użytkownikową. Wskaźnik zdefiniowano jako:

$$CS = \sum_{i=1}^7 w_i \cdot m_i, \quad (2)$$

gdzie  $m_i$  to znormalizowana wartość  $i$ -tej metryki, a  $w_i$  — jej waga. Jako dodatkową walidację zastosowano całkę Choquet z 2-addytywną miarą rozmytą, wyznaczając wartości Shapleya dla poszczególnych metryk.

### 3.4 Dobór liczby klastrów

Optymalną liczbę klastrów  $k$  wyznaczono metodą konsensusu sześciu kryteriów: metoda łokcia (inercja), silhouette score, statystyka luki (gap statistic), indeks Calinińskiego–Harabasz, indeks Daviesa–Bouldina oraz analiza stabilności (bootstrap Jaccard). Głosowanie większościowe wskazało  $k = 9$  (silhouette = 0,2823).

### 3.5 Wyniki porównania metod DR

Tabela 2 przedstawia wyniki porównania ośmiu metod. Trzy metody nieliniowe — UMAP ( $CS = 0,727$ ), PaCMAP ( $CS = 0,725$ ) i t-SNE ( $CS = 0,724$ ) — osiągają zbliżone wyniki, znacząco przewyższając pozostałe. Różnice między nimi są marginalne ( $\Delta CS < 0,004$ ), co sugeruje, że wybór spośród nich powinien uwzględniać dodatkowe kryteria praktyczne.

UMAP i PaCMAP wyróżniają się najlepszym kompromisem między wiernością lokalną a glo-

balną. t-SNE osiąga najwyższy kNN Recall (0,611) i Neighbourhood Hit (0,918), lecz kosztem korelacji globalnej ( $\rho = 0,563$ ) — efekt dobrze udokumentowany w literaturze, wynikający z jądra Studenta w przestrzeni docelowej. PaCMAP natomiast uzyskuje najwyższą korelację rang ( $\rho = 0,709$ ) przy porównywalnej wierności lokalnej, co czyni go rekomendowaną metodą domyślną.

Metody liniowe (PCA, LDA, 8D+log) ustępują nieliniowym pod względem  $CS$ , lecz zachowują wyższą korelację globalną ( $\rho > 0,68$ ). LDA osiąga wysoki Neighbourhood Hit (0,878), lecz jest to artefakt metody nadzorowanej — maksymalizuje separację klas z definicji, co stanowi rozumowanie kołowe w kontekście oceny klasteryzacji.

Całka Choquet z wartościami Shapleya potwierdza ranking, wskazując na PaCMAP i UMAP jako metody o najlepszym profilu wielokryterialnym, z dominującymi wagami dla korelacji Spearmana (0,189) i zachowania odległości (0,147).

## 4 Reprezentacja autorów

### 4.1 Centroid autora i problem wielomodalności

Naturalną reprezentacją profilu badawczego autora  $a$  jest centroid — uśredniony wektor embeddingów jego publikacji:

$$\hat{e}_a = \frac{\bar{e}_a}{\|\bar{e}_a\|}, \quad \bar{e}_a = \frac{1}{n_a} \sum_{p \in P_a} e_p, \quad (3)$$

gdzie  $P_a$  to zbiór publikacji autora, a normalizacja  $L^2$  zapewnia porównywalność z embeddingami artykułów. Mean pooling działa jako filtr szumów (wygładza jednorazowe tematy), jest stałowymiarowy i łatwo aktualizowalny inkrementalnie.

Problem pojawia się dla autorów o zróżnicowanym profilu: centroid badacza łączącego np. robotykę z medycyną trafia w pustą przestrzeń „pomiędzy” tymi obszarami, nie reprezentując wiernie żadnego z nich.

### 4.2 Diagnostyka stabilności centroidu

Aby ocenić wiarygodność centroidu, zaproponowano trzy osie diagnostyczne:

(1) **Test bliskości współautorów.** Zweryfikowano hipotezę, że współautorzy mają istotnie bliższe centroidy niż pary losowe, za pomocą testu U Manna–Whitneya. Potwierdzenie tej hipotezy waliduje, że embeddingi wychwytyują rzeczywiste podobieństwo badawcze.

(2) **Zgodność sąsiedztw top- $k$ .** Zmierzono miarę Jaccarda między zbiorami  $k$  najbliższych są-

siadów autora w różnych konfiguracjach (model  $\times$  typ tekstu wejściowego). Wysoka zgodność oznacza, że profil jest semantycznie stabilny niezależnie od wyboru modelu.

**(3) Stabilność centroidu względem liczby prac.** Obliczono średnie podobieństwo kosinusowe między centroidem zbudowanym z losowego podzbioru  $k$  prac a centroidem pełnym, dla  $k \in \{3, 5, 10, 20, 50, 100\}$ . Stabilność osiąga  $\sim 0,95$  dla  $k = 5$  i  $\sim 0,99$  dla  $k = 10$ , lecz rozkład jest heterogeniczny — sama liczba prac nie wystarcza do oceny wiarygodności centroidu.

Diagnostykę przeprowadzono na sześciu modelach embeddingowych (SPECTER, MiniLM-L6, MiniLM-L12, MPNet-Base, BGE-Small, Multilingual-MiniLM) i czterech wariantach tekstu wejściowego. Modele 768-wymiarowe sprowadzono do wspólnego wymiaru 384 przez projekcję Johnsona–Lindenstraussa, umożliwiając bezpośrednie porównania.

Jako dodatkowy sygnał interdyscyplinarności wprowadzono *miarę rozproszenia* (dispersion) embeddingów prac autora — niezależną od liczby publikacji. Zbiór cech diagnostycznych ( $n\_papers$ ,  $stability@k$ ,  $avg\_jaccard$ ,  $dispersion$ ) stanowi podstawę schematu decyzyjnego opisanego w sekcji 4.5.

### 4.3 Dostrojenie modelu embeddingowego

Model BGE-base dostrojono z wykorzystaniem funkcji straty CoSENTLoss na korpusie 18 880 artykułów ArXiv. Kluczowym elementem jest hierarchiczna funkcja odległości oparta na trzypoziomowej taksonomii ArXiv:

$$h(c_i, c_j) = \begin{cases} 0,00 & \text{ta sama podkategoria,} \\ 0,33 & \text{to samo archiwum,} \\ 0,67 & \text{ta sama grupa główna,} \\ 1,00 & \text{różne grupy.} \end{cases} \quad (4)$$

Dla artykułów z wieloma kategoriami (63,8% zbioru) wynikowy score łączy indeks Jaccarda zbiorów kategorii z najlepszą odległością hierarchiczną:

$$s(p_i, p_j) = 0,5 \cdot J(C_i, C_j) + 0,5 \cdot \min_{c_i \in C_i, c_j \in C_j} h(c_i, c_j). \quad (5)$$

Pary treningowe generowano ze stratyfikowanym próbkowaniem: 3 pary z tej samej podkategorii, 2 z tego samego archiwum, 2 z tej samej grupy i 1 z różnych grup — na każdy artykuł. Trening

**Tabela 3:** Wpływ dostrojenia BGE-base na metryki jakości.

| Metryka                      | Oryg.  | FT     | $\Delta$ |
|------------------------------|--------|--------|----------|
| Main-cat. purity ( $k=118$ ) | 68,07% | 73,76% | +5,69    |
| Fuzzy purity ( $k=118$ )     | 74,14% | 80,59% | +6,46    |
| Precision@10                 | 0,654  | 0,690  | +0,036   |
| Precision@20                 | 0,625  | 0,667  | +0,043   |
| Var. expl. PCA 2D (ArXiv)    | 12,19% | 29,37% | +17,18   |
| Var. expl. PCA 2D (autorzy)  | 33,11% | 54,71% | +21,60   |

**Tabela 4:** Wpływ progu silhouette na dekompozycję wieloklastrową ( $n=115$  autorów,  $\geq 5$  publikacji).

| Próg $s_{min}$ | Autorzy $k>1$ | %           | Śr. $k$     |
|----------------|---------------|-------------|-------------|
| 0,05           | 106           | 92,2        | 2,75        |
| 0,10           | 105           | 91,3        | 2,71        |
| <b>0,15</b>    | <b>98</b>     | <b>85,2</b> | <b>2,59</b> |
| 0,20           | 86            | 74,8        | 2,37        |
| 0,30           | 59            | 51,3        | 1,88        |

przeprowadzono na GPU A100 (Google Colab): 1 epoka, learning rate  $10^{-5}$ , batch size 64, warmup 10%.

Tabela 3 pokazuje wpływ dostrojenia. Na zbiorze ArXiv main-category purity wzrosła o 5,69 pp, a fuzzy purity o 6,46 pp. Kluczowym wynikiem jest wzrost wariancji wyjaśnionej w PCA 2D z 12,19% do 29,37% na ArXiv, a na profilach autorów WMI — z 33,11% do 54,71%, co czyni wizualizację 2D znacząco bardziej wiarygodną.

### 4.4 Dekompozycja wieloklastrowa

Dla autorów z co najmniej pięcioma publikacjami testowano K-means z  $k \in \{2, \dots, 5\}$ . Optymalną liczbę klastrów  $k^*$  wyznaczano jako maksymalizującą silhouette score, z progiem  $s_{min} = 0,15$  — poniżej którego autor otrzymuje reprezentację jednopunktową. Dobór progu uzasadniono empirycznie (Tab. 4).

Przy progu 0,15 — 85,2% autorów wykazuje wieloklastrową strukturę (średnio 2,59 klastra), generując łącznie 298 punktów reprezentacyjnych. Każdy klastery etykietowany jest automatycznie na podstawie trzech najczęstszych tematów i pięciu słów kluczowych z metadanych OpenAlex.

### 4.5 Schemat decyzyjny — reprezentacja adaptacyjna

Cechy diagnostyczne z diagnostyki stabilności (sekcja 4.2) łączone są z cechami strukturalnymi z dekompozycji wieloklastrowej w schemat decyzyjny przypisujący każdemu autorowi jeden z czte-

**Tabela 5:** Separacja 14 zakładów WMI ( $n = 92$  autorów).

| Metryka               | Oryg.        | FT           | $\Delta$ |
|-----------------------|--------------|--------------|----------|
| Intra-dept cosine sim | 0,858        | 0,967        | +0,109   |
| Inter-dept cosine sim | 0,756        | 0,911        | +0,155   |
| NMI                   | 0,672        | <b>0,702</b> | +0,030   |
| NN@1 accuracy         | <b>0,728</b> | 0,663        | -0,065   |
| NN@5 accuracy         | <b>0,609</b> | 0,478        | -0,130   |
| Dept purity (K-means) | 0,641        | 0,620        | -0,022   |
| Silhouette            | 0,064        | 0,060        | -0,004   |

rech trybów:

- **SINGLE** — stabilny centroid ( $stability@k \geq 0,95$ ) i brak wyraźnej struktury klastrowej ( $silhouette < 0,15$ );
- **MULTI** — stabilny centroid  $i$  istotna struktura klastrowa ( $silhouette \geq 0,15$ );
- **LOW\_CONF** — zbyt mało publikacji ( $n < 5$ ) dla wiarygodnej oceny;
- **AMBIGUOUS** — niestabilny centroid bez wyraźnej struktury klastrowej.

Kluczowym aspektem jest to, że autor otrzymuje tryb MULTI tylko wtedy, gdy zarówno jego centroid jest stabilny (diagnoza nie jest artefaktem małej próby), jak i silhouette podziału jest istotny (wielomodalność jest realna, a nie szumowa). Schemat materializowany jest jako artefakt `author_representation_policy.csv`, wiążący obie warstwy analizy.

## 5 Ewaluacja

### 5.1 Separacja zakładów WMI

Jakość reprezentacji autorów oceniono na niezależnym zadaniu separacji 14 zakładów WMI (92 autorów z jednoznacznym przypisaniem). Tabela 5 zestawia wyniki dla modelu oryginalnego i dostrojonego.

Dostrojenie poprawia globalną strukturę (NMI +0,030) kosztem lokalnego sąsiedztwa (NN@1 -6,5 pp, NN@5 -13,0 pp). Efekt wynika z „ściśnięcia” wszystkich embeddingów bliżej siebie — zarówno intra- jak i inter-departmentowe podobieństwo rośnie, lecz proporcjonalnie bardziej rośnie inter (+0,155 vs. +0,109). Jest to akceptowalny kompromis dla wizualizacji eksploracyjnej, gdzie globalna struktura („które zakłady są bliskie tematycznie?”) jest ważniejsza niż dokładność lokalnych sąsiedztw.

Analiza per zakład ujawnia trzy pary jednostek o niemal identycznym profilu semantycznym (po-

**Tabela 6:** Porównanie trzech wariantów reprezentacji autorów na zadaniu separacji 14 zakładów WMI.

| Wariant    | Punkty      | NMI         | NN@1        | Interpret.  |
|------------|-------------|-------------|-------------|-------------|
| baseline   | 115         | <i>TODO</i> | <i>TODO</i> | —           |
| aggressive | 298         | <i>TODO</i> | <i>TODO</i> | <i>TODO</i> |
| adaptive   | <i>TODO</i> | <i>TODO</i> | <i>TODO</i> | <i>TODO</i> |

dobieństwo  $> 0,99$ ): Z. Analizy Funkcjonalnej  $\leftrightarrow$  Z. Analizy Matematycznej, Z. Geometrii Algebraicznej  $\leftrightarrow$  Z. Geometrii Arytmetycznej oraz Z. Teorii Operatorów  $\leftrightarrow$  Z. Przestrzeni Funkcyjnych. Są to ściśle powiązane specjalizacje matematyczne — wysoka bliskość jest poprawna merytorycznie.

### 5.2 Porównanie wariantów reprezentacji

Porównano trzy warianty reprezentacji autorów na wizualizacji:

1. **baseline** — wszyscy autorzy jako pojedynczy centroid;
2. **aggressive** — wszyscy z  $\geq 5$  pracami z dekompozycją multi-cluster;
3. **adaptive** — decyzja per autor na podstawie schematu SINGLE/MULTI/LOW\_CONF/AMBIGUOUS.

Wariant baseline daje 115 punktów o najwyższej kompletności, lecz gubi informację o wielotorowości — autor interdyscyplinarny jest nieinformatywnie umieszczony „pomiędzy” swoimi obszarami. Wariant aggressive generuje 298 punktów, maksymalizując interpretowalność klastrow, lecz zawiera szumowe dekompozycje autorów o jednorodnym profilu. Wariant adaptive ( $n$  punktów zależne od profilu) oferuje kompromis: wielomodalność ujawniana jest tylko tam, gdzie jest wsparta zarówno diagnostyką stabilności, jak i strukturą klastrową.

### 5.3 Analiza przypadków

Wieloklastrowa dekompozycja ujawnia semantycznie spójne podziały. Przykładowo, jeden z autorów Z. Sztucznej Inteligencji został rozłożony na cztery klastry: *decision making*, *robotics*, *fuzzy optimization* oraz *ovarian cancer classification* — co odpowiada rzeczywistym, odrębnym nurtom jego badań.

Na mapie autorów (PCA 2D, model dostrojony) klastry takiego autora rozkładają się w odległych regionach przestrzeni, połączone cienkimi liniami wskazującymi przynależność do tej samej osoby. W wariacie baseline ten sam autor byłby umiesz-

czony jako pojedynczy punkt w centrum — nie dając informacji o żadnym z czterech kierunków.

## 6 Podsumowanie

Zaprezentowano system SARA — dwupoziomową platformę semantycznej eksploracji, łączącą wizualizację publikacji z adaptacyjnym profilowaniem autorów.

Na poziomie publikacji systematyczne porównanie ośmiu metod redukcji wymiarowości z siedmioma metrykami jakości i autorskim wskaźnikiem Composite Score wykazało, że metody nieliniowe (UMAP, PaCMAP, t-SNE) osiągają zbliżoną jakość ( $CS \approx 0,725$ ), znacząco przewyższając metody liniowe. PaCMAP rekomendujemy jako metodę domyślną ze względu na najlepszą korelację globalną przy porównywalnej wierności lokalnej.

Na poziomie autorów kluczowym wynikiem jest odejście od sztywnej reguły „jeden autor = jeden punkt” na rzecz reprezentacji adaptacyjnej. Dostrojenie modelu BGE-base funkcją CoSENTLoss z hierarchiczną odległością kategorii ArXiv poprawiło wariancję wyjaśnioną w PCA 2D z 33,11% do 54,71% na profilach autorów WMI. 85,2% autorów z  $\geq 5$  publikacjami wykazuje wieloklastrową strukturę profilu (średnio  $k = 2,59$ ), co potwierdza, że pojedynczy centroid jest niewystarczającą reprezentacją dla większości badaczy.

Schemat decyzyjny SINGLE/MULTI/LOW\_CONF/AMBIGUOUS, łączący diagnostykę stabilności centroidu z dekompozycją wieloklastrową, stanowi propozycję metodologiczną możliwą do zastosowania w innych systemach profilowania naukowców.

**Ograniczenia.** Ewaluacja przeprowadzona została na jednym wydziale (115 autorów). Brakuje ewaluacji eksperckiej (oceny przez samych badaczy, czy przypisane klastry odpowiadają ich subiektywnym nurtom badawczym). Próg silhouette  $s_{min} = 0,15$  wybrany jest heurystycznie.

**Kierunki dalszych badań.** Ewaluacja użytkownikowa, fine-tuning bezpośrednio na danych WMI, temporal embeddings (ewolucja profilu w czasie), graf cytowań jako dodatkowy sygnał, walidacja cross-institutional na danych innych uczelni.

## Literatura

[1] L. van der Maaten, G. Hinton, *Visualizing Data using t-SNE*, Journal of Machine Learning Research, 9:2579–2605, 2008.

[2] L. McInnes, J. Healy, J. Melville, *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*, arXiv:1802.03426, 2018.

[3] Y. Wang, H. Huang, C. Rudin, Y. Shaposhnik, *Understanding How Dimension Reduction Tools Work: An Empirical Approach to Deciphering t-SNE, UMAP, TriMAP, and PaCMAP for Data Visualization*, Journal of Machine Learning Research, 22(201):1–73, 2021.

[4] S. Xiao, Z. Liu, P. Zhang, N. Muennighoff, *C-Pack: Packaged Resources To Advance General Chinese Embedding*, arXiv:2309.07597, 2024.

[5] I. Coetzer, G. "; E. "; R. "; de Villiers, *CoSENT: A Contrastive Sentence Embedding Training Framework*, NeurIPS, 2022.

[6] W. B. Johnson, J. Lindenstrauss, *Extensions of Lipschitz mappings into a Hilbert space*, Contemporary Mathematics, 26:189–206, 1984.

[7] R. Tibshirani, G. Walther, T. Hastie, *Estimating the number of clusters in a data set via the gap statistic*, Journal of the Royal Statistical Society B, 63(2):411–423, 2001.

[8] J. Priem, H. Piwowar, R. Orr, *OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts*, arXiv:2205.01833, 2022.

[9] A. Cohan, S. Feldman, I. Beltagy, D. Downey, D. S. Weld, *SPECTER: Document-level Representation Learning using Citation-informed Transformers*, ACL, 2020.

[10] P. J. Rousseeuw, *Silhouettes: a Graphical Aid to the Interpretation and Validation of Cluster Analysis*, Computational and Applied Mathematics, 20:53–65, 1987.