

Adaptacyjna reprezentacja naukowców w przestrzeni embeddingów z oceną jakości redukcji wymiarowości

Patryk Żywica¹ Daria Dworzyńska-Wujec¹ Michał Wujec¹
Miłosz Rolewski¹ Jakub Paszke¹

¹Wydział Matematyki i Informatyki, Uniwersytet im. Adama Mickiewicza w Poznaniu
patryk.zywica@amu.edu.pl

Streszczenie. Dynamiczny wzrost liczby publikacji naukowych wymaga narzędzi umożliwiających automatyczną eksplorację zarówno pojedynczych artykułów, jak i profili badawczych ich autorów. W niniejszym artykule podejmujemy dwa powiązane problemy badawcze. Po pierwsze, badamy czy naukowca można wiarygodnie reprezentować pojedynczym punktem (centroidem) w przestrzeni embeddingów, czy też należy stosować reprezentację wielopunktową uwzględniającą wielomodalność profilu badawczego. Po drugie, przeprowadzamy systematyczne porównanie ośmiu metod redukcji wymiarowości pod kątem jakości wizualizacji zbiorów artykułów naukowych. Badania przeprowadzono na zbiorze $N = 3440$ publikacji 115 autorów z 14 jednostek organizacyjnych. Proponujemy adaptacyjną reprezentację, w której decyzja o liczbie punktów reprezentujących badacza podejmowana jest per autor na podstawie diagnostyki stabilności centroidu oraz automatycznej dekompozycji multi-cluster. Do oceny jakości projekcji 2D proponujemy autorski wskaźnik Composite Score, agregujący siedem metryk lokalnych i globalnych. Model embeddingowy BGE-base został dostrojony funkcją straty CoSENTLoss z hierarchiczną odległością kategorii ArXiv, co poprawiło wariancję wyjaśnioną w PCA 2D z 33,11% do 54,71% na profilach autorów. 85,2% autorów z co najmniej pięcioma publikacjami wykazuje wieloklastrową strukturę profilu badawczego (średnio $k = 2,59$ klastrow).

Słowa kluczowe: embeddingi tekstowe, redukcja wymiarowości, profilowanie naukowców, reprezentacja adaptacyjna, fine-tuning, wizualizacja danych naukowych

1 Wprowadzenie

Współczesna nauka generuje publikacje w tempie przekraczającym możliwości ręcznej analizy. Tylko

w roku 2024 w bazie OpenAlex zarejestrowano ponad 200 milionów prac naukowych. Dla badacza szukającego potencjalnych współpracowników, recenzenta oceniającego dorobek czy administratora jednostki potrzebne są narzędzia umożliwiające szybką eksplorację przestrzeni tematycznej — zarówno na poziomie pojedynczych artykułów, jak i całych profili badawczych.

Istniejące narzędzia eksploracji literatury — Google Scholar, Semantic Scholar, OpenAlex — umożliwiają wyszukiwanie artykułów po słowach kluczowych oraz przeglądanie grafów cytowań, lecz nie oferują wizualnej mapy tematycznej pozwalającej na szybką orientację w strukturze dyscypliny. Grupowanie autorów według profilu badawczego wymaga ręcznej analizy dorobku lub opiera się na prostych wskaźnikach bibliometrycznych (np. h-indeks), które nie uwzględniają semantycznej bliskości tematów. Wizualizacja oparta na embeddingach tekstowych oferuje alternatywę: automatyczną projekcję zbioru publikacji lub profili autorów na mapę 2D, na której bliskość przestrzenna odpowiada podobieństwu treściowemu.

Reprezentacja tekstu za pomocą embeddingów — gęstych wektorów w przestrzeni $\mathbb{R}^d$ wytwarzanych przez pretrenowane modele językowe — jest standardowym podejściem do semantycznego modelowania dokumentów. Na ich podstawie profil badawczy autora można aproksymować jako centroid (uśredniony wektor) embeddingów jego publikacji. Podejście to zakłada jednak jednomodalność profilu, co nie jest spełnione dla badaczy interdyscyplinarnych. Pierwszym problemem badawczym podejmowanym w niniejszej pracy jest zatem pytanie: czy naukowca można wiarygodnie reprezentować pojedynczym centroidem, czy też należy stosować reprezentację wielopunktową? Drugim problemem jest ocena jakości wizualizacji 2D — redukcja z $d = 768$ wymiarów do dwóch jest

teoretycznie silnie stratna, a mapę 2D uznaje się za wiarygodną dopiero po rygorystycznej walidacji. Projekcja do dwóch wymiarów, choć drastycznie redukuje informację, jest jedynym formatem umożliwiającym bezpośrednią wizualną inspekcję przez człowieka.

W ramach niniejszej pracy zaproponowano i zbadano następujące podejścia:

1. adaptacyjną reprezentację autorów, łączącą diagnostykę stabilności centroidu z automatyczną dekompozycją wieloklastrową i dostrojeniem modelu embeddingowego z wykorzystaniem hierarchicznej taksonomii kategorii ArXiv,
2. systematyczne porównanie ośmiu metod redukcji wymiarowości z użyciem siedmiu metryk jakości projekcji oraz autorskiego wskaźnika Composite Score.

Badania przeprowadzono na zbiorze publikacji pracowników Wydziału Matematyki i Informatyki Uniwersytetu im. Adama Mickiewicza w Poznaniu ($N = 3440$ artykułów, 115 autorów, 14 jednostek organizacyjnych).

Artykuł ma następującą strukturę. Sekcja 2 opisuje materiały i przygotowanie danych. Sekcja 3 przedstawia proponowane podejście w dwóch obszarach: adaptacyjna reprezentacja autorów oraz ocena jakości redukcji wymiarowości. Sekcja 4 prezentuje wyniki eksperymentów, a sekcja 5 podsumowuje pracę.

2 Materiały i przygotowanie danych

2.1 Przygotowanie zbioru danych

Dane pozyskano z Portalu Badawczego UAM oraz interfejsu OpenAlex API [9]. Procedura zbierania obejmowała cztery etapy: (1) scraping profili pracowników WMI z ekstrakcją identyfikatorów ORCID i Scopus, (2) pobieranie metadanych publikacji z OpenAlex na podstawie ORCID, (3) uzupełnianie brakujących abstraktów przez bezpośredni scraping witryn wydawców (16 wariantów selektorów CSS), (4) filtrowanie i deduplikacja. Wynikowy zbiór liczy $N = 3440$ publikacji przypisanych do 115 autorów z 14 jednostek organizacyjnych WMI. Średnia liczba publikacji na autora wynosi 29,9 (mediana 19).

Ze zbioru wykluczono publikacje pozbawione abstraktu po etapie uzupełniania (etap 3) oraz duplikaty zidentyfikowane na podstawie identyfikatora DOI. Autorów bez żadnej publikacji z abstraktem ($n = 49$) wykluczono z dalszych analiz,

Tabela 1: Porównanie modeli embeddingowych (top 5 z 9 testowanych, ArXiv $n = 2397$, $k = 118$).

Model	d	Purity
BGE-base-en-v1.5	768	70,55%
BGE-large-en-v1.5	1024	69,63%
Nomic-embed-v1.5	768	69,50%
SPECTER	768	68,88%
all-mpnet-base-v2	768	68,09%

pozostawiając 115 autorów z co najmniej jedną reprezentowalną pracą.

Jako korpus referencyjny do dostrojenia modelu embeddingowego wykorzystano zbiór 18 880 artykułów pobranych z repozytorium ArXiv — po 200 z każdej ze 118 podkategorii. ArXiv stanowi dogodnie źródło danych referencyjnych dzięki hierarchicznej, trzypoziomowej taksonomii kategorii (grupa główna $\rightarrow$ archiwum $\rightarrow$ podkategoria), która dostarcza sygnału nadzoru do uczenia metrycznego. 63,8% artykułów w tym zbiorze posiada więcej niż jedną kategorię (średnio 2,06).

2.2 Embeddingi tekstowe

Dla każdej publikacji generowany jest embedding na podstawie konkatenacji tytułu i abstraktu: "{title}. {abstract}". Wektory mają wymiar $d = 768$ i są normalizowane L^2 , dzięki czemu odległość euklidesowa staje się monotoniczna względem podobieństwa kosinusowego:

$$\|e_i - e_j\|^2 = 2(1 - e_i \cdot e_j). \quad (1)$$

Wybór modelu embeddingowego stanowił decyzję badawczą opartą na porównaniu dziewięciu pretrenowanych modeli (Tab. 1) na podzbiorze 2397 artykułów ArXiv. Jako kryterium wyboru przyjęto main-category purity — odsetek par artykułów w tym samym klastrze K-means, które dzielą główną kategorię ArXiv. Najwyższą wartość (70,55% dla $k = 118$) uzyskał model BAAI/bge-base-en-v1.5, który wybrano jako model bazowy do dalszych badań.

3 Proponowane podejście

Proponowane podejście obejmuje dwa uzupełniające się obszary. Pierwszy dotyczy reprezentacji autorów w przestrzeni embeddingów — od diagnostyki stabilności centroidu, przez dostrojenie modelu, po schemat decyzyjny o trybie reprezentacji (jednopunktowa vs. wieloklastrowa). Drugi dotyczy oceny jakości projekcji 2D — od wyboru metryk, po autorski wskaźnik Composite Score agre-

gujący ich sygnały. Oba obszary łączy wspólna przestrzeń embeddingów: jakość wizualizacji 2D warunkuje interpretowalność map autorów.

3.1 Adaptacyjna reprezentacja autora

Centroid i problem wielomodalności. Naturalną reprezentacją profilu badawczego autora a jest centroid — uśredniony wektor embeddingów jego publikacji:

$$\hat{e}_a = \frac{\bar{e}_a}{\|\bar{e}_a\|}, \quad \bar{e}_a = \frac{1}{n_a} \sum_{p \in P_a} e_p, \quad (2)$$

gdzie P_a to zbiór publikacji autora, a normalizacja L^2 zapewnia porównywalność z embeddingami artykułów. Mean pooling działa jako filtr szumów (wygładza jednorazowe tematy), jest stałowymiarowy i łatwo aktualizowalny inkrementalnie.

Problem pojawia się dla autorów o zróżnicowanym profilu: centroid badacza łączącego np. robotykę z medycyną trafia w pustą przestrzeń „pomiędzy” tymi obszarami, nie reprezentując wiernie żadnego z nich.

Diagnostyka stabilności centroidu. Aby ocenić wiarygodność centroidu, zaproponowano trzy osie diagnostyczne:

(1) **Test bliskości współautorów.** Zweryfikowano hipotezę, że współautorzy mają istotnie bliższe centroidy niż pary losowe, za pomocą testu U Manna–Whitneya. Potwierdzenie tej hipotezy waliduje, że embeddingi wychwytyują rzeczywiste podobieństwo badawcze.

(2) **Zgodność sąsiedztw top- k .** Zmierzono miarę Jaccarda między zbiorami k najbliższych sąsiadów autora w różnych konfiguracjach (model $\times$ typ tekstu wejściowego). Wysoka zgodność oznacza, że profil jest semantycznie stabilny niezależnie od wyboru modelu.

(3) **Stabilność centroidu względem liczby prac.** Obliczono średnie podobieństwo kosinusowe między centroidem zbudowanym z losowego podzbioru k prac a centroidem pełnym, dla $k \in \{3, 5, 10, 20, 50, 100\}$.

Diagnostykę przeprowadzono na sześciu modelach embeddingowych (SPECTER, MiniLM-L6, MiniLM-L12, MPNet-Base, BGE-Small, Multilingual-MiniLM) i czterech wariantach tekstu wejściowego. Modele 768-wymiarowe sprowadzono do wspólnego wymiaru 384 przez projekcję Johnsona–Lindenstraussa, umożliwiając bezpośrednie porównania.

Jako dodatkowy sygnał interdyscyplinarności wprowadzono *miarę rozproszenia* (dispersion) em-

beddingów prac autora — niezależną od liczby publikacji.

Dostrojenie modelu embeddingowego. Model BGE-base dostrojono z wykorzystaniem funkcji straty CoSENTLoss na korpusie 18 880 artykułów ArXiv. Kluczowym elementem jest hierarchiczna funkcja odległości oparta na trzypoziomowej taksonomii ArXiv:

$$h(c_i, c_j) = \begin{cases} 0,00 & \text{ta sama podkategoria,} \\ 0,33 & \text{to samo archiwum,} \\ 0,67 & \text{ta sama grupa główna,} \\ 1,00 & \text{różne grupy.} \end{cases} \quad (3)$$

Dla artykułów z wieloma kategoriami (63,8% zbioru) wynikowy score łączy indeks Jaccarda zbiorów kategorii z najlepszą odległością hierarchiczną:

$$s(p_i, p_j) = 0,5 \cdot J(C_i, C_j) + 0,5 \cdot \min_{c_i \in C_i, c_j \in C_j} h(c_i, c_j). \quad (4)$$

Dekompozycja wieloklastrowa. Dla autorów z co najmniej pięcioma publikacjami testowany jest K-means z $k \in \{2, \dots, 5\}$. Optymalną liczbę klastrow k^* wyznacza się jako maksymalizującą silhouette score [11], z progiem s_{min} — poniżej którego autor otrzymuje reprezentację jednopunktową. Każdy klastrow etykietowany jest automatycznie na podstawie trzech najczęstszych tematów i pięciu słów kluczowych z metadanych OpenAlex.

Schemat decyzyjny. Zbiór cech diagnostycznych ($n_papers, stability@k, avg_jaccard, dispersion$) łączy z cechami strukturalnymi z dekompozycji wieloklastrowej w schemat decyzyjny przypisujący każdemu autorowi jeden z czterech trybów:

- **SINGLE** — stabilny centroid ($stability@k \geq 0,95$) i brak wyraźnej struktury klastrowej ($silhouette < s_{min}$);
- **MULTI** — stabilny centroid i istotna struktura klastrowa ($silhouette \geq s_{min}$);
- **LOW_CONF** — zbyt mało publikacji ($n < 5$) dla wiarygodnej oceny;
- **AMBIGUOUS** — niestabilny centroid bez wyraźnej struktury klastrowej.

Kluczowym aspektem jest to, że autor otrzymuje tryb MULTI tylko wtedy, gdy zarówno jego centroid jest stabilny (diagnoza nie jest artefaktem małej próby), jak i silhouette podziału jest istotny (wielomodalność jest realna, a nie szumowa).

3.2 Ocena jakości redukcji wymiarowości

Wizualizacja zbiorów artykułów wymaga projekcji z przestrzeni $\mathbb{R}^{768}$ do $\mathbb{R}^2$. Jakość takiej projekcji nie jest oczywista — różne metody zachowują różne aspekty struktury danych. Problem oceny jakości redukcji wymiarowości formalizujemy jako wielokryterialną ocenę odwzorowania $f : \mathbb{R}^{768} \rightarrow \mathbb{R}^2$ pod kątem zachowania relacji lokalnych (sąsiedztwa) i globalnych (odległości).

Metody redukcji wymiarowości. Porównano osiem metod, podzielonych na dwie grupy.

Metody lokalne koncentrują się na zachowaniu sąsiedztw:

- **t-SNE** [1] — minimalizuje dywergencję KL między rozkładami prawdopodobieństwa sąsiedztw w przestrzeni oryginalnej i docelowej;
- **UMAP** [2] — modeluje strukturę danych jako ważony graf simpleksów rozmytych;
- **PaCMAP** [3] — optymalizuje trzy typy par (bliskie, średnie, dalekie) z adaptacyjnymi wagami;
- **Spectral Embedding** — wykorzystuje wektory własne laplasjanu grafu sąsiedztwa.

Metody globalne/liniowe zachowują relacje na większą skalę:

- **PCA** — maksymalizuje wariancję wzdłuż głównych osi;
- **Isomap** [4] — zachowuje odległości geodezyjne na rozmaitości;
- **LDA** — maksymalizuje separację klas (metoda nadzorowana);
- **PCA 8D+log** — pipeline: podobieństwo kosinusowe do centroidów klastrów, transformacja logarytmiczna, PCA do 2D.

Metryki jakości projekcji. Aby zbudować wielokryterialną ocenę, zdefiniowano siedem metryk podzielonych na lokalne i globalne:

Metryki lokalne: (1) *kNN Recall@100* — odsetek prawdziwych sąsiadów w 768D zachowanych w 2D; (2) *Trustworthiness* — odsetek sąsiadów w 2D, którzy są rzeczywistymi sąsiadami w 768D; (3) *Neighbourhood Hit* — odsetek k -sąsiadów w 2D należących do tego samego klastra.

Metryki globalne: (4) *korelacja rang Spearmana* (ρ) — monotoniczność relacji odległości; (5) *korelacja Pearsona* (r) — liniowość zachowania odległości; (6) *Kruskal Stress* (σ) — znormalizowany błąd odwzorowania odległości; (7) *SPDE* — skalowana różnica odległości parami.

Composite Score. Na bazie powyższych sied-

miu metryk zaproponowano autorski wskaźnik Composite Score (CS), łączący metryki lokalne i globalne w jedną miarę jakości projekcji:

$$CS = \sum_{i=1}^7 w_i \cdot m_i, \quad (5)$$

gdzie m_i to znormalizowana wartość i -tej metryki, a w_i — jej waga. Wagi wyznaczono empirycznie poprzez analizę korelacji między metrykami i minimalizację redundancji, a następnie zwalidowano przez porównanie rankingu metod z niezależną oceną użytkownikową. Jako dodatkową walidację zastosowano całą Choquet z 2-addytywną miarą rozmytą, wyznaczając wartości Shapleya dla poszczególnych metryk.

4 Wyniki

4.1 Konfiguracja eksperymentów

Wszystkie eksperymenty przeprowadzono na zbiorze $N = 3440$ publikacji w przestrzeni $d = 768$ z miarą odległości kosinusowej. Dostrojenie modelu wykonano na GPU A100 (Google Colab): 1 epoka, learning rate 10^{-5} , batch size 64, warmup 10%. Pary treningowe generowano ze stratyfikowanym próbkowaniem: 3 pary z tej samej podkategorii, 2 z tego samego archiwum, 2 z tej samej grupy i 1 z różnych grup — na każdy artykuł.

Optymalną liczbę klastrów k dla wizualizacji publikacji wyznaczono metodą konsensusu sześciu kryteriów: metoda łokcia, silhouette score, statystyka luki [8], indeks Calińskiego-Harabasa, indeks Daviesa-Bouldina oraz analiza stabilności (bootstrap Jaccard). Głosowanie większościowe wskazało $k = 9$ (silhouette = 0,2823). Próg silhouette dla dekompozycji wieloklastrowej autorów ustalono na $s_{min} = 0,15$.

4.2 Porównanie metod redukcji wymiarowości

Tabela 2 przedstawia wyniki porównania ośmiu metod. Trzy metody nieliniowe — UMAP ($CS = 0,727$), PaCMAP ($CS = 0,725$) i t-SNE ($CS = 0,724$) — osiągają zbliżone wyniki, znacząco przewyższając pozostałe. Różnice między nimi są marginalne ($\Delta CS < 0,004$), co sugeruje, że wybór spośród nich powinien uwzględniać dodatkowe kryteria praktyczne.

UMAP i PaCMAP wyróżniają się najlepszym kompromisem między wiernością lokalną a globalną. t-SNE osiąga najwyższy kNN Recall (0,611) i Neighbourhood Hit (0,918), lecz kosztem korelacji

Tabela 2: Porównanie ośmiu metod DR na zbiorze $N = 3440$ publikacji ($k = 9$ klastrów). CS — Composite Score, kNN — kNN Recall@100, Trust — Trustworthiness, NH — Neighbourhood Hit, ρ — Spearman.

Metoda	CS	kNN	Trust	NH	ρ
UMAP	0,727	0,587	0,961	0,908	0,679
PaCMAP	0,725	0,573	0,963	0,908	0,709
t-SNE	0,724	0,611	0,972	0,918	0,563
Isomap	0,605	0,319	0,868	0,747	0,716
PCA	0,576	0,260	0,855	0,711	0,685
LDA	0,575	0,216	0,879	0,878	0,773
Spectral	0,536	0,314	0,850	0,800	0,741
8D+log	0,530	0,197	0,816	0,498	0,770

globalnej ($\rho = 0,563$) — efekt dobrze udokumentowany w literaturze, wynikający z jądra Studenta w przestrzeni docelowej. PaCMAP natomiast uzyskuje najwyższą korelację rang ($\rho = 0,709$) przy porównywalnej wierności lokalnej.

Metody liniowe (PCA, LDA, 8D+log) ustępują nieliniowym pod względem CS, lecz zachowują wyższą korelację globalną ($\rho > 0,68$). LDA osiąga wysoki Neighbourhood Hit (0,878), lecz jest to artefakt metody nadzorowanej — maksymalizuje separację klas z definicji, co stanowi rozumowanie kołowe w kontekście oceny klasteryzacji.

Całka Choquet z wartościami Shapleya potwierdza ranking, wskazując na PaCMAP i UMAP jako metody o najlepszym profilu wielokryterialnym, z dominującymi wagami dla korelacji Spearmana (0,189) i zachowania odległości (0,147).

Uzyskane wartości metryk należy interpretować w kontekście ograniczenia Johnsona–Lindenstraussa [7]: wierna projekcja $n = 3440$ punktów z dokładnością $\varepsilon = 0,1$ wymaga co najmniej $d_{\min} \approx 1200$ wymiarów. Redukcja do 2 wymiarów jest zatem $600\times$ poniżej tego minimum, co wyjaśnia, dlaczego nawet najlepsza metoda osiąga kNN Recall poniżej 0,62 — jest to wynik matematycznie oczekiwany, a nie słabość konkretnej metody.

4.3 Wpływ dostrojenia modelu

Tabela 3 zestawia wpływ dostrojenia modelu BGE-base na metryki jakości embeddingów. Na zbiorze ArXiv main-category purity wzrosła o 5,69 pp, a fuzzy purity o 6,46 pp. Kluczowym wynikiem jest wzrost wariancji wyjaśnionej w PCA 2D z 12,19% do 29,37% na ArXiv, a na profilach autorów WMI — z 33,11% do 54,71%, co czyni wizualizację 2D znacząco bardziej wiary-

Tabela 3: Wpływ dostrojenia BGE-base na metryki jakości.

Metryka	Oryg.	FT	Δ
Main-cat. purity ($k = 118$)	68,07%	73,76%	+5,69
Fuzzy purity ($k = 118$)	74,14%	80,59%	+6,46
Precision@10	0,654	0,690	+0,036
Precision@20	0,625	0,667	+0,043
Var. expl. PCA 2D (ArXiv)	12,19%	29,37%	+17,18
Var. expl. PCA 2D (autorzy)	33,11%	54,71%	+21,60

Tabela 4: Wpływ progu silhouette na dekompozycję wieloklastrową ($n = 115$ autorów, ≥ 5 publikacji).

Próg $s_{\min}$	Autorzy $k > 1$	%	Śr. k
0,05	106	92,2	2,75
0,10	105	91,3	2,71
0,15	98	85,2	2,59
0,20	86	74,8	2,37
0,30	59	51,3	1,88

godną.

4.4 Dekompozycja wieloklastrowa autorów

Tabela 4 przedstawia wpływ progu silhouette na wynik dekompozycji. Przy wybranym progu $s_{\min} = 0,15$ — 85,2% autorów wykazuje wieloklastrową strukturę (średnio 2,59 klastra), generując łącznie 298 punktów reprezentacyjnych.

Stabilność centroidu osiąga $\sim 0,95$ dla $k = 5$ prac i $\sim 0,99$ dla $k = 10$, lecz rozkład jest heterogeniczny — sama liczba prac nie wystarcza do oceny wiarygodności, co uzasadnia wprowadzenie wielowymiarowego schematu diagnostycznego.

4.5 Separacja jednostek organizacyjnych

Jakość reprezentacji autorów oceniono na niezależnym zadaniu separacji 14 jednostek WMI (92 autorów z jednoznacznym przypisaniem). Tabela 5 zestawia wyniki dla modelu oryginalnego i dostrojonego.

Dostrojenie poprawia globalną strukturę (NMI +0,030) kosztem lokalnego sąsiedztwa (NN@1 –6,5 pp, NN@5 –13,0 pp). Efekt wynika z „ściśnięcia” wszystkich embeddingów bliżej siebie — zarówno intra- jak i inter-departmentowe podobieństwo rośnie, lecz proporcjonalnie bardziej rośnie inter (+0,155 vs. +0,109). Jest to akceptowalny kompromis dla wizualizacji eksploracyjnej, gdzie globalna struktura („które jednostki są bliskie tematycznie?”) jest ważniejsza niż dokładność

Tabela 5: Separacja 14 jednostek WMI ($n = 92$ autorów).

Metryka	Oryg.	FT	Δ
Intra-dept cosine sim	0,858	0,967	+0,109
Inter-dept cosine sim	0,756	0,911	+0,155
NMI	0,672	0,702	+0,030
NN@1 accuracy	0,728	0,663	-0,065
NN@5 accuracy	0,609	0,478	-0,130
Dept purity (K-means)	0,641	0,620	-0,022
Silhouette	0,064	0,060	-0,004

Tabela 6: Porównanie trzech wariantów reprezentacji autorów na zadaniu separacji 14 jednostek WMI.

Wariant	Punkty	NMI	NN@1	Interpret.
baseline	115	<i>TODO</i>	<i>TODO</i>	—
aggressive	298	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
adaptive	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>

lokalnych sąsiedztw.

Analiza per jednostkę ujawnia trzy pary o niemal identycznym profilu semantycznym (podobieństwo $> 0,99$): Z. Analizy Funkcjonalnej $\leftrightarrow$ Z. Analizy Matematycznej, Z. Geometrii Algebraicznej $\leftrightarrow$ Z. Geometrii Arytmetycznej oraz Z. Teorii Operatorów $\leftrightarrow$ Z. Przestrzeni Funkcyjnych. Są to ściśle powiązane specjalizacje matematyczne — wysoka bliskość jest poprawna merytorycznie.

4.6 Porównanie wariantów reprezentacji

Porównano trzy warianty reprezentacji autorów na wizualizacji:

1. **baseline** — wszyscy autorzy jako pojedynczy centroid;
2. **aggressive** — wszyscy z ≥ 5 pracami z dekompozycją multi-cluster;
3. **adaptive** — decyzja per autor na podstawie schematu SINGLE/MULTI/LOW_CONF/AMBIGUOUS.

Wariant baseline daje 115 punktów o najwyższej kompletności, lecz gubi informację o wielotorowości — autor interdyscyplinarny jest nieinformatywnie umieszczony „pomiędzy” swoimi obszarami. Wariant aggressive generuje 298 punktów, maksymalizując interpretowalność klastrów, lecz zawiera szumowe dekompozycje autorów o jednorodnym profilu. Wariant adaptive (n punktów zależne od profilu) oferuje kompromis: wielomodalność ujawniana jest tylko tam, gdzie jest wsparta zarówno diagnostyką stabilności, jak i strukturą

klastrową.

4.7 Analiza przypadków

Wieloklastrowa dekompozycja ujawnia semantycznie spójne podziały. Przykładowo, jeden z autorów Z. Sztucznej Inteligencji został rozłożony na cztery klastry: *decision making*, *robotics*, *fuzzy optimization* oraz *ovarian cancer classification* — co odpowiada rzeczywistym, odrębnym nurtom jego badań.

Na mapie autorów (PCA 2D, model dostrojony) klastry takiego autora rozkładają się w odległych regionach przestrzeni, połączone cienkimi liniami wskazującymi przynależność do tej samej osoby. W wariancie baseline ten sam autor byłby umieszczony jako pojedynczy punkt w centrum — nie dając informacji o żadnym z czterech kierunków.

5 Podsumowanie

W niniejszej pracy zaproponowano i zbadano dwa powiązane podejścia do semantycznej eksploracji dorobku naukowego: adaptacyjną reprezentację autorów w przestrzeni embeddingów oraz wielokryterialną ocenę jakości redukcji wymiarowości.

Na poziomie publikacji systematyczne porównanie ośmiu metod redukcji wymiarowości z siedmioma metrykami jakości i autorskim wskaźnikiem Composite Score wykazało, że metody nieliniowe (UMAP, PaCMAP, t-SNE) osiągają zbliżoną jakość ($CS \approx 0,725$), znacząco przewyższając metody liniowe.

Na poziomie autorów kluczowym wynikiem jest odejście od sztywnej reguły „jeden autor = jeden punkt” na rzecz reprezentacji adaptacyjnej. Dostrojenie modelu BGE-base funkcją CoSENTLoss z hierarchiczną odległością kategorii ArXiv poprawiło wariancję wyjaśnioną w PCA 2D z 33,11% do 54,71% na profilach autorów. 85,2% autorów z ≥ 5 publikacjami wykazuje wieloklastrową strukturę profilu (średnio $k = 2,59$), co potwierdza, że pojedynczy centroid jest niewystarczającą reprezentacją dla większości badaczy.

Schemat decyzyjny SINGLE/MULTI/LOW_CONF/AMBIGUOUS, łączący diagnostykę stabilności centroidu z dekompozycją wieloklastrową, stanowi główny wkład metodologiczny niniejszej pracy, możliwy do zastosowania w innych kontekstach profilowania naukowców.

Ograniczenia. Ewaluacja przeprowadzona została na zbiorze 115 autorów z jednej jednostki akademickiej. Brakuje ewaluacji eksperckiej

(oceny przez samych badaczy, czy przypisane klastry odpowiadają ich subiektywnym nurtom badawczym). Próg silhouette $s_{min} = 0,15$ wybrany jest heurystycznie.

Kierunki dalszych badań. Ewaluacja użytkownikowa, fine-tuning bezpośrednio na danych docelowej jednostki, temporal embeddings (ewolucja profilu w czasie), graf cytowań jako dodatkowy sygnał, walidacja na danych innych jednostek akademickich.

Literatura

- [1] L. van der Maaten, G. Hinton, *Visualizing Data using t-SNE*, Journal of Machine Learning Research, 9:2579–2605, 2008.
- [2] L. McInnes, J. Healy, J. Melville, *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*, arXiv:1802.03426, 2018.
- [3] Y. Wang, H. Huang, C. Rudin, Y. Shaposhnik, *Understanding How Dimension Reduction Tools Work: An Empirical Approach to Deciphering t-SNE, UMAP, TriMAP, and PaCMAP for Data Visualization*, Journal of Machine Learning Research, 22(201):1–73, 2021.
- [4] J. B. Tenenbaum, V. de Silva, J. C. Langford, *A Global Geometric Framework for Nonlinear Dimensionality Reduction*, Science, 290(5500):2319–2323, 2000.
- [5] S. Xiao, Z. Liu, P. Zhang, N. Muennighoff, *C-Pack: Packaged Resources To Advance General Chinese Embedding*, arXiv:2309.07597, 2024.
- [6] J. Su, *CoSENT: A more efficient sentence vector scheme than Sentence-BERT*, Blog post, 2022.
- [7] W. B. Johnson, J. Lindenstrauss, *Extensions of Lipschitz mappings into a Hilbert space*, Contemporary Mathematics, 26:189–206, 1984.
- [8] R. Tibshirani, G. Walther, T. Hastie, *Estimating the number of clusters in a data set via the gap statistic*, Journal of the Royal Statistical Society B, 63(2):411–423, 2001.
- [9] J. Priem, H. Piwowar, R. Orr, *OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts*, arXiv:2205.01833, 2022.
- [10] A. Cohan, S. Feldman, I. Beltagy, D. Downey, D. S. Weld, *SPECTER: Document-level Representation Learning using Citation-informed Transformers*, ACL, 2020.
- [11] P. J. Rousseeuw, *Silhouettes: a Graphical Aid to the Interpretation and Validation of Cluster Analysis*, Computational and Applied Mathematics, 20:53–65, 1987.