

Adaptacyjna reprezentacja naukowców w przestrzeni embeddingów z oceną jakości redukcji wymiarowości

Patryk Żywica¹ Daria Dworzyńska-Wujec¹ Michał Wujec¹
Jakub Paszke¹

¹Wydział Matematyki i Informatyki, Uniwersytet im. Adama Mickiewicza w Poznaniu
patryk.zywica@amu.edu.pl

Streszczenie. Dynamiczny wzrost liczby publikacji naukowych wymaga narzędzi umożliwiających automatyczną eksplorację zarówno pojedynczych artykułów, jak i profili badawczych ich autorów. W niniejszym artykule podejmujemy dwa powiązane problemy badawcze. Po pierwsze, badamy czy naukowca można wiarygodnie reprezentować pojedynczym punktem (centroidem) w przestrzeni embeddingów, czy też należy stosować reprezentację wielopunktową uwzględniającą wielomodalność profilu badawczego. Po drugie, przeprowadzamy systematyczne porównanie ośmiu metod redukcji wymiarowości pod kątem jakości wizualizacji zbiorów artykułów naukowych. Badania przeprowadzono na zbiorze $N = 3440$ publikacji 115 autorów z 14 jednostek organizacyjnych. Proponujemy adaptacyjną reprezentację, w której decyzja o liczbie punktów reprezentujących badacza podejmowana jest per autor na podstawie diagnostyki stabilności centroidu oraz automatycznej dekompozycji multi-cluster. Do oceny jakości projekcji 2D proponujemy autorski wskaźnik Composite Score, agregujący siedem metryk lokalnych i globalnych. Model embeddingowy BGE-base został dostrojony funkcją straty CoSENTLoss z hierarchiczną odległością kategorii ArXiv, co poprawiło wariancję wyjaśnioną w PCA 2D z 33,11% do 54,71% na profilach autorów. Znaczna większość autorów z co najmniej pięcioma publikacjami (85,2%) wykazuje wieloklastrową strukturę profilu badawczego (średnio $k = 2,59$ klastrów).

Słowa kluczowe: embeddingi tekstowe, redukcja wymiarowości, profilowanie naukowców, reprezentacja adaptacyjna, fine-tuning, wizualizacja danych naukowych

1 Wprowadzenie

Współczesna nauka generuje publikacje w tempie przekraczającym możliwości ręcznej analizy. Tylko w roku 2024 w bazie OpenAlex zarejestrowano ponad 200 milionów prac naukowych. Dla badacza szukającego potencjalnych współpracowników, recenzenta oceniającego dorobek czy administratora jednostki potrzebne są narzędzia umożliwiające szybką eksplorację przestrzeni tematycznej — zarówno na poziomie pojedynczych artykułów, jak i całych profili badawczych.

Istniejące narzędzia eksploracji literatury — Google Scholar, Semantic Scholar, OpenAlex — umożliwiają wyszukiwanie artykułów po słowach kluczowych oraz przeglądanie grafów cytowań, lecz nie oferują wizualnej mapy tematycznej pozwalającej na szybką orientację w strukturze dyscypliny. Grupowanie autorów według profilu badawczego wymaga ręcznej analizy dorobku lub opiera się na prostych wskaźnikach bibliometrycznych (np. h-indeks), które nie uwzględniają semantycznej bliskości tematów. Wizualizacja oparta na embeddingach tekstowych oferuje alternatywę: automatyczną projekcję zbioru publikacji lub profili autorów na mapę 2D, na której bliskość przestrzenna odpowiada podobieństwu treściowemu.

Reprezentacja tekstu za pomocą embeddingów — gęstych wektorów w przestrzeni $\mathbb{R}^d$ wytwarzanych przez pretrenowane modele językowe — jest standardowym podejściem do semantycznego modelowania dokumentów. Na ich podstawie profil badawczy autora można aproksymować jako centroid (uśredniony wektor) embeddingów jego publikacji. Podejście to zakłada jednak jednomodalność profilu, co nie jest spełnione dla badaczy interdyscyplinarnych. Pierwszym problemem badawczym podejmowanym w niniejszej pracy jest zatem pytanie: czy naukowca można wiarygodnie reprezentować pojedynczym centroidem, czy

też należy stosować reprezentację wielopunktową? Drugim problemem jest ocena jakości wizualizacji 2D — redukcja z $d = 768$ wymiarów do dwóch jest teoretycznie silnie stratna, a mapę 2D uznaje się za wiarygodną dopiero po rygorystycznej walidacji. Projekcja do dwóch wymiarów, choć drastycznie redukuje informację, jest jedynym formatem umożliwiającym bezpośrednią wizualną inspekcję przez człowieka.

W ramach niniejszej pracy zaproponowano i zbadano następujące podejścia:

1. adaptacyjną reprezentację autorów, łączącą diagnostykę stabilności centroidu z automatyczną dekompozycją wieloklastrową i dostrojeniem modelu embeddingowego z wykorzystaniem hierarchicznej taksonomii kategorii ArXiv,
2. systematyczne porównanie ośmiu metod redukcji wymiarowości z użyciem siedmiu metryk jakości projekcji oraz autorskiego wskaźnika Composite Score.

Badania przeprowadzono na zbiorze publikacji pracowników Wydziału Matematyki i Informatyki Uniwersytetu im. Adama Mickiewicza w Poznaniu ($N = 3440$ artykułów, 115 autorów, 14 jednostek organizacyjnych).

Artykuł ma następującą strukturę. Sekcja 2 opisuje materiały i przygotowanie danych. Sekcja 3 przedstawia proponowane podejście w dwóch obszarach: adaptacyjna reprezentacja autorów oraz ocena jakości redukcji wymiarowości. Sekcja 4 prezentuje wyniki eksperymentów, a sekcja 5 podsumowuje pracę.

2 Materiały i przygotowanie danych

2.1 Przygotowanie zbioru danych

Dane pozyskano z Portalu Badawczego UAM oraz interfejsu OpenAlex API [9]. Procedura zbierania obejmowała cztery etapy: (1) scraping profili pracowników WMI z ekstrakcją identyfikatorów ORCID i Scopus, (2) pobieranie metadanych publikacji z OpenAlex na podstawie ORCID, (3) uzupełnianie brakujących abstraktów przez bezpośredni scraping witryn wydawców (16 wariantów selektorów CSS), (4) filtrowanie i deduplikacja. Wynikowy zbiór liczy $N = 3440$ publikacji przypisanych do 115 autorów z 14 jednostek organizacyjnych WMI. Średnia liczba publikacji na autora wynosi 29,9 (mediana 19).

Ze zbioru wykluczono publikacje pozbawione abstraktu po etapie uzupełniania (etap 3) oraz du-

Tabela 1: Porównanie modeli embeddingowych (top 5 z 9 testowanych, ArXiv $n = 2397$, $k = 118$).

Model	d	Purity
BGE-base-en-v1.5	768	70,55%
BGE-large-en-v1.5	1024	69,63%
Nomic-embed-v1.5	768	69,50%
SPECTER	768	68,88%
all-mpnet-base-v2	768	68,09%

plikaty zidentyfikowane na podstawie identyfikatora DOI. Autorów bez żadnej publikacji z abstraktem ($n = 49$) wykluczono z dalszych analiz, pozostawiając 115 autorów z co najmniej jedną reprezentowalną pracą.

Jako korpus referencyjny do dostrojenia modelu embeddingowego wykorzystano zbiór 18 880 artykułów pobranych z repozytorium ArXiv — po 200 z każdej ze 118 podkategorii. ArXiv stanowi dogodnie źródło danych referencyjnych dzięki hierarchicznej, trzypoziomowej taksonomii kategorii (grupa główna $\rightarrow$ archiwum $\rightarrow$ podkategoria), która dostarcza sygnału nadzoru do uczenia metrycznego. 63,8% artykułów w tym zbiorze posiada więcej niż jedną kategorię (średnio 2,06).

2.2 Embeddingi tekstowe

Dla każdej publikacji generowany jest embedding na podstawie konkatenacji tytułu i abstraktu: "{title}. {abstract}". Wektory mają wymiar $d = 768$ i są normalizowane L^2 , dzięki czemu odległość euklidesowa staje się monotoniczna względem podobieństwa kosinusowego:

$$\|e_i - e_j\|^2 = 2(1 - e_i \cdot e_j). \quad (1)$$

Wybór modelu embeddingowego stanowił decyzję badawczą opartą na porównaniu dziewięciu pretrenowanych modeli (Tab. 1) na podzbiorze 2397 artykułów ArXiv. Jako kryterium wyboru przyjęto main-category purity — odsetek par artykułów w tym samym klastrze K-means, które dzielą główną kategorię ArXiv. Najwyższą wartość (70,55% dla $k = 118$) uzyskał model BAAI/bge-base-en-v1.5, który wybrano jako model bazowy do dalszych badań.

3 Proponowane podejście

Proponowane podejście obejmuje dwa uzupełniające się obszary. Pierwszy dotyczy reprezentacji autorów w przestrzeni embeddingów — od diagnostyki stabilności centroidu, przez dostrojenie modelu, po schemat decyzyjny o trybie reprezentacji

(jednopunktowa vs. wieloklastrowa). Drugi dotyczy oceny jakości projekcji 2D — od wyboru metryk, po autorski wskaźnik Composite Score agregujący ich sygnały. Oba obszary łączy wspólna przestrzeń embeddingów: jakość wizualizacji 2D warunkuje interpretowalność map autorów.

3.1 Adaptacyjna reprezentacja autora

Centroid i problem wielomodalności. Naturalną reprezentacją profilu badawczego autora a jest centroid — uśredniony wektor embeddingów jego publikacji:

$$\hat{e}_a = \frac{\bar{e}_a}{\|\bar{e}_a\|}, \quad \bar{e}_a = \frac{1}{n_a} \sum_{p \in P_a} e_p, \quad (2)$$

gdzie P_a to zbiór publikacji autora, a normalizacja L^2 zapewnia porównywalność z embeddingami artykułów. Mean pooling działa jako filtr szumów (wygładza jednorazowe tematy), jest stałowymiary i łatwo aktualizowalny inkrementalnie.

Problem pojawia się dla autorów o zróżnicowanym profilu: centroid badacza łączącego np. robotykę z medycyną trafia w pustą przestrzeń „pomiędzy” tymi obszarami, nie reprezentując wiernie żadnego z nich.

Diagnostyka stabilności centroidu. Aby ocenić wiarygodność centroidu, zaproponowano trzy osie diagnostyczne:

(1) **Test bliskości współautorów.** Zweryfikowano hipotezę, że współautorzy mają istotnie bliższe centroidy niż pary losowe, za pomocą testu U Manna–Whitneya. Potwierdzenie tej hipotezy waliduje, że embeddingi wychwytyją rzeczywiste podobieństwo badawcze.

(2) **Zgodność sąsiedztw top- k .** Zmierzono miarę Jaccarda między zbiorami k najbliższych sąsiadów autora w różnych konfiguracjach (model $\times$ typ tekstu wejściowego). Wysoka zgodność oznacza, że profil jest semantycznie stabilny niezależnie od wyboru modelu.

(3) **Stabilność centroidu względem liczby prac.** Obliczono średnie podobieństwo kosinusowe między centroidem zbudowanym z losowego podzbioru k prac a centroidem pełnym, dla $k \in \{3, 5, 10, 20, 50, 100\}$.

Diagnostykę przeprowadzono na sześciu modelach embeddingowych (SPECTER, MiniLM-L6, MiniLM-L12, MPNet-Base, BGE-Small, Multilingual-MiniLM) i czterech wariantach tekstu wejściowego. Modele 768-wymiarowe sprowadzono do wspólnego wymiaru 384 przez

projekcję Johnsona–Lindenstraussa, umożliwiając bezpośrednie porównania.

Jako dodatkowy sygnał interdyscyplinarności wprowadzono *miarę rozproszenia* (dispersion) embeddingów prac autora — niezależną od liczby publikacji.

Dostrojenie modelu embeddingowego. Model BGE-base dostrojono z wykorzystaniem funkcji straty CoSENTLoss na korpusie 18 880 artykułów ArXiv. Kluczowym elementem jest hierarchiczna funkcja odległości oparta na trzypoziomowej taksonomii ArXiv:

$$h(c_i, c_j) = \begin{cases} 0,00 & \text{ta sama podkategoria,} \\ 0,33 & \text{to samo archiwum,} \\ 0,67 & \text{ta sama grupa główna,} \\ 1,00 & \text{różne grupy.} \end{cases} \quad (3)$$

Dla artykułów z wieloma kategoriami (63,8% zbioru) wynikowy score łączy indeks Jaccarda zbiorów kategorii z najlepszą odległością hierarchiczną:

$$s(p_i, p_j) = 0,5 \cdot J(C_i, C_j) + 0,5 \cdot \min_{c_i \in C_i, c_j \in C_j} h(c_i, c_j). \quad (4)$$

Dekompozycja wieloklastrowa. Dla autorów z co najmniej pięcioma publikacjami testowany jest K-means z $k \in \{2, \dots, 5\}$. Optymalną liczbę klastrów k^* wyznacza się jako maksymalizującą silhouette score [11], z progiem s_{min} — poniżej którego autor otrzymuje reprezentację jednopunktową. **Każdy klaster etykietowany jest automatycznie na podstawie trzech najczęstszych tematów i pięciu słów kluczowych z metadanych OpenAlex.**

Schemat

decyzyjny.

Zbiór cech diagnostycznych ($n_papers, stability@k, avg_jaccard, dispersion$) łączy z cechami strukturalnymi z dekompozycji wieloklastrowej w schemat decyzyjny przypisujący każdemu autorowi jeden z czterech trybów. Próg stabilności τ wyznaczono jako kwantyl P_{25} rozkładu $\overline{stab}(5)$ na korpusie ($\tau = 0,994$) — podejście data-driven zamiast arbitralnego progu, konieczne po dostrojeniu modelu CoSENT, które przesuwają rozkład stabilności ku jedynce.

- **SINGLE** — stabilny centroid ($stability@k \geq \tau$) i brak wyraźnej struktury klastrowej ($silhouette < s_{min}$);
- **MULTI** — stabilny centroid i istotna struktura klastrowa ($silhouette \geq s_{min}$);
- **LOW_CONF** — zbyt mało publikacji ($n < 5$) dla wiarygodnej oceny;

- **AMBIGUOUS** — niestabilny centroid bez wyraźnej struktury klastrowej.

Kluczowym aspektem jest to, że autor otrzymuje tryb MULTI tylko wtedy, gdy zarówno jego centroid jest stabilny (diagnoza nie jest artefaktem małej próby), jak i silhouette podziału jest istotny (wielomodalność jest realna, a nie szumowa).

3.2 Ocena jakości redukcji wymiarowości

Wizualizacja zbioru artykułów wymaga projekcji embeddingów z przestrzeni $\mathbb{R}^{768}$ do $\mathbb{R}^2$. Różne metody redukcji wymiarowości zachowują odmienne aspekty struktury danych — żadna nie odwzorowuje jednocześnie wiernie lokalnych sąsiedztw i globalnych proporcji odległości. Problem oceny jakości projekcji formalizujemy jako wielokryterialną ocenę odwzorowania $f: \mathbb{R}^{768} \rightarrow \mathbb{R}^2$ względem siedmiu komplementarnych metryk oceniających zachowanie struktury lokalnej i globalnej przestrzeni embeddingów.

Porównywane metody. Porównano osiem metod podzielonych na dwie grupy. *Metody lokalne* — t-SNE [1], UMAP [2], PaCMAP [3], Spectral Embedding — koncentrują się na zachowaniu bezpośrednich sąsiedztw punktów. *Metody globalne i liniowe* — PCA, Isomap [4], LDA, PCA 8D+log — zachowują relacje geometryczne na większą skalę kosztem precyzji lokalnej. LDA jest metodą nadzorowaną i pełni rolę górnego ograniczenia separowalności klastrów, a nie punktu odniesienia dla metod nienadzorowanych. PCA 8D+log to autorski pipeline: podobieństwo kosinusowe każdego artykułu do centroidów $k = 9$ klastrów, transformacja logarymiczna, redukcja PCA do 2D.

Metryki jakości projekcji. Zdefiniowano siedem metryk w dwóch grupach. *Metryki lokalne*: (1) *kNN Recall@100* — odsetek prawdziwych 100-sąsiadów z $\mathbb{R}^{768}$ zachowanych w projekcji 2D; (2) *Trustworthiness* — odsetek sąsiadów w 2D, którzy są rzeczywistymi sąsiadami w 768D (miara precision komplementarna do kNN Recall); (3) *Neighbourhood Hit* ($k = 10$) — odsetek k -sąsiadów w 2D należących do tego samego klastra K-Means. We wszystkich metrykach odległości w $\mathbb{R}^{768}$ mierzono kosinusowo, a w projekcji $\mathbb{R}^2$ — euklidesowo. *Metryki globalne* oceniają zachowanie proporcji odległości parami na całym zbiorze $\binom{3440}{2} \approx 5,9 \times 10^6$ par: (4) *korelacja rang Spearmana* (ρ) — monotoniczność globalnego porządku odległości; (5) *korelacja Pearsona* (r) — liniowość zachowania odległości; (6) *Kruskal Stress* (σ) — znormalizowany

błąd MDS odwzorowania odległości (niższy = lepszy); (7) *SPDE* — skalowana średnia różnica odległości parami.

Composite Score. Aby zagregować siedem metryk w jedną miarę jakości projekcji, zastosowano dyskretną całkę Choqueta z 2-addytywną miarą rozmytą:

$$CS_{\text{Ch}} = \sum_{i=1}^7 (m_{(i)} - m_{(i-1)}) g(A_{(i)}), \quad (5)$$

gdzie $m_{(i)}$ to i -ta co do wielkości znormalizowana metryka, $A_{(i)} = \{j : m_j \geq m_{(i)}\}$, a $g(\cdot)$ to 2-addytywna miara rozmyta uwzględniająca redundancje i synergie między parami metryk. W odróżnieniu od klasycznej średniej ważonej, całka Choqueta ogranicza efekt pełnej kompensacyjności: słaby wynik jednej istotnej metryki nie jest całkowicie zniwelowany przez wysokie wartości pozostałych. Wagi singletonowe dobrano tak, aby zachować równowagę między metrykami lokalnymi i globalnymi oraz odzwierciedlić ich komplementarną rolę w ocenie jakości projekcji; dobór zweryfikowano analizą wrażliwości Dirichleta (1000 konfiguracji wag), która potwierdziła stabilność rankingów top-3 w 87%–100% przypadków: $w_{\text{kNN}} = 0,17$, $w_{\text{Trust}} = 0,17$, $w_{\text{NH}} = 0,16$, $w_{\rho} = 0,15$, $w_r = 0,15$, $w_{\text{SPDE}} = 0,10$, $w_{\sigma} = 0,10$. Interakcje wyznaczono na podstawie empirycznych korelacji Pearsona między metrykami: redundancja (kNN, Trust) ($r = 0,953$, $I = -0,04$), redundancja (ρ , r) ($r = 0,667$, $I = -0,03$), synergia (kNN, NH) ($r = 0,716$, $I = +0,03$) oraz synergia (Trust, SPDE) ($r = 0,352$, $I = +0,04$).

4 Wyniki

4.1 Konfiguracja eksperymentów

Wszystkie eksperymenty przeprowadzono na zbiorze $N = 3440$ publikacji w przestrzeni $d = 768$ z miarą odległości kosinusowej. Dostrojenie modelu wykonano na GPU A100 (Google Colab): 1 epoka, learning rate 10^{-5} , batch size 64, warmup 10%. Pary treningowe generowano ze stratyfikowanym próbkowaniem: 3 pary z tej samej podkategorii, 2 z tego samego archiwum, 2 z tej samej grupy i 1 z różnych grup — na każdy artykuł. Implementację wykonano w Pythonie z wykorzystaniem bibliotek scikit-learn, umap-learn oraz pacmap; dla wszystkich metod z losową inicjalizacją przyjęto `random_state=42`, zapewniając pełną powtarzalność wyników.

Optymalną liczbę klastrow k dla wizualizacji publikacji wyznaczono metodą kompozytową łączącą sześć kryteriów: metodę łokcia, indeks sylwetkowy, statystykę luki [8], indeks Calińskiego–Harabasz, indeks Daviesa–Bouldina oraz stabilność bootstrapową (spójność Jaccarda klasteryzacji na losowych podzbiorach). Kryteriom o monotonicznych tendencjach (luka, Caliński–Harabasz, stabilność) przypisano niższe wagi w ważonym Composite Score: $CS(k) = 0,30 \widetilde{\text{Sil}} + 0,25 \widetilde{\text{Elbow}} + 0,20 (1 - \widetilde{\text{DB}}) + 0,15 \widetilde{\text{CH}} + 0,10 \widetilde{\text{Gap}}$. Najwyższy wynik uzyskało $k = 9$ (silhouette = 0,2823). Próg silhouette dla dekompozycji wieloklastrowej autorów ustalono na $s_{\min} = 0,15$.

4.2 Porównanie metod redukcji wymiarowości

Tabela 2 zestawia wyniki wszystkich ośmiu metod według siedmiu metryk jakości projekcji. Użyte wartości należy interpretować w kontekście twierdzenia Johnsona–Lindenstraussa [7]: zachowanie odległości przy tak drastycznej redukcji wymiarowości (z $\mathbb{R}^{768}$ do $\mathbb{R}^2$) wymaga przestrzeni o znacznie wyższym wymiarze niż 2. Niskie wartości kNN Recall rzędu 0,2–0,6 są zatem zgodne z ogólnymi ograniczeniami teoretycznymi redukcji wymiarowości do bardzo niskich przestrzeni i nie świadczą o słabości konkretnej metody.

Spośród metod nienadzorowanych najwyższy CS_{Ch} uzyskało t-SNE (0,803), osiągając najwyższe wartości wszystkich trzech metryk lokalnych: kNN Recall 0,611, Trustworthiness 0,972, Neighbourhood Hit 0,918. Odbywa się to kosztem korelacji globalnej ($\rho = 0,563$) — efekt dobrze udokumentowany w literaturze, wynikający z własności jądra Studenta zniekształcającego odległości między klastrami. PaCMAP ($CS_{\text{Ch}} = 0,796$) wykazuje najbardziej zrównoważony profil: metryki lokalne jedynie nieznacznie niższe od t-SNE przy wyraźnie wyższej korelacji globalnej ($\rho = 0,709$, $r = 0,714$) — najlepszej wśród metod nienadzorowanych. UMAP ($CS_{\text{Ch}} = 0,798$) oferuje kompromis między t-SNE a PaCMAP. Różnice między tą trójką są marginalne ($\Delta CS_{\text{Ch}} < 0,007$), a wybór spośród nich powinien uwzględniać kryteria praktyczne — czasy obliczeń wyniosły odpowiednio: t-SNE 9,6 s, PaCMAP 3,1 s, UMAP 30,1 s (zbiór $n = 3440$, $\mathbb{R}^{768}$).

Metody globalne plasują się na dalszych pozycjach rankingu. PCA osiąga najniższy Kruskal Stress (0,442) i najwyższe SPDE (0,832), co odpowiada jego właściwości minimalnego błędu re-

konstrukcji w sensie Frobeniusa dla projekcji liniowych. Isomap ($CS_{\text{Ch}} = 0,728$) uzyskuje wyższe metryki lokalne niż PCA (kNN = 0,319 vs 0,260) dzięki odległościom geodezyjnym. Spectral Embedding ($CS_{\text{Ch}} = 0,666$) kolapsuje do struktury liniowej wskutek dominacji pierwszego wektora własnego Laplacianu, co skutkuje ekstremalnym Kruskal Stress ($\sigma = 1,844$).

Całka Choqueta z wartościami Shapleya wskazuje na dominującą rolę metryk lokalnych w ocenie jakości wizualizacji embeddingów tekstowych: Neighbourhood Hit ($\phi = 0,175$), Trustworthiness ($\phi = 0,170$), kNN Recall ($\phi = 0,165$), przed Spearman ($\phi = 0,135$), Pearson ($\phi = 0,135$), SPDE ($\phi = 0,120$), Stress ($\phi = 0,100$). Zdolność dyskryminacyjna całki Choqueta jest wyraźnie lepsza niż przy klasycznej średniej ważonej — zakres wyników [0,637; 0,803] wobec efektu spłaszczenia przy agregacji Sugeno, gdzie pięć metod uzyskało identyczny wynik 0,730. Warto zaznaczyć, że ranking top-3 (t-SNE, UMAP, PaCMAP) jest identyczny dla Choqueta i dla prostej średniej arytmetycznej metryk — zastosowanie całki Choqueta wpływa zatem głównie na zdolność dyskryminacyjną między metodami, nie na zmianę porządku czołówki.

4.3 Stabilność rankingu

Aby zweryfikować, czy ranking top-3 nie jest artefaktem konkretnej inicjalizacji losowej, przeprowadzono eksperyment z 10 niezależnymi uruchomieniami każdej z trzech najlepszych metod (tab. 3). t-SNE uzyskało najwyższą średnią ($\bar{CS} = 0,7984$) i najmniejszą wariancję ($\sigma = 0,0013$), wynikającą ze stabilnej inicjalizacji PCA. UMAP wykazuje największą zmienność ($\sigma = 0,0061$) i może osiągać zarówno najwyższe (0,8017), jak i najniższe (0,7850) wyniki. Test Wilcozona wskazuje istotną statystycznie przewagę t-SNE nad UMAP i PaCMAP ($p = 0,037$), natomiast różnica UMAP–PaCMAP jest nieistotna ($p = 0,770$), co potwierdza ich jakościową równoważność. Analiza wrażliwości metodą próbkowania Dirichleta (1000 konfiguracji wag) wykazała, że trójka top-3 pozostaje stabilna w 87% przypadków przy ekstremalnym próbkowaniu ($\alpha = 1,0$) i w 100% przy próbkowaniu bliskim wagom bazowym ($\alpha = 5,0$).

4.4 Wpływ dostrojenia modelu

Tabela 4 zestawia wpływ dostrojenia modelu BGE-base na metryki jakości embeddingów. Na zbiorze ArXiv main-category purity wzrosła o 5,69 pp, a fuzzy purity o 6,46 pp. Kluczo-

Tabela 2: Porównanie ośmiu metod DR na zbiorze $N = 3440$ publikacji ($k = 9$ klastrów, metryka kosinusowa w $\mathbb{R}^{768}$). CS_{Ch} — Composite Score (całka Choqueta); kNN — kNN Recall@100; Trust — Trustworthiness; NH — Neighbourhood Hit ($k = 10$); ρ — Spearman ρ (surowy); r — Pearson (surowy); σ — Kruskal Stress (surowy; niższy = lepszy). Pogrubione: najlepsza wartość wśród metod nienadzorowanych.

Metoda	CS_{Ch}	kNN	Trust	NH	ρ	r	SPDE	σ
<i>Metody nienadzorowane</i>								
t-SNE	0,803	0,611	0,972	0,918	0,563	0,602	0,806	0,503
UMAP	0,798	0,585	0,958	0,908	0,666	0,654	0,774	0,595
PaCMAP	0,796	0,573	0,963	0,908	0,709	0,714	0,757	0,706
Isomap	0,728	0,319	0,868	0,747	0,716	0,720	0,803	0,538
PCA	0,715	0,260	0,855	0,711	0,685	0,692	0,832	0,442
Spectral	0,666	0,314	0,850	0,800	0,741	0,605	0,583	1,844
8D+log	0,637	0,197	0,816	0,498	0,770	0,741	0,706	0,948
<i>Metoda nadzorowana (punkt odniesienia dla separowalności klastrów)</i>								
LDA	0,736	0,216	0,879	0,878	0,773	0,759	0,784	0,582

Tabela 3: Stabilność rankingu top-3: CS_{Ch} dla 10 niezależnych inicjalizacji. Testy Wilcozona (parami): t-SNE–UMAP $p = 0,037^*$, t-SNE–PaCMAP $p = 0,037^*$, UMAP–PaCMAP $p = 0,770$ (ns).

Metoda	$\bar{CS}$	σ	Min	Max	Wins
t-SNE	0,7984	0,0013	0,7956	0,7999	5/10
PaCMAP	0,7942	0,0045	0,7877	0,8012	2/10
UMAP	0,7931	0,0061	0,7850	0,8017	3/10

Tabela 4: Wpływ dostrojenia BGE-base na metryki jakości.

Metryka	Oryg.	FT	Δ
Main-cat. purity ($k=118$)	68,07%	73,76%	+5,69
Fuzzy purity ($k=118$)	74,14%	80,59%	+6,46
Precision@10	0,654	0,690	+0,036
Precision@20	0,625	0,667	+0,043
Var. expl. PCA 2D (ArXiv)	12,19%	29,37%	+17,18
Var. expl. PCA 2D (autorzy)	33,11%	54,71%	+21,60

wym wynikiem jest wzrost wariancji wyjaśnionej w PCA 2D z 12,19% do 29,37% na ArXiv, a na profilach autorów WMI — z 33,11% do 54,71% ($\Delta = +21,6$ pp), co czyni wizualizację 2D profili autorów istotnie bardziej wiarygodną.

4.5 Dekompozycja wieloklastrowa autorów

Tabela 5 przedstawia wpływ progu *silhouette* na wynik dekompozycji. Przy wybranym progu $s_{min} = 0,15$ — 85,2% autorów wykazuje wieloklastrową strukturę (średnio 2,59 klastra), generując łącznie 298 punktów reprezentacyjnych. Wynik ten jest stabilny w zakresie progów $s_{min} \in [0,10; 0,20]$,

Tabela 5: Wpływ progu *silhouette* na dekompozycję wieloklastrową ($n = 115$ autorów, ≥ 5 publikacji).

Próg s_{min}	Autorzy $k > 1$	%	Śr. k
0,05	106	92,2	2,75
0,10	105	91,3	2,71
0,15	98	85,2	2,59
0,20	86	74,8	2,37
0,30	59	51,3	1,88

gdzie odsetek autorów wieloklastrowych waha się między 74,8% a 91,3% (tab. 5).

Stabilność centroidu osiąga $\sim 0,95$ dla $k = 5$ prac i $\sim 0,99$ dla $k = 10$, lecz rozkład jest heterogeniczny — sama liczba prac nie wystarcza do oceny wiarygodności, co uzasadnia wprowadzenie wielowymiarowego schematu diagnostycznego.

Schemat diagnostyczny przypisuje każdemu autorowi jedną z czterech etykiet na podstawie *silhouette*_{max} (sygnał struktury klastrowej, próg 0,15) oraz *stab*(5) (średnie podobieństwo kosinusowe centroidu z 5 pracami do centroidu pełnego, próg adaptacyjny $\tau = P_{25} = 0,994$ wyznaczony na rozkładzie korpusu): **SINGLE** — 7 autorów (6,1%, profil monotematyczny — niski *silhouette*, wysoka stabilność); **MULTI** — 98 autorów (85,2%, wyraźna struktura klastrowa, dekompozycja na $k > 1$ centroidów); **LOW_CONF** — 9 autorów (7,8%, $n < 5$ prac); **AMBIGUOUS** — 1 autor (0,9%, niska stabilność bez struktury klastrowej).

Tabela 6: Separacja 14 [jednostek](#) WMI ($n = 92$ autorów).

Metryka	Oryg.	FT	Δ
Intra-dept cosine sim	0,858	0,967	+0,109
Inter-dept cosine sim	0,756	0,911	+0,155
NMI	0,672	0,702	+0,030
NN@1 accuracy	0,728	0,663	-0,065
NN@5 accuracy	0,609	0,478	-0,130
Dept purity (K-means)	0,641	0,620	-0,022
Silhouette	0,064	0,060	-0,004

4.6 Separacja [jednostek](#) organizacyjnych

Jakość reprezentacji autorów oceniono na niezależnym zadaniu separacji 14 [jednostek](#) WMI (92 autorów z jednoznacznym przypisaniem). Tabela 6 zestawia wyniki dla modelu oryginalnego i dostrojonego.

Dostrojenie poprawia globalną strukturę (NMI +0,030) kosztem lokalnego sąsiedztwa (NN@1 -6,5 pp, NN@5 -13,0 pp). Efekt wynika z „ściśnięcia” wszystkich embeddingów bliżej siebie — zarówno intra- jak i inter-departmentowe podobieństwo rośnie, lecz proporcjonalnie bardziej rośnie inter (+0,155 vs. +0,109). Jest to akceptowalny kompromis dla wizualizacji eksploracyjnej, gdzie globalna struktura („które [jednostki](#) są bliskie tematycznie?”) jest ważniejsza niż dokładność lokalnych sąsiedztw.

Analiza per [jednostkę](#) ujawnia trzy pary o niemal identycznym profilu semantycznym (podobieństwo $> 0,99$): Z. Analizy Funkcjonalnej $\leftrightarrow$ Z. Analizy Matematycznej, Z. Geometrii Algebraicznej $\leftrightarrow$ Z. Geometrii Arytmetycznej oraz Z. Teorii Operatorów $\leftrightarrow$ Z. Przestrzeni Funkcyjnych. Są to ściśle powiązane specjalizacje matematyczne — wysoka bliskość jest poprawna merytorycznie.

4.7 Porównanie wariantów reprezentacji

Porównano trzy warianty reprezentacji autorów na wizualizacji:

1. **baseline** — wszyscy autorzy jako pojedynczy centroid;
2. **aggressive** — wszyscy z ≥ 5 pracami z dekompozycją multi-cluster;
3. **adaptive** — decyzja per autor na podstawie schematu SINGLE/MULTI/LOW_CONF/AMBIGUOUS.

Wyniki przeczą intuicyjnemu założeniu „więcej punktów = lepsza reprezentacja”. Wariant **ba-**

seline osiąga najwyższe NMI (0,702) i Purity (0,620) na zadaniu separacji jednostek — pojedynczy centroid kondensuje pełną informację o autorze i pozwala algorytmowi K-Means efektywniej rekonstruować strukturę organizacyjną. Wariant **aggressive** obniża NMI o 16 pp, ponieważ wymuszone dekompozycje autorów monotematycznych generują sztuczne sąsiedztwa międzyautorskie, rozmywając granice jednostek.

Wariant **adaptive** (242 punkty wobec 259 w aggressive — 17 punktów mniej dzięki klasyfikacji SINGLE/LOW_CONF/AMBIGUOUS) plasuje się pośrodku, lecz zachowuje ważną własność: *lepszą lokalną wierność niż aggressive* (NN@1 +0,9 pp), przy porównywalnej liczbie punktów. Pokazuje to, że selektywna decyzja o dekompozycji (oparta zarówno na strukturze klastrowej, jak i na stabilności profilu) ogranicza szum wprowadzany przez wymuszone podziały.

Kluczowa obserwacja jest jednak metodologiczna: *zadanie separacji jednostek nie jest właściwym kryterium oceny dla wieloklastrowej reprezentacji*. Multi-cluster z definicji rozszczepia profile autorów interdyscyplinarnych w różne regiony przestrzeni — co *powinno* obniżyć metryki klasyfikacji per-jednostka, ponieważ informatyk publikujący w biologii obliczeniowej jest reprezentowany zarówno blisko Z. Sztucznej Inteligencji, jak i Z. Biologii. Cel multi-cluster to ujawnienie tej interdyscyplinarności, a nie wzmocnienie podziału na jednostki. Tabela 7 stanowi zatem *cenę* jaką płacimy za dodatkową interpretowalność, a nie miarę jakości w jej własnym celu — **co wskazuje na fundamentalny konflikt między celem wizualizacji eksploracyjnej a klasycznymi metrykami klasyfikacyjnymi**. Formalnie, **zadanie separacji jednostek maksymalizuje spójność klastrową względem etykiety instytucjonalnej, podczas gdy reprezentacja wieloklastrowa optymalizuje odwzorowanie wielomodalnej struktury semantycznej — cele te są nieredukowalnie sprzeczne**.

4.8 Analiza przypadków

Wieloklastrowa dekompozycja ujawnia semantycznie spójne podziały. Przykładowo, jeden z autorów Z. Sztucznej Inteligencji został rozłożony na cztery klastry: *decision making*, *robotics*, *fuzzy optimization* oraz *ovarian cancer classification* — co odpowiada rzeczywistym, odrębnym nurtom jego badań.

Na mapie autorów (PCA 2D, model dostrojonny) klastry takiego autora rozkładają się w odległych

Tabela 7: Porównanie trzech wariantów reprezentacji autorów na zadaniu separacji 14 jednostek WMI ($n = 92$ autorów z jednoznacznym przypisaniem). NN@ k liczone z wykluczeniem punktów tego samego autora.

Wariant	Punkty	NMI	NN@1	NN@5	Purity	Sil.
baseline	92	0,702	0,663	0,478	0,620	0,060
aggressive	259	0,541	0,591	0,548	0,583	−0,001
adaptive	242	0,504	0,599	0,541	0,566	−0,027

regionach przestrzeni, połączone cienkimi liniami wskazującymi przynależność do tej samej osoby. W wariancie baseline ten sam autor byłby umieszczony jako pojedynczy punkt w centrum — nie dając informacji o żadnym z czterech kierunków.

5 Podsumowanie

W niniejszej pracy zaproponowano i zbadano dwa powiązane podejścia do semantycznej eksploracji dorobku naukowego: adaptacyjną reprezentację autorów w przestrzeni embeddingów oraz wielokryterialną ocenę jakości redukcji wymiarowości.

Na poziomie publikacji systematyczne porównanie ośmiu metod redukcji wymiarowości z siedmioma metrykami jakości i autorskim wskaźnikiem Composite Score (całka Choqueta) wykazało, że metody nieliniowe (t-SNE, UMAP, PaCMAP) osiągają zbliżoną jakość ($CS_{Ch} \in [0,796; 0,803]$), uzyskując wyraźnie wyższe wartości Composite Score niż metody liniowe ($CS_{Ch} \in [0,637; 0,728]$).

Na poziomie autorów kluczowym wynikiem jest odejście od sztywnej reguły „jeden autor = jeden punkt” na rzecz reprezentacji adaptacyjnej. Dostrojenie modelu BGE-base funkcją CoSENTLoss z hierarchiczną odległością kategorii ArXiv poprawiło wariancję wyjaśnioną w PCA 2D z 33,11% do 54,71% na profilach autorów. 85,2% autorów z ≥ 5 publikacjami wykazuje wieloklastrową strukturę profilu (średnio $k = 2,59$), co potwierdza, że pojedynczy centroid jest niewystarczającą reprezentacją dla większości badaczy.

Schemat decyzyjny SINGLE/MULTI/LOW_CONF/AMBIGUOUS, łączący diagnostykę stabilności centroidu z dekompozycją wieloklastrową, stanowi główny wkład metodologiczny niniejszej pracy, możliwy do zastosowania w innych kontekstach profilowania naukowców.

Wyniki wskazują, że wybór metody redukcji wymiarowości powinien być uzależniony od celu analizy: metody lokalne (t-SNE, UMAP, PaCMAP) są właściwe dla eksploracji semantycznych sąsiedztw, natomiast metody globalne (PCA, Isomap) — gdy

priorytetem jest zachowanie proporcji odległości między klastrami. Wyboru nie należy traktować jako uniwersalnego problemu optymalizacji.

Ograniczenia. Ewaluacja przeprowadzona została na zbiorze 115 autorów z jednej jednostki akademickiej. Brakuje ewaluacji eksperckiej (oceny przez samych badaczy, czy przypisane klastry odpowiadają ich subiektywnym nurtom badawczym). Próg silhouette $s_{min} = 0,15$ wybrany jest heurystycznie.

Kierunki dalszych badań. Ewaluacja użytkownikowa, fine-tuning bezpośrednio na danych docelowej jednostki, temporal embeddings (ewolucja profilu w czasie), graf cytowań jako dodatkowy sygnał, walidacja na danych innych jednostek akademickich.

Literatura

- [1] L. van der Maaten, G. Hinton, *Visualizing Data using t-SNE*, Journal of Machine Learning Research, 9:2579–2605, 2008.
- [2] L. McInnes, J. Healy, J. Melville, *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*, arXiv:1802.03426, 2018.
- [3] Y. Wang, H. Huang, C. Rudin, Y. Shaposhnik, *Understanding How Dimension Reduction Tools Work: An Empirical Approach to Deciphering t-SNE, UMAP, TriMAP, and PaCMAP for Data Visualization*, Journal of Machine Learning Research, 22(201):1–73, 2021.
- [4] J. B. Tenenbaum, V. de Silva, J. C. Langford, *A Global Geometric Framework for Nonlinear Dimensionality Reduction*, Science, 290(5500):2319–2323, 2000.
- [5] S. Xiao, Z. Liu, P. Zhang, N. Muennighoff, *C-Pack: Packaged Resources To Advance General Chinese Embedding*, arXiv:2309.07597, 2024.
- [6] J. Su, *CoSENT: A more efficient sentence vector scheme than Sentence-BERT*, Blog post, 2022.
- [7] W. B. Johnson, J. Lindenstrauss, *Extensions of Lipschitz mappings into a Hilbert space*, Contemporary Mathematics, 26:189–206, 1984.

- [8] R. Tibshirani, G. Walther, T. Hastie, *Estimating the number of clusters in a data set via the gap statistic*, Journal of the Royal Statistical Society B, 63(2):411–423, 2001.
- [9] J. Priem, H. Piwowar, R. Orr, *OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts*, arXiv:2205.01833, 2022.
- [10] A. Cohan, S. Feldman, I. Beltagy, D. Downey, D. S. Weld, *SPECTER: Document-level Representation Learning using Citation-informed Transformers*, ACL, 2020.
- [11] P. J. Rousseeuw, *Silhouettes: a Graphical Aid to the Interpretation and Validation of Cluster Analysis*, Computational and Applied Mathematics, 20:53–65, 1987.