

Plan pracy magisterskiej

Semantyczna eksploracja artykułów naukowych:
metody redukcji wymiarowości i ocena jakości projekcji

Daria Dworzyńska-Wujec

Michał Wujec

Rozdział 1 — Wprowadzenie i pozyskiwanie danych (wspólny)

Rozdział stanowi punkt wyjścia całej pracy i wprowadza czytelnika w problematykę semantycznej eksploracji zbiorów artykułów naukowych. Omówiona zostaje motywacja praktyczna: dynamiczny wzrost liczby publikacji sprawia, że ręczna analiza korpusów jest niemożliwa. Opisane jest źródło i charakterystyka zbioru danych — $N = 3440$ artykułów naukowych reprezentowanych wektorami w przestrzeni R^{768} — wraz z informacjami o procedurze ich pobrania i ewentualnym filtrowaniu. Następnie przedstawiony jest proces generowania embeddingów tekstowych: wybór modelu (np. `all-mpnet-base-v2`), sposób łączenia tytułu z abstraktem oraz normalizacja L^2 , dzięki której odległość euklidesowa staje się monotoniczna względem podobieństwa kosinusowego. Już tutaj sygnalizowane jest kluczowe ograniczenie teoretyczne: lemat Johnsona–Lindenstraussa gwarantuje, że wierna redukcja $N = 3440$ punktów wymaga co najmniej ~ 1200 wymiarów, więc projekcja do 2D jest z definicji stratna — co motywuje potrzebę starannej oceny jakości za pomocą metryk opisanych w rozdziałach 2 i 3. Na końcu rozdziału zawarty jest formalny podział zadań między autorów, uzasadniający odrębną strukturę rozdziałów 2 i 3.

Rozdział 2 — Lokalne metody redukcji wymiarowości i metryki lokalne (Daria)

Rozdział obejmuje cztery metody koncentrujące się na zachowaniu *lokalnej struktury danych*: t-SNE, UMAP, PaCMAP oraz Spectral Embedding. Dla każdej metody przedstawiona jest intuicja działania, formalizm matematyczny (funkcja kosztu / cel optymalizacji) oraz omówienie typowych zniekształceń i ograniczeń (np. efekt wyrównywania klastrów w t-SNE, wrażliwość na hiperparametry). Następnie opisane są metryki jakości adekwatne dla wierności lokalnej: k NN Recall, Trustworthiness oraz Neighbourhood Hit. Dla każdej metryki podana jest definicja formalna, zakres wartości oraz przykład liczbowy ułatwiający interpretację. Rozdział kończy się osobną podsekcją poświęconą **Composite Score** — wspólnej propozycji obu autorów łączącej metryki lokalne (rozdziały 2) i globalne (rozdział 3) w jedną miarę jakości projekcji. Opisane jest empiryczne uzasadnienie wag (analiza korelacji między metrykami, minimalizacja redundancji), walidacja metryki przez porównanie rankingu metod z niezależną oceną użytkownikową oraz analiza wrażliwości na zmiany wag.

Rozdział 3 — Globalne i liniowe metody redukcji wymiarowości oraz metryki globalne (Michał)

Rozdział obejmuje cztery metody zachowujące *globalną i liniową strukturę danych*: PCA, Isomap, LDA oraz pipeline PCA 8D+log. Dla każdej metody omówiona jest idea (np. maksymalizacja wariancji w PCA, odległości geodezyjne w Isomap, separacja klas w LDA), formuła matematyczna oraz interpretacja wyników. Następnie opisane są cztery metryki globalne: korelacja rang Spearmana (ρ), korelacja Pearsona (r), Kruskal Stress (σ) oraz SPDE. Dla każdej metryki podana jest definicja, intuicja (co dokładnie mierzy w kontekście projekcji 768D $\rightarrow$ 2D) oraz interpretacja skrajnych wartości. Rozdział kończy się analogiczną do rozdziału 2 tabelą porównawczą.

Rozdział 4 — Wyniki i analiza (wspólny)

Rozdział otwiera sekcja konfiguracji eksperymentów opisująca wspólne ustawienia zapewniające powtarzalność wyników: rozmiar zbioru ($N = 3440$), wymiar embeddingów (768), normalizację L^2 oraz miarę odległości kosinusowej ($d = 1 - e_i \cdot e_j$). Omówiona jest procedura klasteryzacji K-Means: wybór $k = 9$ klastrów na podstawie analizy silhouette (max = 0,2823) oraz szczegóły obliczania metryk (próbkiowanie $n = 1500$, $k = 15$ sąsiadów dla metryk lokalnych, $k = 100$ dla kNN Recall w tabeli porównawczej). Kolejna sekcja wyjaśnia teoretycznie, dlaczego uzyskane wartości metryk są matematycznie oczekiwane: lemat Johnsona–Lindenstraussa wskazuje na potrzebę co najmniej $d_{\min} \approx 1200$ wymiarów dla $n = 3440$ punktów, a redukcja do 2D daje przestrzeń $600\times$ mniejszą niż to minimum. Omawiane są także typowe zniekształcenia: efekt ciężkich ogonów t-SNE, rozumowanie kołowe LDA i zbieżność t-SNE z UMAP przy inicjalizacji PCA. Następnie przedstawiane są wyniki empiryczne: tabela zbiorcza ośmiu metod i siedmiu metryk + Composite, omówienie każdej metody z osobna oraz wizualizacje projekcji 2D z kolorowanymi klastrami. Rozdział kończy tabela przewodnika doboru metody dla różnych zastosowań (widok interaktywny, eksploracja lokalna, relacje między klastrami, baseline).

Rozdział 5 — Podsumowanie i wnioski końcowe (wspólny)

Rozdział syntetyzuje wyniki obu głównych rozdziałów tematycznych i odpowiada na centralne pytanie badawcze: *czy artykuły bliskie w wizualizacji 2D są rzeczywiście semantycznie podobne w przestrzeni 768D?* Zebrane są wnioski szczegółowe dotyczące poszczególnych metod i metryk optymalnej liczby klastrów. Wskazane są kierunki dalszych badań: wpływ wyboru modelu embeddingów, ewaluacja użytkownikowa oraz rozszerzenie korpusu danych. + widzimy tutaj ewentualne odwołanie się do całkosztu pracy jako 4 osób (jakie te badania miały "szersze" zastosowanie)

Plan ma charakter roboczy i może ulec zmianie w trakcie pisania pracy. Rozdziały 2 i 3 są rozłączne autorsko; rozdziały 1, 4 i 5 są wspólne. Composite Score (podsekcja w rozdziale 2) jest wspólną propozycją metodologiczną obu autorów.