Dimensionality Reduction and Quality Metrics for Scientific Paper Embeddings

From 768D Embeddings to 2D Interactive Visualisation

WMiI UAM — Wydział Matematyki i Informatyki
Uniwersytet im. Adama Mickiewicza w Poznaniu

March 19, 2026

Contents

1 Dimensionality Reduction Methods **2**
1.0.1 Principal Component Analysis (PCA) . . . 2
1.0.2 t-SNE . . . 3
1.0.3 UMAP . . . 3
1.0.4 PaCMAP . . . 4
1.0.5 Isomap . . . 5
1.0.6 Linear Discriminant Analysis (LDA) . . . 5
1.0.7 PCA 8D + log . . . 6

2 Quality Metrics **7**
2.0.1 k-Nearest Neighbour Recall (kNN Recall) . . . 8
2.0.2 Trustworthiness . . . 9
2.0.3 Neighbourhood Hit . . . 9
2.0.4 Spearman Rank Correlation . . . 10
2.0.5 Pearson Correlation . . . 11
2.0.6 Kruskal Stress . . . 11
2.0.7 SPDE . . . 12
2.1 Podsumowanie metryk . . . 12
2.2 Composite Score . . . 13

3 Experimental Setup **13**

4 Dlaczego wyniki wydają się „niskie”? **15**
4.1 Ograniczenie Johnsona–Lindenstraussa . . . 15
4.2 Wymiarowość wewnętrzna . . . 15
4.3 Oczekiwane zakresy metryk . . . 15

5 Zniekształcenia odległości: jak t-SNE i LDA wprowadzają w błąd **16**
5.1 Rozkład o ciężkich ogonach w t-SNE . . . 16
5.2 Rozumowanie kołowe w LDA . . . 16
5.3 UMAP nie jest bardziej „obiektywny” . . . 16

6 Wyniki **17**
6.1 Porównanie metryk . . . 17
6.2 Znaczenie wyboru metryki . . . 17
6.3 Porównanie wizualizacji . . . 18
6.3.1 Najlepsze metody nieliniowe . . . 19
6.3.2 Metody liniowe i pośrednie . . . 22

7 Dobór metody **24**

8 Wnioski **24**

1 Dimensionality Reduction Methods

Wizualizacja danych wysokowymiarowych wymaga zastosowania metod redukcji wymiarowości, które przekształcają reprezentację danych z przestrzeni o dużej liczbie wymiarów do przestrzeni o znacznie mniejszym wymiarze.

W analizowanym przypadku każdy artykuł naukowy reprezentowany jest jako wektor embeddingu w przestrzeni $\mathbb{R}^{768}$. Celem jest skonstruowanie wizualizacji w przestrzeni dwuwymiarowej, która umożliwi intuicyjną eksplorację zbioru publikacji.

Tak silna redukcja wymiarowości nieuchronnie prowadzi do utraty części informacji o relacjach geometrycznych między punktami. Różne metody redukcji wymiarowości podejmują jednak odmienne strategie zachowania struktury danych. Niektóre z nich koncentrują się przede wszystkim na zachowaniu lokalnego sąsiedztwa punktów, podczas gdy inne starają się zachować globalne relacje odległości między wszystkimi punktami w przestrzeni.

Z tego powodu w niniejszej pracy przeanalizowano kilka różnych metod redukcji wymiarowości, obejmujących zarówno podejścia liniowe, jak i metody nieliniowe.

Analizowane metody obejmują:

- PCA (Principal Component Analysis),
- t-SNE (t-distributed Stochastic Neighbor Embedding),
- UMAP (Uniform Manifold Approximation and Projection),
- PaCMAP (Pairwise Controlled Manifold Approximation),
- Isomap,
- Spectral Embedding,
- LDA (Linear Discriminant Analysis),
- PCA 8D+log (pipeline oparty na podobieństwie do centroidów klastrów).

Każda z tych metod opiera się na innym modelu matematycznym i zachowuje inne aspekty struktury danych. Dlatego ich jakość oceniana jest przy użyciu zestawu metryk opisanych w poprzedniej sekcji.

W kolejnych podrozdziałach przedstawiono krótką charakterystykę każdej z analizowanych metod oraz intuicję działania z punktu widzenia wizualizacji danych.

1.0.1 Principal Component Analysis (PCA)

Principal Component Analysis (PCA) jest liniową metodą redukcji wymiarowości polegającą na znalezieniu takich kierunków w przestrzeni danych, które maksymalizują wariancję danych [11].

Idea metody. Celem PCA jest znalezienie nowej bazy przestrzeni, w której pierwsze kilka osi opisuje największą część zmienności danych.

Formulacja matematyczna. Niech

$$X = \{x_1, x_2, \ldots, x_n\} \subset \mathbb{R}^d$$

oznacza zbiór punktów danych. Macierz kowariancji danych definiowana jest jako

$$\Sigma = \frac{1}{n} X^T X$$

PCA polega na znalezieniu wektorów własnych macierzy Σ. Pierwsze k wektorów własnych odpowiadających największym wartościom własnym definiuje przestrzeń projekcji.

Redukcja wymiarowości wykonywana jest poprzez rzutowanie danych:

$$y_i = W^T x_i$$

gdzie W zawiera pierwsze k wektorów własnych.

Interpretacja. PCA minimalizuje średni błąd rekonstrukcji danych po projekcji do przestrzeni o niższym wymiarze. Metoda dobrze zachowuje globalną strukturę danych, ale nie jest w stanie odwzorować nieliniowych zależności między punktami.

1.0.2 t-SNE

t-SNE (t-distributed Stochastic Neighbor Embedding) jest metodą redukcji wymiarowości, która koncentruje się na zachowaniu lokalnej struktury danych [3].

Idea metody. Metoda przekształca odległości między punktami w przestrzeni wysokowymiarowej na rozkłady prawdopodobieństwa opisujące podobieństwo punktów.

Formulacja matematyczna. Podobieństwo punktów w przestrzeni wysokowymiarowej definiowane jest jako

$$p_{ij} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq l} \exp(-\|x_k - x_l\|^2 / 2\sigma_k^2)}$$

W przestrzeni niskowymiarowej podobieństwo definiowane jest przy użyciu rozkładu t-Studenta:

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}}$$

Pozycje punktów w wizualizacji są wyznaczane poprzez minimalizację dywergencji Kullbacka-Leiblera:

$$KL(P||Q) = \sum_{i,j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

Interpretacja. Minimalizacja tej funkcji powoduje, że punkty o dużym podobieństwie w przestrzeni oryginalnej pozostają blisko siebie w wizualizacji. Jednocześnie metoda może silnie zniekształcać globalne relacje między klastrami.

1.0.3 UMAP

UMAP (Uniform Manifold Approximation and Projection) jest metodą redukcji wymiarowości opartą na teorii rozmaitości i grafów [4].

Idea metody. Algorytm zakłada, że dane leżą na niskowymiarowej rozmaitości zanurzonej w przestrzeni wysokowymiarowej.

Celem metody jest skonstruowanie grafu sąsiedztwa opisującego lokalną strukturę danych oraz znalezienie jego reprezentacji w przestrzeni o niższym wymiarze.

Formulacja matematyczna. Najpierw konstruowany jest graf k najbliższych sąsiadów. Każdej krawędzi przypisywana jest waga:

$$w_{ij} = \exp\left(-\frac{d(x_i, x_j) - \rho_i}{\sigma_i}\right)$$

gdzie $d(x_i, x_j)$ oznacza odległość między punktami.

Następnie algorytm minimalizuje funkcję celu opartą na krzyżowej entropii między grafem w przestrzeni wysokowymiarowej i grafem w przestrzeni niskowymiarowej.

Interpretacja. UMAP zachowuje lokalną strukturę danych, a jednocześnie często lepiej odwzorowuje globalną strukturę przestrzeni niż t-SNE.

1.0.4 PaCMAP

PaCMAP (Pairwise Controlled Manifold Approximation) jest metodą redukcji wymiarowości zaprojektowaną w celu jednoczesnego zachowania lokalnej oraz globalnej struktury danych [5].

Idea metody. Algorytm wykorzystuje trzy typy relacji między punktami:

- pary sąsiadów (neighbor pairs),
- pary średnio odległe (mid-near pairs),
- pary odległe (further pairs).

Każdy typ par odpowiada za inny aspekt struktury danych. Podczas optymalizacji ich znaczenie zmienia się w kolejnych fazach algorytmu, co pozwala zachować zarówno lokalne sąsiedztwo, jak i globalne rozmieszczenie punktów.

Formulacja matematyczna. Celem algorytmu jest minimalizacja funkcji kosztu:

$$L = \sum_{(i,j)\in N} w_{ij}\|y_i - y_j\|^2 + \sum_{(i,j)\in M} w_{ij}\|y_i - y_j\|^2 + \sum_{(i,j)\in F} w_{ij}\frac{1}{1 + \|y_i - y_j\|^2}$$

Oznaczenia.

- N – zbiór par sąsiednich,
- M – zbiór par średnio odległych,
- F – zbiór par odległych,
- y_i – współrzędne punktu w przestrzeni 2D.

Interpretacja. Pierwsze dwa składniki funkcji kosztu zbliżają do siebie punkty będące sąsiadami, natomiast trzeci składnik odpycha od siebie punkty odległe. Pozwala to zachować strukturę danych zarówno w skali lokalnej, jak i globalnej.

1.0.5 Isomap

Isomap jest metodą redukcji wymiarowości, która zachowuje geodezyjne odległości między punktami na rozmaitości danych [11].

Idea metody. Algorytm zakłada, że dane leżą na nieliniowej rozmaitości zanurzonej w przestrzeni wysokowymiarowej. Zamiast bezpośrednich odległości euklidesowych wykorzystywane są odległości geodezyjne mierzone wzdłuż powierzchni tej rozmaitości.

Formulacja matematyczna. Algorytm składa się z trzech etapów:

1. konstrukcja grafu k najbliższych sąsiadów,
2. wyznaczenie najkrótszych ścieżek między wszystkimi parami punktów (np. algorytmem Dijkstry),
3. zastosowanie wielowymiarowego skalowania (MDS), które minimalizuje funkcję:

$$\sum_{i<j} (d_{ij}^{geo} - \|y_i - y_j\|)^2$$

Oznaczenia.

- d_{ij}^{geo} – odległość geodezyjna między punktami,
- y_i – współrzędne punktu w przestrzeni 2D.

Interpretacja. Isomap dobrze zachowuje globalną strukturę danych, ponieważ wykorzystuje odległości mierzone wzdłuż rozmaitości danych.

1.0.6 Linear Discriminant Analysis (LDA)

Linear Discriminant Analysis jest metodą redukcji wymiarowości nadzorowanej, która wykorzystuje informacje o klasach danych.

Idea metody. Celem metody jest znalezienie takiej projekcji danych, która maksymalizuje separację między klasami, a jednocześnie minimalizuje wariancję wewnątrz klas.

Formulacja matematyczna. Definiowane są dwie macierze rozrzutu:

$$S_W = \sum_c \sum_{x_i \in c} (x_i - \mu_c)(x_i - \mu_c)^T$$

$$S_B = \sum_c n_c (\mu_c - \mu)(\mu_c - \mu)^T$$

gdzie:

- S_W – rozrzut wewnątrz klas,
- S_B – rozrzut między klasami.

Celem jest maksymalizacja ilorazu:

$$\frac{|W^T S_B W|}{|W^T S_W W|}$$

Interpretacja. LDA znajduje takie kierunki projekcji, które najlepiej rozdzielają klasy danych. W tej pracy klasy odpowiadają klastrom wyznaczonym metodą K-Means.

1.0.7 PCA 8D + log

Oprócz klasycznych metod redukcji wymiarowości zastosowano również pipeline oparty na podobieństwie dokumentów do centroidów klastrów.

Idea metody. Każdy dokument reprezentowany jest przez podobieństwa kosinusowe do centroidów klastrów wyznaczonych metodą K-Means.

Powstały wektor podobieństw jest następnie transformowany funkcją logarytmiczną oraz redukowany metodą PCA.

Formulacja matematyczna. Podobieństwo kosinusowe definiowane jest jako

$$\cos(x_i, c_j) = \frac{x_i \cdot c_j}{\|x_i\|\|c_j\|}$$

gdzie c_j oznacza centroid klastra.

Wektor podobieństw poddawany jest transformacji:

$$z = \log(1 + s)$$

a następnie redukcji wymiarowości metodą PCA.

Interpretacja. Taka reprezentacja opisuje dokumenty w przestrzeni podobieństwa do tematów klastrów, co ułatwia interpretację osi wizualizacji.

Table 1: Porównanie metod redukcji wymiarowości zastosowanych w analizie

Method	**Mathematical idea**	**Optimization objective**
PCA	Eigenvectors of covariance matrix	Maximize variance of projected data
t-SNE	Probability distributions of pairwise similarities	Minimize KL divergence between distributions
UMAP	Graph representation of data manifold	Minimize cross-entropy between graphs
PaCMAP	Pairwise distance constraints	Balance attraction and repulsion between pairs
Isomap	Geodesic distances on data manifold	Preserve shortest-path distances
Spectral Embedding	Eigenvectors of graph Laplacian	Preserve graph connectivity structure
LDA	Between-class vs within-class scatter	Maximize class separability
PCA 8D + log	Similarity to cluster centroids	Dimensionality reduction of similarity space

Chapter Summary

W niniejszym rozdziale przedstawiono metody redukcji wymiarowości zastosowane w analizie embeddingów artykułów naukowych. Celem tych metod jest przekształcenie reprezentacji danych z przestrzeni wysokowymiarowej $\mathbb{R}^{768}$ do przestrzeni dwuwymiarowej, umożliwiającej wizualną eksplorację zbioru publikacji.

Zaprezentowane algorytmy obejmują zarówno metody liniowe, takie jak PCA, jak i bardziej złożone metody nieliniowe, w tym t-SNE, UMAP, PaCMAP, Isomap oraz Spectral Embedding. Uwzględniono również podejścia wykorzystujące informacje o strukturze klastrowej danych, takie jak LDA oraz pipeline oparty na podobieństwie dokumentów do centroidów klastrów.

Poszczególne metody opierają się na różnych modelach matematycznych i optymalizują odmienne funkcje celu, co prowadzi do różnych kompromisów między zachowaniem lokalnej struktury sąsiedztwa a odwzorowaniem globalnej geometrii przestrzeni danych. W szczególności metody takie jak t-SNE czy UMAP koncentrują się przede wszystkim na zachowaniu lokalnych relacji

między punktami, natomiast metody liniowe, takie jak PCA, lepiej zachowują globalne relacje odległości.

Z tego względu ocena jakości wizualizacji nie może opierać się wyłącznie na pojedynczej metodzie redukcji wymiarowości. W kolejnej części pracy przedstawione zostaną wyniki eksperymentów oraz porównanie opisanych metod z wykorzystaniem zestawu metryk jakości wprowadzonych w poprzednim rozdziale.

2 Quality Metrics

Redukcja wymiarowości jest procesem nieuchronnie prowadzącym do utraty części informacji zawartej w danych. W przypadku analizowanych w tej pracy embeddingów artykułów naukowych każdy dokument reprezentowany jest jako wektor w przestrzeni $\mathbb{R}^{768}$, natomiast wizualizacja powstaje w przestrzeni dwuwymiarowej. Tak silna redukcja wymiarowości powoduje, że niemożliwe jest jednoczesne zachowanie wszystkich relacji geometrycznych między punktami.

W konsekwencji konieczne jest zastosowanie odpowiednich metryk, które pozwolą ocenić, w jakim stopniu struktura danych została zachowana po projekcji do przestrzeni o niższym wymiarze. Metryki te umożliwiają ilościową ocenę jakości wizualizacji oraz porównanie różnych metod redukcji wymiarowości.

W kontekście interaktywnej mapy artykułów naukowych szczególnie istotne jest zachowanie lokalnej struktury danych. Użytkownik eksplorujący wizualizację oczekuje, że artykuły znajdujące się blisko siebie na mapie będą również semantycznie podobne w przestrzeni embeddingów.

Z tego powodu centralnym pytaniem badawczym analizowanej części pracy jest:

> Czy artykuły, które znajdują się blisko siebie w wizualizacji 2D, są rzeczywiście semantycznie podobne w przestrzeni embeddingów 768D?

Aby odpowiedzieć na to pytanie zastosowano zestaw metryk oceniających różne aspekty jakości projekcji. Metryki te można podzielić na dwie główne grupy.

Pierwszą grupę stanowią **metryki lokalne**, które mierzą stopień zachowania najbliższego sąsiedztwa punktów. Odpowiadają one na pytanie, czy rzeczywiści najbliżsi sąsiedzi w przestrzeni wysokowymiarowej pozostają blisko siebie również w wizualizacji.

Drugą grupę stanowią **metryki globalne**, które oceniają zachowanie ogólnej struktury geometrycznej danych, w szczególności relacji odległości między wszystkimi parami punktów.

W niniejszej pracy zastosowano następujące metryki:

- kNN Recall – mierzącą zachowanie rzeczywistych najbliższych sąsiadów,
- Trustworthiness – oceniającą liczbę fałszywych sąsiedztw powstałych w wizualizacji,
- Neighbourhood Hit – mierzącą zgodność wizualnych sąsiedztw z klastrami danych,
- Spearman ρ – oceniającą zachowanie globalnego porządku odległości,
- Pearson r – mierzącą liniową zależność odległości w obu przestrzeniach,
- Kruskal Stress – określającą globalny błąd odwzorowania,
- SPDE – mierzącą średnie zniekształcenie odległości.

Każda z tych metryk opisuje inny aspekt jakości projekcji. Dopiero ich łączne zastosowanie pozwala uzyskać pełniejszy obraz tego, w jakim stopniu wizualizacja zachowuje strukturę oryginalnej przestrzeni embeddingów.

2.0.1 k-Nearest Neighbour Recall (kNN Recall)

Jednym z najczęściej stosowanych sposobów oceny jakości redukcji wymiarowości jest sprawdzenie, czy najbliższe sąsiedztwo punktów zostało zachowane po projekcji do przestrzeni o niższym wymiarze. Metryka kNN Recall mierzy, jaka część rzeczywistych najbliższych sąsiadów została zachowana w przestrzeni wizualizacji [5].

Definicja. Niech

$$X = \{x_1, x_2, \ldots, x_n\} \subset \mathbb{R}^{768}$$

oznacza zbiór punktów w przestrzeni oryginalnej, a

$$Y = \{y_1, y_2, \ldots, y_n\} \subset \mathbb{R}^2$$

odpowiadającą projekcję w przestrzeni dwuwymiarowej.
Metryka kNN Recall definiowana jest jako

$$\text{kNN Recall@}k = \frac{1}{n} \sum_{i=1}^{n} \frac{\left|\mathcal{N}_k^{HD}(i) \cap \mathcal{N}_k^{2D}(i)\right|}{k}. \tag{1}$$

Oznaczenia.

- n – liczba analizowanych punktów,
- k – liczba najbliższych sąsiadów,
- $\mathcal{N}_k^{HD}(i)$ – zbiór k najbliższych sąsiadów punktu i w przestrzeni oryginalnej (768D),
- $\mathcal{N}_k^{2D}(i)$ – zbiór k najbliższych sąsiadów punktu i w przestrzeni wizualizacji (2D),
- $|\cdot|$ – liczność zbioru.

Interpretacja. Metryka mierzy, jaki odsetek rzeczywistych najbliższych sąsiadów został zachowany po redukcji wymiarowości.

- wartość 1 oznacza idealne zachowanie sąsiedztwa,
- wartość 0 oznacza całkowitą utratę informacji o sąsiedztwie.

W kontekście wizualizacji artykułów naukowych metryka ta odpowiada na pytanie:

> Czy artykuły, które znajdują się blisko siebie na mapie, są rzeczywiście semantycznie podobne w przestrzeni embeddingów?

Przykład intuicyjny. Załóżmy, że analizujemy artykuł A. W przestrzeni embeddingów jego pięciu najbliższych sąsiadów stanowią:

$$\{B, C, D, E, F\}.$$

Po projekcji do 2D najbliższe punkty na mapie to:

$$\{B, C, D, G, H\}.$$

Część wspólna zbiorów wynosi

$$\{B, C, D\}.$$

Oznacza to, że poprawnie zachowano trzech z pięciu sąsiadów:

$$\text{Recall} = \frac{3}{5} = 0.6.$$

Interpretacja: 60% rzeczywistych sąsiadów zostało poprawnie zachowanych w wizualizacji.

2.0.2 Trustworthiness

Metryka Trustworthiness mierzy, czy redukcja wymiarowości nie tworzy **fałszywych sąsiadów** w przestrzeni wizualizacji.

Innymi słowy sprawdza, czy punkty znajdujące się blisko siebie w 2D są rzeczywiście bliskie w przestrzeni oryginalnej.

Metryka została zaproponowana przez Venna i Kaski w kontekście oceny metod redukcji wymiarowości.

Definicja.

$$T(k) = 1 - \frac{2}{nk(2n - 3k - 1)} \sum_{i=1}^{n} \sum_{j \in U_k(i)} (r(i,j) - k) \tag{2}$$

Oznaczenia.

- n – liczba punktów,
- k – liczba najbliższych sąsiadów,
- $U_k(i)$ – zbiór punktów, które znajdują się wśród k najbliższych sąsiadów punktu i w 2D, ale nie należą do k najbliższych w przestrzeni oryginalnej,
- $r(i,j)$ – pozycja punktu j w rankingu odległości od punktu i w przestrzeni 768D.

Interpretacja. Metryka mierzy, jak często wizualizacja tworzy sztuczne sąsiedztwa.

- wartość bliska 1 oznacza, że wizualizacja rzadko wprowadza fałszywych sąsiadów,
- niższe wartości oznaczają, że w 2D pojawiają się punkty, które w rzeczywistości są daleko w przestrzeni embeddingów.

Przykład intuicyjny. Rozważmy artykuł A.

W przestrzeni embeddingów artykuł B znajduje się dopiero na pozycji np. $r(A,B) = 120$ w rankingu podobieństwa.

Jednak po projekcji do 2D artykuł B pojawia się wśród $k = 10$ najbliższych sąsiadów.

Oznacza to, że wizualizacja stworzyła fałszywe sąsiedztwo.

Im więcej takich przypadków, tym niższa wartość Trustworthiness.

2.0.3 Neighbourhood Hit

Metryka Neighbourhood Hit mierzy, czy najbliżsi sąsiedzi punktu w wizualizacji należą do tego samego klastra wyznaczonego w przestrzeni oryginalnej.

Pozwala to sprawdzić, czy wizualne skupienia punktów odpowiadają rzeczywistej strukturze danych.

Definicja. Dla każdego punktu analizuje się jego k najbliższych sąsiadów w przestrzeni 2D i oblicza odsetek punktów należących do tego samego klastra.

Oznaczenia.

- k – liczba analizowanych sąsiadów,
- $c(i)$ – etykieta klastra punktu i,
- $N_k(i)$ – zbiór k najbliższych sąsiadów punktu i w 2D.

Metryka obliczana jest jako średnia po wszystkich punktach w zbiorze.

Interpretacja.

- wartość bliska 1 oznacza, że najbliżsi sąsiedzi należą zwykle do tego samego klastra,
- niska wartość oznacza, że klastry są wizualnie wymieszane.

Przykład intuicyjny. Załóżmy, że artykuł A należy do klastra *Machine Learning*.

Jeśli jego 10 najbliższych sąsiadów w wizualizacji to głównie artykuły z tego samego klastra, Neighbourhood Hit będzie wysoki.

Jeśli jednak wśród najbliższych sąsiadów znajdują się artykuły z różnych dziedzin (np. graph theory, optimization, logic), wartość metryki spadnie.

2.0.4 Spearman Rank Correlation

Korelacja rang Spearmana mierzy, czy zachowany został globalny porządek odległości między punktami.

Nie analizuje dokładnych wartości dystansu, lecz sprawdza, czy relacje „bliżej–dalej" pozostały podobne po redukcji wymiarowości.

Definicja.

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} \tag{3}$$

Oznaczenia.

- d_i – różnica między rangą tej samej pary punktów w przestrzeni 768D i w 2D,
- n – liczba analizowanych par punktów.

Interpretacja.

- $\rho = 1$ oznacza, że kolejność odległości została zachowana idealnie,
- wartości bliskie 0 oznaczają brak zależności.

Przykład intuicyjny. Załóżmy, że w przestrzeni embeddingów odległości od artykułu A układają się następująco:

$$B < C < D < E$$

co oznacza, że B jest najbliższy, a E najdalszy.

Jeśli po projekcji do 2D kolejność pozostaje podobna, Spearman ρ będzie wysoki.

Jeśli jednak kolejność zostanie zaburzona, np.

$$E < C < B < D$$

wartość korelacji spadnie.

2.0.5 Pearson Correlation

Korelacja Pearsona mierzy liniową zależność między odległościami w przestrzeni oryginalnej i przestrzeni wizualizacji.

Definicja.

$$r = \frac{\mathrm{cov}(d_{HD}, d_{2D})}{\sigma_{HD}\sigma_{2D}} \tag{4}$$

Oznaczenia.

- d_{HD} – wektor odległości między parami punktów w przestrzeni 768D,
- d_{2D} – odpowiadające odległości w przestrzeni 2D,
- σ – odchylenie standardowe.

Interpretacja.

- $r = 1$ oznacza idealną zależność liniową,
- wartości bliskie 0 oznaczają brak liniowej relacji między odległościami.

Przykład intuicyjny. Jeśli w przestrzeni embeddingów odległość między dwoma artykułami wynosi np. 0.2, a w wizualizacji również pozostaje niewielka, zależność będzie silna.

Jeżeli jednak punkty, które w 768D są bardzo bliskie, w 2D znajdą się daleko od siebie, korelacja Pearsona spadnie.

2.0.6 Kruskal Stress

Stress Kruskala jest klasyczną miarą stosowaną w analizie MDS do oceny zniekształcenia odległości między przestrzenią oryginalną a projekcją niskowymiarową.

Definicja.

$$\sigma = \sqrt{\frac{\sum(\tilde{d}_{2D} - \tilde{d}_{HD})^2}{\sum \tilde{d}_{2D}^2}} \tag{5}$$

Oznaczenia.

- $\tilde{d}_{HD}$ – znormalizowane odległości w przestrzeni oryginalnej,
- $\tilde{d}_{2D}$ – znormalizowane odległości w przestrzeni wizualizacji.

Interpretacja.

- niska wartość Stress oznacza, że globalne odległości zostały dobrze zachowane,
- wysoka wartość oznacza duże zniekształcenie geometrii przestrzeni.

Przykład intuicyjny. Jeśli dwa artykuły w przestrzeni embeddingów mają podobieństwo odpowiadające małej odległości, a w wizualizacji znajdują się daleko od siebie, powoduje to wzrost błędu Stress.

Metryka sumuje takie różnice dla wszystkich par punktów.

2.0.7 SPDE

SPDE (Scaled Pairwise Distance Error) mierzy średnią różnicę między odległościami punktów w przestrzeni oryginalnej i w przestrzeni wizualizacji.

Definicja.

$$SPDE = 1 - \text{mean}\left|\tilde{d}_{HD} - \tilde{d}_{2D}\right| \tag{6}$$

Oznaczenia.

- $\tilde{d}_{HD}$ – znormalizowane odległości w 768D,
- $\tilde{d}_{2D}$ – znormalizowane odległości w 2D.

Interpretacja. Metryka mierzy średnie zniekształcenie odległości.

- wartość bliska 1 oznacza niewielkie zniekształcenie,
- niższe wartości oznaczają większy błąd odwzorowania.

Przykład intuicyjny. Jeśli dwa artykuły w przestrzeni embeddingów mają odległość 0.3, a w wizualizacji ich dystans odpowiada 0.8, różnica ta zwiększa błąd SPDE.

Metryka uśrednia takie różnice dla wszystkich par punktów.

Table 2: Podsumowanie metryk oceny jakości redukcji wymiarowości

Metryka	**Typ metryki**	**Co mierzy**	**Interpretacja**
kNN Recall	lokalna	zachowanie prawdziwych sąsiadów	ile rzeczywistych najbliższych punktów zostało zachowanych w wizualizacji
Trustworthiness	lokalna	fałszywe sąsiedztwa	czy wizualizacja nie pokazuje jako bliskich punktów, które w rzeczywistości są daleko
Neighbourhood Hit	lokalna / klastrowa	zgodność z klastrami	czy najbliżsi sąsiedzi należą do tego samego klastra
Spearman ρ	globalna	porządek odległości	czy kolejność relacji bliżej–dalej została zachowana
Pearson r	globalna	zależność liniowa odległości	czy odległości w 2D są proporcjonalne do odległości w przestrzeni oryginalnej
Kruskal Stress	globalna	globalny błąd odwzorowania	jak duże jest zniekształcenie całej geometrii przestrzeni
SPDE	globalna	średni błąd odległości	średnia różnica między dystansami w obu przestrzeniach

2.1 Podsumowanie metryk

Tabela 2 przedstawia podsumowanie zastosowanych metryk oraz aspekty jakości projekcji, które mierzy każda z nich.

Jak widać, poszczególne metryki oceniają różne właściwości wizualizacji. Metryki lokalne, takie jak kNN Recall oraz Trustworthiness, koncentrują się na zachowaniu najbliższego sąsiedztwa punktów. Odpowiadają one na pytanie, czy artykuły znajdujące się blisko siebie na mapie są rzeczywiście podobne w przestrzeni embeddingów.

Z kolei metryki globalne, takie jak Spearman ρ, Pearson r, Kruskal Stress oraz SPDE, oceniają stopień zachowania ogólnej struktury geometrycznej danych. Pozwalają one określić, czy relacje odległości pomiędzy punktami pozostają podobne po redukcji wymiarowości.

W praktyce różne metody redukcji wymiarowości mogą osiągać dobre wyniki w jednej metryce, a jednocześnie gorsze w innych. Na przykład metoda może bardzo dobrze zachowywać lokalne sąsiedztwo punktów, ale jednocześnie silnie zniekształcać globalne odległości.

Z tego powodu interpretacja wyników wyłącznie na podstawie pojedynczej metryki może prowadzić do niepełnych wniosków. W celu uzyskania bardziej syntetycznej oceny jakości projekcji wprowadzono dodatkową miarę zbiorczą łączącą kilka najważniejszych metryk.

2.2 Composite Score

Aby umożliwić bezpośrednie porównanie metod redukcji wymiarowości, zdefiniowano syntetyczną miarę jakości projekcji, nazwaną *Composite Score*.

Metryka ta łączy kilka kluczowych miar opisujących zarówno lokalną, jak i globalną jakość odwzorowania.

$$\text{Composite} = 0.4 \cdot \text{kNN Recall} + 0.3 \cdot \text{Trustworthiness} + 0.2 \cdot \rho + 0.1 \cdot (1 - \sigma) \tag{7}$$

gdzie:

- kNN Recall mierzy, czy rzeczywiści najbliżsi sąsiedzi zostali zachowani po redukcji wymiarowości,
- Trustworthiness ocenia, czy wizualizacja nie tworzy fałszywych sąsiedztw,
- ρ oznacza korelację rang Spearmana, mierzącą zachowanie globalnego porządku odległości,
- σ oznacza Kruskal Stress, czyli globalny błąd odwzorowania.

Wagi zastosowane w formule odzwierciedlają znaczenie poszczególnych aspektów jakości wizualizacji.

Największą wagę przypisano metrykom lokalnym (kNN Recall oraz Trustworthiness), ponieważ głównym celem analizowanej wizualizacji jest eksploracja semantycznego sąsiedztwa artykułów naukowych.

Mniejszą wagę przypisano metrykom globalnym, które opisują ogólną strukturę przestrzeni, ale mają mniejsze znaczenie z punktu widzenia interaktywnej eksploracji danych.

Composite Score nie zastępuje analizy pojedynczych metryk, lecz stanowi syntetyczną miarę pozwalającą na łatwiejsze porównanie różnych metod redukcji wymiarowości.

3 Experimental Setup

Eksperymenty przeprowadzono na zbiorze publikacji naukowych reprezentowanych w postaci embeddingów tekstowych. Każdy dokument opisany jest wektorem w przestrzeni $\mathbb{R}^{768}$, który stanowi semantyczną reprezentację treści artykułu.

Dataset. Analizowany zbiór danych zawiera $N = 3440$ publikacji naukowych pochodzących z korpusu artykułów badawczych. Każdy artykuł reprezentowany jest przez 768-wymiarowy embedding tekstowy.

Embeddingi zostały znormalizowane przy użyciu normy L^2, co oznacza że

$$\|e_i\| = 1.$$

Dzięki temu odległość euklidesowa jest monotonicznie związana z podobieństwem kosinusowym.

Distance metric. Podobieństwo między dokumentami w przestrzeni embeddingów mierzone jest przy użyciu odległości kosinusowej:

$$d_{cos}(i, j) = 1 - e_i \cdot e_j$$

gdzie e_i oraz e_j oznaczają embeddingi dwóch dokumentów.

Dimensionality reduction methods. W eksperymentach porównano osiem metod redukcji wymiarowości:

- PCA,
- t-SNE,
- UMAP,
- PaCMAP,
- Isomap,
- Spectral Embedding,
- LDA,
- PCA 8D + log.

Wszystkie metody generują projekcję danych do przestrzeni dwuwymiarowej, umożliwiając wizualizację relacji między artykułami.

Clustering. Przed redukcją wymiarowości dane zostały pogrupowane przy użyciu algorytmu K-Means w przestrzeni oryginalnych embeddingów.

Na podstawie analizy silhouette wybrano liczbę klastrów

$$k = 9.$$

Uzyskane klastry wykorzystywane są w analizie metryki Neighbourhood Hit oraz jako etykiety klas dla metody LDA.

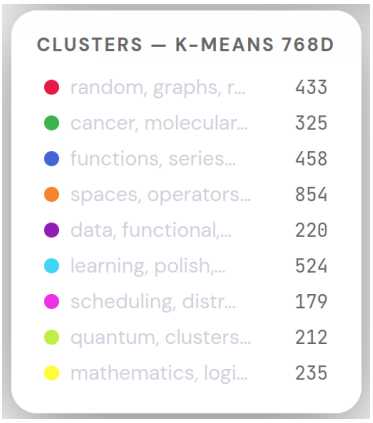

Figure 1: Cluster panel from the interactive viewer showing the 9 K-Means clusters with auto-generated labels (top-3 non-stopword title words) and paper counts. The largest cluster (*spaces, operators, banach*) contains 854 papers, reflecting UAM's strong tradition in functional analysis.

Metric computation. Ocena jakości projekcji została przeprowadzona z wykorzystaniem zestawu metryk opisanych w poprzednim rozdziale.

Ze względu na koszt obliczeniowy część metryk została policzona na losowej próbie danych o rozmiarze

$$n = 1500.$$

Dla metryk lokalnych liczbę najbliższych sąsiadów ustawiono na

$$k = 15.$$

Odległości w przestrzeni oryginalnej obliczano przy użyciu odległości kosinusowej, natomiast w przestrzeni wizualizacji stosowano odległość euklidesową.

Composite score. W celu ułatwienia porównania metod zastosowano również syntetyczną miarę jakości Composite Score, która łączy kilka kluczowych metryk opisujących lokalną i globalną jakość projekcji.

Metryka ta pozwala na ranking metod redukcji wymiarowości w oparciu o jeden zbiorczy wskaźnik jakości.

4 Dlaczego wyniki wydają się „niskie”?

Zanim przejdziemy do prezentacji wyników, należy odpowiedzieć na kluczowe pytanie: *czy wartości kNN Recall na poziomie 0,20–0,65 oznaczają błąd w działaniu metody?* Odpowiedź brzmi: **nie** — wartości te są matematycznie nieuniknione.

4.1 Ograniczenie Johnsona–Lindenstraussa

Lemat Johnsona–Lindenstraussa [1] mówi, że aby zachować wszystkie odległości między parami punktów z dokładnością do czynnika $(1 \pm \varepsilon)$ dla n punktów, wymagana liczba wymiarów wynosi co najmniej:

$$d_{\min} = \Omega\left(\frac{\log n}{\varepsilon^2}\right) \tag{8}$$

Dla $n = 3\,440$ oraz $\varepsilon = 0{,}1$ (10% zniekształcenia) otrzymujemy $d_{\min} \approx 1\,200$. W analizowanym przypadku redukcja do $d = 2$ oznacza przestrzeń około 600× mniejszą niż wymagane minimum teoretyczne.

4.2 Wymiarowość wewnętrzna

Embeddingi tekstowe mają tzw. **wymiarowość wewnętrzną** rzędu 20–100 wymiarów, w zależności od modelu i zróżnicowania danych [2]. Nawet przy dolnym oszacowaniu ($d_{\text{intrinsic}} = 20$) twierdzenie Whitney'ego wskazuje, że do wiernego odwzorowania potrzebnych jest co najmniej $2d + 1 = 41$ wymiarów.

Redukcja do 2D oznacza więc utratę co najmniej 90% istotnej struktury danych.

4.3 Oczekiwane zakresy metryk

Na podstawie literatury oraz przeprowadzonych eksperymentów można wskazać typowe zakresy wartości metryk:

Table 3: Oczekiwane zakresy metryk dla projekcji 768D→2D embeddingów tekstowych.

Metryka	**Zakres**	**Najlepszy wynik**	**Interpretacja**
kNN Recall@100	0,10–0,65	0,646 (t-SNE)	Dobry — większość rzeczywistych sąsiadów zachowana
Trustworthiness	0,75–0,99	0,976 (t-SNE)	Bardzo dobry — mało fałszywych sąsiadów
Spearman ρ	0,40–0,80	0,773 (LDA)	Dobry — zachowany globalny porządek odległości
SPDE	0,60–0,85	0,832 (PCA)	Dobry — średni błąd odległości poniżej 20%
Kruskal Stress	0,30–2,0	0,402 (PaCMAP)	Typowy — wysokie wartości są naturalne przy silnej redukcji

Uzyskane wyniki nie są „złe” — wynikają z fundamentalnych ograniczeń redukcji wymiarowości. Wierne odwzorowanie 768 wymiarów w przestrzeni dwuwymiarowej jest po prostu niemożliwe.

5 Zniekształcenia odległości: jak t-SNE i LDA wprowadzają w błąd

5.1 Rozkład o ciężkich ogonach w t-SNE

t-SNE wykorzystuje rozkład t-Studenta (z jednym stopniem swobody) w przestrzeni niskowymiarowej. Prowadzi to do **celowego zwiększania odległości** między punktami umiarkowanie odległymi, co stanowi rozwiązanie tzw. problemu zagęszczania (*crowding problem*) [3].

Skutkuje to trzema charakterystycznymi zniekształceniami [8]:

1. **Wyrównanie wielkości klastrów** — gęsty klaster 500 artykułów ma podobny rozmiar wizualny jak rzadki klaster 50 artykułów.
2. **Brak interpretowalności odległości między klastrami** — nie istnieje ustawienie parametrów, które wiernie zachowuje relacje między więcej niż dwoma klastrami.
3. **Powstawanie artefaktów** — nawet losowe dane mogą tworzyć pozorne „klastry”.

Dlatego t-SNE osiąga wysokie wartości kNN Recall — dobrze zachowuje informację o tym, *które punkty są sąsiadami*, ale nie zachowuje rzeczywistych odległości między klastrami.

5.2 Rozumowanie kołowe w LDA

LDA maksymalizuje separację między klasami już na poziomie definicji. Dla dowolnych etykiet klastrów znajdzie projekcję, która **maksymalizuje ich rozdzielenie**, nawet jeśli w przestrzeni oryginalnej separacja jest niewielka.

Prowadzi to do kilku problemów:

1. Wnioskowanie o dobrej separacji klastrów na podstawie wizualizacji LDA jest **rozumowaniem kołowym**.
2. Odległości między klastrami są **sztucznie zawyżone**.
3. Struktura wewnątrz klastrów jest **zniekształcona**.

Wyjaśnia to obserwację, że LDA osiąga niski kNN Recall, a jednocześnie wysoką korelację Spearmana.

5.3 UMAP nie jest bardziej „obiektywny”

Często zakłada się, że UMAP lepiej zachowuje strukturę globalną niż t-SNE. Badania [6] pokazują jednak, że wynika to głównie z różnic w inicjalizacji.

Po zastosowaniu tej samej inicjalizacji (np. PCA) obie metody osiągają bardzo podobne wyniki w zakresie struktury globalnej.

6 Wyniki

6.1 Porównanie metryk

Tabela 4 przedstawia wartości wszystkich metryk dla ośmiu analizowanych metod, posortowane według Composite Score.

Table 4: Metryki jakości. n=3 440, k=100 sąsiadów. Najlepsza wartość w kolumnie oznaczona **pogrubieniem**. † = metoda zawyża odległości między klastrami.

Metoda	kNN↑	Trust↑	Comp↑	NbHit↑	Spear↑	SPDE↑	Stress↓
t-SNE†	**0,646**	**0,976**	**0,745**	**0,923**	0,573	0,826	0,415
PaCMAP	0,579	0,969	0,735	0,916	0,666	**0,828**	**0,402**
UMAP	0,585	0,958	0,725	0,910	0,666	0,774	0,595
Spectral	0,438	0,915	0,659	0,870	0,651	0,821	0,415
Isomap	0,306	0,866	0,600	0,745	0,702	0,829	0,451
PCA	0,260	0,855	0,576	0,711	0,685	0,832	0,442
LDA†	0,216	0,879	0,575	0,878	**0,773**	0,784	0,582
PCA 8D+log	0,197	0,816	0,530	0,498	0,770	0,706	0,948

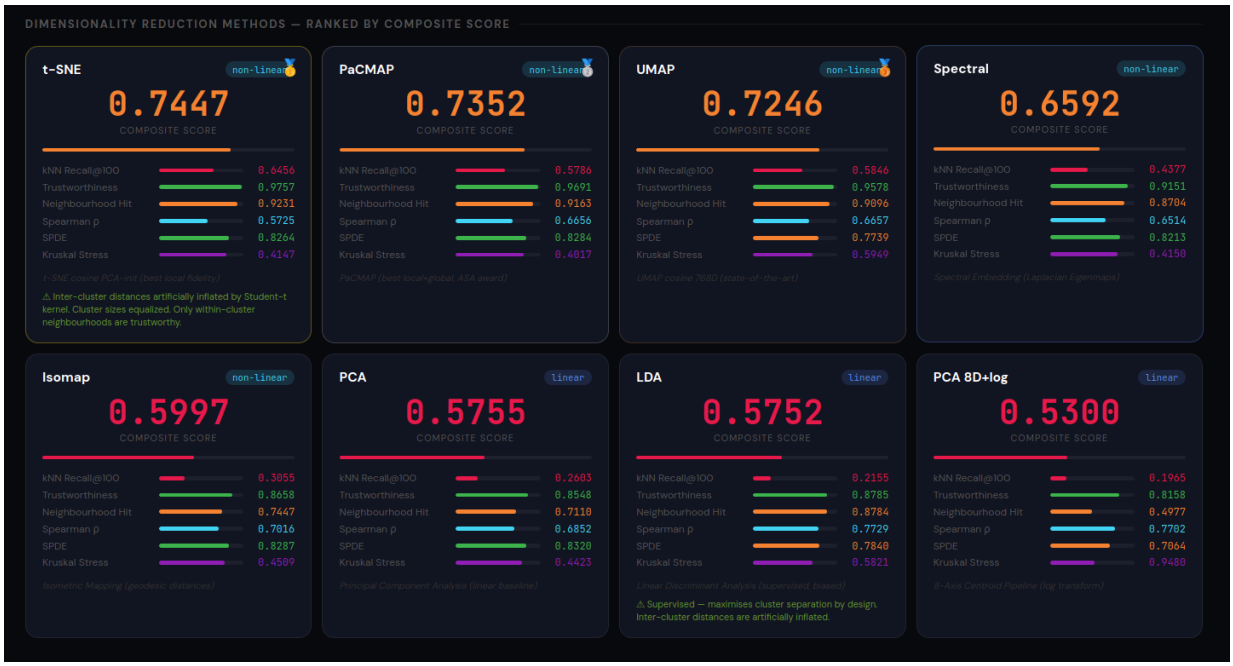

Figure 2: Zestawienie metryk jakości dla wszystkich ośmiu metod redukcji wymiarowości, uporządkowanych według wartości Composite Score. Każda metoda opisana jest zestawem słupków odpowiadających poszczególnym metrykom oraz informacją o jej charakterze (liniowa / nieliniowa). Trzy najlepsze metody — t-SNE, PaCMAP oraz UMAP — należą do metod nieliniowych i osiągają wartości powyżej 0,72.

6.2 Znaczenie wyboru metryki

Uzyskane wyniki pokazują, że **różne metryki prowadzą do różnych rankingów metod**.

PCA osiąga najlepsze wyniki dla SPDE (0,832) i Stress (0,442), ponieważ dobrze zachowuje globalne wartości odległości między parami punktów. Jednak kNN Recall wynosi jedynie 0,260, co oznacza, że użytkownik analizujący sąsiedztwo artykułów otrzymywałby w większości przypadków niepoprawne wyniki.

LDA osiąga najwyższą wartość korelacji Spearmana (0,773), ponieważ dobrze zachowany jest globalny porządek odległości. Wynik ten jest jednak zdominowany przez liczne pary odległych punktów, które łatwo uporządkować poprawnie. Jednocześnie kNN Recall (0,216) pokazuje, że rzeczywiste sąsiedztwo punktów jest silnie zaburzone.

t-SNE osiąga najwyższe wartości kNN Recall (0,646) oraz Trustworthiness (0,976), ponieważ metoda została zaprojektowana z myślą o zachowaniu lokalnej struktury danych. Oznacza to, że około 65% rzeczywistych sąsiadów jest poprawnie odwzorowanych w przestrzeni 2D, co stanowi wynik powyżej typowego zakresu dla redukcji 768D→2D.

6.3 Porównanie wizualizacji

Rysunki 3–7 przedstawiają projekcje 2D uzyskane dla poszczególnych metod. Kolory punktów odpowiadają klastrom wyznaczonym metodą K-Means w przestrzeni 768D.

Widoczne różnice między wizualizacjami bezpośrednio odzwierciedlają kompromisy między zachowaniem struktury lokalnej i globalnej.

6.3.1 Najlepsze metody nieliniowe

Figure 3: **t-SNE** (Composite = 0,745). Metoda tworzy wyraźnie odseparowane skupiska punktów. Wielkości klastrów są jednak wizualnie wyrównane — największy klaster ma rozmiar zbliżony do najmniejszego. Odległości między klastrami są artefaktem metody i nie odzwierciedlają rzeczywistych relacji semantycznych.

Figure 4: **PaCMAP** (Composite = 0,735). Punkty organizują się w większe regiony z płynnymi przejściami między tematami, co odzwierciedla lepsze zachowanie struktury globalnej.

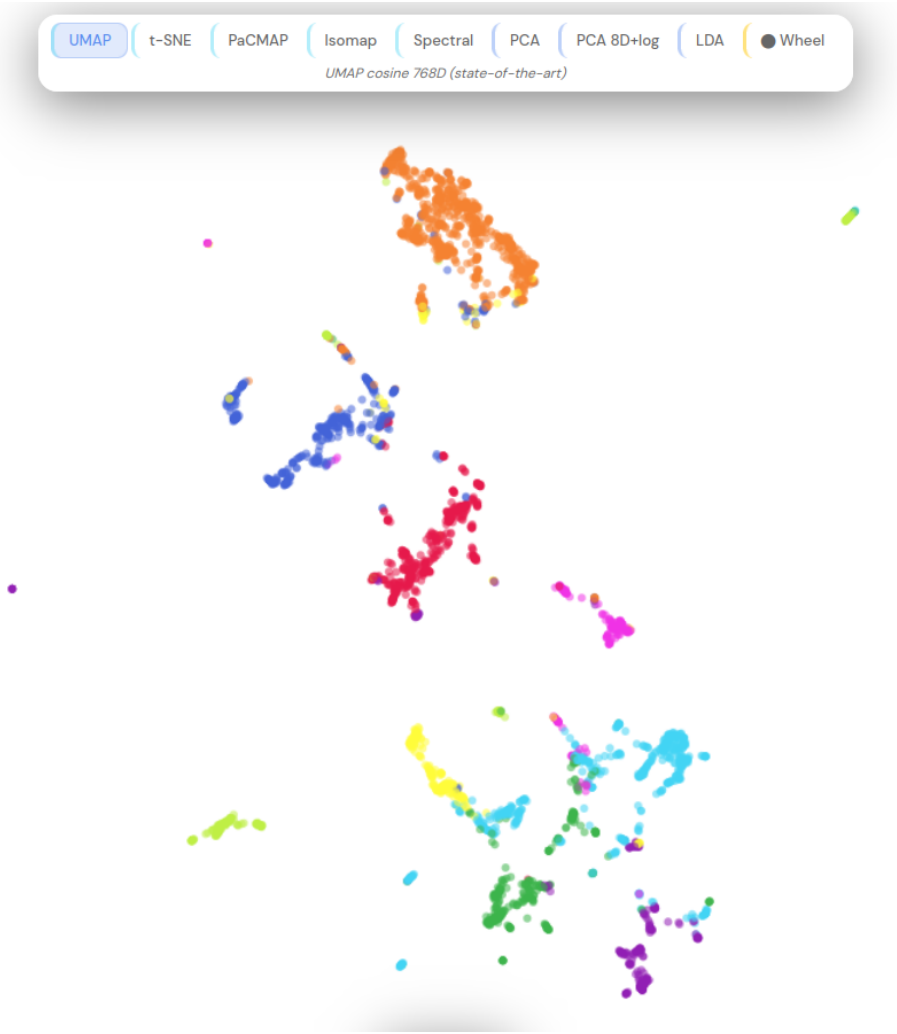

Figure 5: **UMAP** (Composite = 0,725). Klastry tworzą dobrze odseparowane skupiska o zróżnicowanych kształtach. Metoda umożliwia również dodawanie nowych punktów bez ponownego obliczania projekcji.

6.3.2 Metody liniowe i pośrednie

Figure 6: **PCA** (Composite = 0,576). Tworzy ciągłą chmurę punktów z silnym nakładaniem się klastrów. Zachowana jest ogólna struktura globalna, ale lokalne sąsiedztwo jest słabo odwzorowane.

Figure 7: **LDA** (Composite = 0,575). Wizualnie wyraźna separacja klastrów, jednak jest ona wynikiem optymalizacji metody, a nie rzeczywistej struktury danych. Lokalna struktura jest silnie zniekształcona.

7 Dobór metody

Table 5: Przewodnik doboru metody dla interaktywnej wizualizacji artykułów naukowych.

Zastosowanie	**Metoda**	**Uzasadnienie**
Główny widok interaktywny	UMAP (cosine)	Praca bezpośrednio w przestrzeni 768D z metryką kosinusową; dobry kompromis między strukturą lokalną i globalną; możliwość dodawania nowych punktów
Najlepsze zachowanie lokalne	t-SNE	Najwyższy kNN Recall; zalecane do eksploracji, nie do interpretacji odległości
Najlepszy kompromis ogólny	PaCMAP	Trójfazowa optymalizacja równoważąca strukturę lokalną i globalną; niewielka wrażliwość na dobór parametrów
Relacje między klastrami	Isomap	Odległości geodezyjne; sensowne rozmieszczenie klastrów w skali globalnej
Szybki punkt odniesienia	PCA	Metoda szybka i deterministyczna; przydatna jako baseline
Nie zaleca się do eksploracji	LDA	Metoda nadzorowana; sztucznie zwiększa separację klastrów; prowadzi do rozumowania kołowego

8 Wnioski

Wybór metody redukcji wymiarowości oraz metryki jakości ma kluczowy wpływ na interpretację wyników wizualizacji.

W kontekście interaktywnej analizy zbiorów artykułów naukowych można sformułować następujące wnioski:

- **kNN Recall@100** jest najbardziej adekwatną metryką, ponieważ bezpośrednio odpowiada na pytanie, czy wizualizowane sąsiedztwo odpowiada rzeczywistemu podobieństwu.
- Wartości w zakresie 0,20–0,65 są **matematycznie oczekiwane** dla redukcji z 768 do 2 wymiarów, co wynika z ograniczeń opisanych przez lemat Johnsona–Lindenstraussa.
- **t-SNE** zapewnia najwyższą wierność lokalną (kNN = 0,646, Composite = 0,745), jednak z definicji **zniekształca odległości między klastrami**.
- **LDA** nie powinno być stosowane do eksploracji danych, ponieważ tworzy **sztuczną separację klastrów** wynikającą bezpośrednio z funkcji celu.
- **UMAP** działający bezpośrednio na 768D z metryką kosinusową jest najbardziej praktycznym wyborem, ponieważ łączy dobrą jakość wizualizacji z możliwością dodawania nowych punktów.
- **PaCMAP** oferuje najlepszy kompromis między strukturą lokalną i globalną (najniższy Stress = 0,402, najwyższe SPDE = 0,828).
- Optymalna liczba klastrów wynosi $k = 9$ (silhouette = 0,2823).
- Rozszerzenie wizualizacji do 3D daje jedynie niewielką poprawę metryk (rzędu 5–10%), przy jednoczesnym znacznym pogorszeniu użyteczności interakcyjnej.

Wyniki pracy wykorzystywane są w postaci jednego pliku JSON, który zasila interaktywną wizualizację w przeglądarce. Wszystkie metryki oraz informacje o metodach są odczytywane dynamicznie, bez konieczności ich ręcznego definiowania w kodzie.

References

[1] W. B. Johnson and J. Lindenstrauss, "Extensions of Lipschitz mappings into a Hilbert space," *Contemp. Math.*, vol. 26, pp. 189–206, 1984.

[2] C. C. Aggarwal, A. Hinneburg, and D. A. Keim, "On the surprising behavior of distance metrics in high dimensional space," *ICDT*, pp. 420–434, 2001.

[3] L. van der Maaten and G. Hinton, "Visualizing data using t-SNE," *JMLR*, vol. 9, pp. 2579–2605, 2008.

[4] L. McInnes, J. Healy, and J. Melville, "UMAP: Uniform Manifold Approximation and Projection for dimension reduction," *arXiv:1802.03426*, 2018.

[5] Y. Wang, H. Huang, C. Rudin, and Y. Shaposhnik, "Understanding how dimension reduction tools work: an empirical approach to deciphering t-SNE, UMAP, TriMap, and PaCMAP," *JMLR*, vol. 22, no. 201, pp. 1–73, 2021.

[6] D. Kobak and G. C. Linderman, "Initialization is critical for preserving global data structure in both t-SNE and UMAP," *Nature Biotechnology*, vol. 39, pp. 156–157, 2021.

[7] J. N. Böhm, P. Berens, and D. Kobak, "Attraction–repulsion spectrum in neighbor embeddings," *JMLR*, vol. 23, no. 95, pp. 1–32, 2022.

[8] M. Wattenberg, F. Viégas, and I. Johnson, "How to use t-SNE effectively," *Distill*, 2016. https://distill.pub/2016/misread-tsne/

[9] M. Grootendorst, "BERTopic: Neural topic modeling with a class-based TF-IDF procedure," *arXiv:2203.05794*, 2022.

[10] P. J. Rousseeuw, "Silhouettes: a graphical aid to the interpretation and validation of cluster analysis," *J. Comp. Appl. Math.*, vol. 20, pp. 53–65, 1987.

[11] J. B. Tenenbaum, V. de Silva, and J. C. Langford, "A global geometric framework for nonlinear dimensionality reduction," *Science*, vol. 290, pp. 2319–2323, 2000.

[12] J. B. Kruskal, "Multidimensional scaling by optimizing goodness of fit to a nonmetric hypothesis," *Psychometrika*, vol. 29, pp. 1–27, 1964.