Wizualizacja profili badawczych naukowców WMI UAM za pomocą embeddingów tekstowych

From 768D Paper Embeddings to 2D Author Maps
with Multi-Cluster Representation

Jakub Paszke
Wydział Matematyki i Informatyki
Uniwersytet im. Adama Mickiewicza w Poznaniu

Marzec 2026

Streszczenie

Praca opisuje pipeline wizualizacji profili badawczych 115 naukowców Wydziału Matematyki i Informatyki UAM w przestrzeni dwuwymiarowej. Każdy naukowiec jest reprezentowany przez embeddingi swoich publikacji (768-wymiarowe wektory generowane przez model BGE-base-en-v1.5 po fine-tuningu CoSENT na zbiorze ArXiv). Proponujemy dwa warianty wizualizacji: *mean pooling* (jeden punkt per autor) oraz *multi-cluster* (wiele punktów per autor, odpowiadających odrębnym kierunkom badawczym, z automatycznym doborem liczby klastrów za pomocą silhouette score). Fine-tuning modelu bazowego poprawia separację kategorii naukowych o 5–7 pp (fuzzy purity) i zwiększa variance explained w PCA z 33% do 55% na danych autorów. Ewaluacja na strukturze zakładów WMI (NMI = 0.702) potwierdza, że embeddingi sensownie odzwierciedlają pokrewieństwo tematyczne. Wynikowe interaktywne wizualizacje HTML (Plotly) umożliwiają wyszukiwanie i porównywanie naukowców w przeglądarce.

Spis treści

1 Wstęp i motywacja

1.1 Kontekst projektu SARA

Niniejsza praca powstała w ramach projektu **SARA** (*Search and Research Assistant*) — systemu rekomendacji i eksploracji dorobku naukowego realizowanego na Wydziale Matematyki i Informatyki UAM. Celem projektu SARA jest zbudowanie narzędzia umożliwiającego wyszukiwanie artykułów naukowych, identyfikację potencjalnych współpracowników oraz eksplorację struktury badawczej wydziału. Jednym z kluczowych komponentów systemu jest interaktywna mapa naukowców, która wizualizuje profile badawcze pracowników WMI w przestrzeni dwuwymiarowej.

Wizualizacja autorów pełni w systemie SARA konkretną rolę: nie jest jedynie efektownym wykresem, lecz narzędziem wspierającym decyzje. Nowy doktorant szukający promotora może na jej podstawie zidentyfikować badaczy o pokrewnych zainteresowaniach. Zespół grantowy może wykryć, że dwóch naukowców z różnych zakładów pracuje nad zbliżoną tematyką i mógłby efektywnie współpracować. Administracja wydziału może ocenić, na ile struktura organizacyjna (podział na zakłady) odzwierciedla rzeczywiste pokrewieństwo badawcze.

1.2 Porównanie z podejściem opartym na wizualizacji artykułów

Równolegle M. Wujec opracował komplementarny moduł systemu SARA — interaktywną wizualizację **artykułów** naukowych WMI [**?**]. W jego podejściu każdy z 3440 artykułów reprezentowany jest jako punkt na mapie 2D, a użytkownik eksploruje tematyczne sąsiedztwo poszczególnych publikacji. Wujec przeprowadził obszerną analizę porównawczą ośmiu metod redukcji wymiarowości (PCA, t-SNE, UMAP, PaCMAP, Isomap, Spectral Embedding, LDA, PCA 8D+log) z wykorzystaniem siedmiu metryk jakości projekcji.

Niniejsza praca stawia inne pytanie badawcze: zamiast wizualizować poszczególne artykuły, wizualizuje **autorów** — agregując dorobek każdego naukowca w pojedynczy punkt (lub kilka punktów, w wariancie multi-cluster). Różnica w skali jest istotna: 3440 punktów/artykułów u Wujca wobec 115 punktów/autorów w niniejszej pracy. Ta zmiana skali prowadzi do odmiennych wyzwań:

- **Agregacja informacji:** Każdy punkt na mapie autorów reprezentuje średnio ∼30 prac, co wymaga strategii uśredniania embeddingów (mean pooling).
- **Mniejszy zbiór:** Przy 115 punktach problem nakładania się jest mniejszy, ale za to każdy punkt jest „cięższy” — utrata informacji przy złym uśrednieniu jest bardziej dotkliwa.
- **Interpretowalność:** Na mapie artykułów użytkownik widzi tytuły i abstrakty; na mapie autorów widzi nazwiska i zakłady, co pozwala na bezpośrednie wnioski organizacyjne.
- **Wariancja danych:** Uśrednianie per autor wygładza szum pojedynczych prac, co skutkuje wyższym variance explained w PCA (54.7% na autorach vs 12.2–29.4% na artykułach — szczegóły w sekcji **??**).

Ponadto M. Rolewski [**?**] w swojej pracy magisterskiej opisał fundamenty profilowania naukowców WMI za pomocą embeddingów, testując 6 modeli (SPECTER, MiniLM, MPNet, BGE-Small) i metody walidacji oparte na współautorstwie. W sekcji 1.7 jego pracy zaproponował jako kierunek przyszły *reprezentację multimodalną* — kilka centroidów per naukowiec. Niniejsza praca realizuje tę propozycję.

1.3 Zakres pracy

Praca obejmuje pełny pipeline — od scrapingu danych o pracownikach WMI, przez pobieranie ich dorobku naukowego z OpenAlex, generowanie embeddingów tekstowych, fine-tuning modelu embeddingowego, po końcową wizualizację interaktywną. Dokument opisuje dwa warianty wizualizacji: **mean pooling** (jeden punkt per autor) oraz **multi-cluster** (wiele punktów per autor, odpowiadających odrębnym kierunkom badawczym).

2 Pipeline danych

2.1 Źródła danych

Pipeline danych składa się z dwóch etapów zbierania informacji: scrapingu danych kadrowych WMI oraz pobierania dorobku naukowego z otwartych baz bibliometrycznych.

Scraper WMI. Skrypt scrapingowy przechodzi po stronach poszczególnych zakładów i pracowni wydziału, zbierając dla każdego naukowca: imię i nazwisko, afiliację (zakład/pracownia), identyfikator ORCID oraz ewentualne dodatkowe identyfikatory. Dane zapisywane są w pliku `scientists_with_identifiers.csv`. Na tym etapie zidentyfikowano **164 pracowników** WMI UAM, z czego 160 posiada identyfikator ORCID. Po połączeniu z danymi z OpenAlex, **115 naukowców** miało co najmniej jedną publikację w bazie. Spośród nich 92 ma jednoznaczne przypisanie do konkretnego zakładu lub pracowni.

OpenAlex API. Drugi etap wykorzystuje identyfikatory ORCID do pobrania dorobku naukowego każdego autora z bazy **OpenAlex** [**?**] — otwartego katalogu publikacji naukowych. Wynikowy plik `titles_with_abstracts.csv` zawiera **3440 prac**.

Tabela 1: Podsumowanie zbioru danych.

Parametr	Wartość
Pracownicy WMI UAM	164
Z identyfikatorem ORCID	160
Z publikacjami w OpenAlex	115
Z przypisaniem do zakładu	92
Publikacje (łącznie)	3 440
Średnia prac / autor	29.9
Mediana prac / autor	19.0
Zakłady / pracownie	19

Rozkład prac per autor. Rozkład liczby prac na autora jest silnie prawoskośny (rys. **??**). Autorzy z mniej niż 5 pracami (9 osób) traktowani są w wizualizacji jako „low confidence” — ich embeddingi mogą być niestabilne.

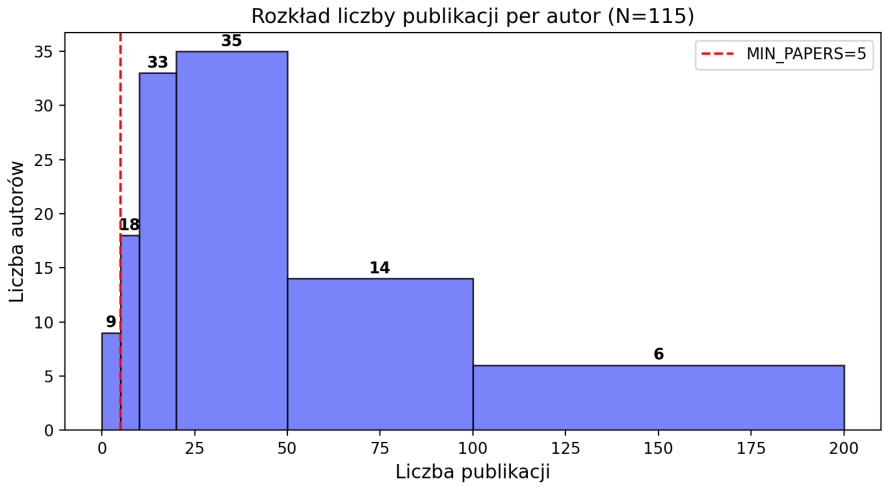

Rysunek 1: Rozkład liczby publikacji per autor ($N = 115$). Linia przerywana oznacza próg `MIN_PAPERS = 5`.

2.2 Embeddingi artykułów

Każdy artykuł kodowany jest jako wektor 768-wymiarowy za pomocą modelu Sentence Transformer. Tekst wejściowy konstruowany jest jako konkatenacja tytułu i abstraktu: `"{title}. {abstract}"`. W przypadku braku abstraktu używany jest sam tytuł (w praktyce dotyczy to jedynie 4 z 3440 prac).

Wybór modelu. W ramach prac nad systemem SARA przetestowano 9 modeli embeddingowych na zbiorze 2 397 artykułów ArXiv z hierarchiczną strukturą kategorii (118 podkategorii). Rysunek **??** przedstawia porównanie.

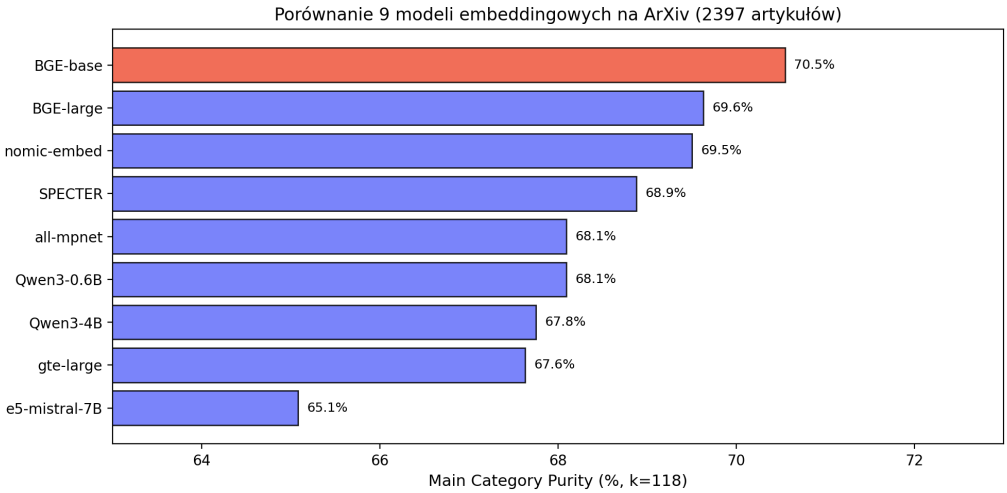

Rysunek 2: Porównanie 9 modeli embeddingowych: main category purity (K-means, k=118) na zbiorze ArXiv. BGE-base osiąga najwyższy wynik (70.55%) mimo mniejszego wymiaru niż BGE-large.

Model bazowy to **BAAI/bge-base-en-v1.5** [?] — model embeddingowy generujący wektory 768-wymiarowe, osiągający najwyższą main category purity (70.55%) spośród wszystkich testowanych modeli. Warto odnotować, że największy testowany model — e5-mistral-7b-instruct

(4096D) — osiąga najsłabszy wynik (65.08%), co sugeruje, że większy wymiar embeddingu nie przekłada się automatycznie na lepszą jakość klastrowania.

Normalizacja. Embeddingi generowane są z normalizacją L_2: $\|e_i\| = 1$. Dzięki temu odległość euklidesowa jest monotonicznie związana z podobieństwem kosinusowym:

$$d_{\text{euc}}(e_i, e_j) = \sqrt{2\big(1 - \cos(e_i, e_j)\big)}, \tag{1}$$

co upraszcza zarówno obliczenia (K-means z odległością euklidesową jest równoważny z metryką kosinusową), jak i interpretację.

2.3 Fine-tuning modelu

Motywacja. Model bazowy BGE-base został wytrenowany na ogólnym korpusie tekstów i nie jest specjalnie dostosowany do rozróżniania subtelnych różnic między poddziedzinami nauki.

Pierwsza próba: MNR. Zastosowanie *MultipleNegativesRankingLoss* (3 epoki, lr $= 2 \cdot 10^{-5}$, batch 32) prowadziło do overfittingu po 2. epoce. Problem wynikał z binarnej natury MNR — artykuł z `cs.AI` jest „bardziej podobny" do `cs.ML` niż do `math.AG`, ale MNR traktuje obie pary jako negatywne.

Rozwiązanie: CoSENTLoss. Drugie podejście zastąpiło MNR funkcją straty **CoSENTLoss** [**?**], która akceptuje ciągłe wyniki podobieństwa $\in [0, 1]$. Wyniki obliczane są na podstawie 3-poziomowej hierarchii kategorii ArXiv:

$$d_{\text{hier}}(c_i, c_j) = \begin{cases} 0.0 & \text{ta sama podkategoria (np. cs.AI vs cs.AI),} \\ 0.33 & \text{to samo archiwum, inna podkat. (np. hep-ph vs hep-th),} \\ 0.67 & \text{ta sama grupa, inne archiwum (np. astro-ph.CO vs quant-ph),} \\ 1.0 & \text{inna grupa (np. cs.AI vs math.AG).} \end{cases} \tag{2}$$

Ponieważ 63.8% artykułów ma więcej niż jedną kategorię (średnio 2.06), stosujemy **rozmyte etykiety**:

$$\text{score}(A, B) = 0.5 \cdot J(C_A, C_B) + 0.5 \cdot \overline{d}_{\text{best}}(C_A, C_B), \tag{3}$$

gdzie J oznacza współczynnik Jaccarda zbiorów kategorii, a $\overline{d}_{\text{best}}$ — średnią najlepszego hierarchicznego dopasowania.

Tabela 2: Hiperparametry fine-tuningu.

Parametr	Wartość
Model bazowy	BAAI/bge-base-en-v1.5 (768D)
Funkcja straty	CoSENTLoss
Artykuły (trening)	18 880
Epoki	1
Learning rate	$1 \cdot 10^{-5}$
Batch size	64
GPU	Google Colab A100

3 Metody reprezentacji autorów

Przejście od embeddingów per-artykuł do embeddingów per-autor wymaga strategii agregacji. Każdy autor a ma zbiór prac $\mathcal{P}_a = \{p_1, \ldots, p_{n_a}\}$, gdzie każda praca p_i jest reprezentowana przez embedding $e_i \in \mathbb{R}^{768}$.

3.1 Mean Pooling (jeden punkt per autor)

Definicja. Embedding autora a definiujemy jako znormalizowaną średnią embeddingów jego prac:

$$\bar{e}_a = \frac{1}{n_a} \sum_{i=1}^{n_a} e_i, \qquad \hat{e}_a = \frac{\bar{e}_a}{\|\bar{e}_a\|}. \tag{4}$$

Dlaczego mean pooling? Mean pooling jest nieobciążony — średnia wektorów z danej podprzestrzeni leży w centroidzie tej podprzestrzeni, co jest naturalną „środkową" reprezentacją dorobku. Rozważano alternatywne strategie (max pooling, weighted pooling ważony cytowaniami, attention pooling), ale żadna nie uzasadniała dodatkowej złożoności przy 115 autorach.

Wpływ normalizacji. Bez normalizacji autor z dużą liczbą prac o spójnej tematyce miałby wektor o dużej normie, natomiast autor z pracami rozrzuconymi tematycznie — o małej normie. Normalizacja eliminuje ten efekt: porównujemy jedynie *kierunki* w przestrzeni embeddingów.

Próg wiarygodności. Autorzy z mniej niż 5 publikacjami oznaczani są jako „low-confidence" i domyślnie ukryci na wizualizacji. Próg ten jest spójny z wynikami Rolewskiego [**?**], który wykazał, że centroid stabilizuje się (sim > 0.95) przy $\sim$5 pracach.

3.2 Multi-Cluster (wiele punktów per autor)

Mean pooling zakłada, że profil badawczy autora jest **unimodalny**. W rzeczywistości wielu naukowców prowadzi badania w dwóch lub więcej odrębnych kierunkach. Uśrednienie takich embeddingów dałoby punkt w pustej przestrzeni „między" dziedzinami — niereprezentujący żadnego z rzeczywistych kierunków.

Wariant **multi-cluster** reprezentuje każdego autora jako $k_a \geq 1$ punktów, gdzie każdy punkt odpowiada jednemu kierunkowi badawczemu. Pomysł ten jest bezpośrednią realizacją „dalszego kierunku badań" zaproponowanego przez Rolewskiego [**?**] (sekcja 1.7, punkt 3).

Algorytm. Pełny pseudokod:

1. Jeśli $n \leq 1$: zwróć 1 klaster z centroidem $= e_1$.
2. Jeśli $n < 5$ (`MIN_PAPERS`): zwróć 1 klaster z centroidem $= \hat{\bar{e}}$.
3. Dla $k = 2, 3, \ldots, \min(5, n{-}1)$: uruchom K-Means, oblicz silhouette score.
4. Wybierz k z najwyższym silhouette. Jeśli $\bar{s} < 0.15$ (`THRESHOLD`), ustaw $k{=}1$.
5. Dla każdego klastra oblicz i znormalizuj centroid.

Etykiety per klaster. Każdy klaster otrzymuje automatycznie generowaną etykietę: top-3 tematy i top-5 słów kluczowych z metadanych OpenAlex (za pomocą `Counter.most_common`).

4 Automatyczny dobór liczby klastrów

4.1 Silhouette Score

Metryką oceny jakości klasteryzacji jest *silhouette score* [?]. Dla każdego punktu i przypisanego do klastra C_i:

$$a(i) = \frac{1}{|C_i| - 1} \sum_{\substack{j \in C_i \\ j \neq i}} d(i,j), \qquad b(i) = \min_{C_k \neq C_i} \frac{1}{|C_k|} \sum_{j \in C_k} d(i,j), \tag{5}$$

gdzie $a(i)$ jest miarą **spójności** (średnia odległość do współklasterów), a $b(i)$ miarą **separacji** (minimalna średnia odległość do obcego klastra).

Silhouette score dla punktu i:

$$s(i) = \frac{b(i) - a(i)}{\max\big(a(i),\, b(i)\big)}, \qquad s(i) \in [-1, 1]. \tag{6}$$

Interpretacja: $s \approx 1$ — punkt jest blisko swoich i daleko od obcych; $s \approx 0$ — punkt na granicy między klastrami; $s < 0$ — punkt jest bliżej obcego klastra niż swojego.

Przykład intuicyjny. Autor z 10 pracami: 3 o AI, 4 o NLP, 3 o grafach. Dla k=2: K-means grupuje AI i NLP razem, $\bar{s} = 0.22$. Dla k=3: K-means rozdziela AI, NLP i grafy, $\bar{s} = 0.38$. Algorytm wybiera k=3, bo $0.38 > 0.22$ i $0.38 > 0.15$.

4.2 Dobór progu silhouette

Próg `SILHOUETTE_THRESHOLD = 0.15` decyduje, poniżej jakiego $\bar{s}$ odrzucamy klasteryzację. Zgodnie z klasyfikacją Rousseeuw [?]: $\bar{s} > 0.50$ oznacza silną strukturę, $0.25 < \bar{s} \leq 0.50$ rozsądną, $\bar{s} \leq 0.25$ słabą.

Tabela 3: Wpływ progu silhouette na liczbę klastrów.

Próg	Autorów z k>1	% autorów z k>1	Średnie k	Cluster-points
0.05	106	92.2%	2.75	316
0.10	105	91.3%	2.71	312
0.15	**98**	**85.2%**	**2.59**	**298**
0.20	86	74.8%	2.37	272
0.30	59	51.3%	1.88	216

Próg 0.15 daje 298 cluster-points z 115 autorów (średnio 2.59 punkty/autor), co zapewnia informatywną wizualizację bez nadmiernego zagęszczenia.

5 Redukcja wymiarowości: PCA

5.1 Definicja

Niech $X = \{x_1, \ldots, x_n\} \subset \mathbb{R}^d$ (d=768). Macierz kowariancji: $\Sigma = \frac{1}{n} X^T X$. PCA polega na znalezieniu wektorów własnych Σ; pierwsze k odpowiadających największym wartościom własnym $\lambda_1 \geq \ldots \geq \lambda_k$ definiuje przestrzeń projekcji:

$$y_i = W^T x_i, \qquad \text{VarExplained}(k) = \frac{\sum_{j=1}^{k} \lambda_j}{\sum_{j=1}^{d} \lambda_j}. \tag{7}$$

5.2 Variance explained: autorzy vs artykuły

Tabela 4: Variance explained (2 komponenty PCA) dla różnych zbiorów i modeli.

Zbiór	Model	Var. expl. (2 PC)
Artykuły ArXiv (18 880)	BGE-base (oryginalny)	12.19%
Artykuły ArXiv (18 880)	BGE-base (fine-tuned)	29.37%
Autorzy WMI (115)	BGE-base (oryginalny)	33.11%
Autorzy WMI (115)	BGE-base (fine-tuned)	**54.71%**

Mean pooling per autor działa jak filtr dolnoprzepustowy — uśrednianie wygładza szum i uwydatnia główne tematy, co skutkuje wyższym variance explained.

5.3 Scree plot

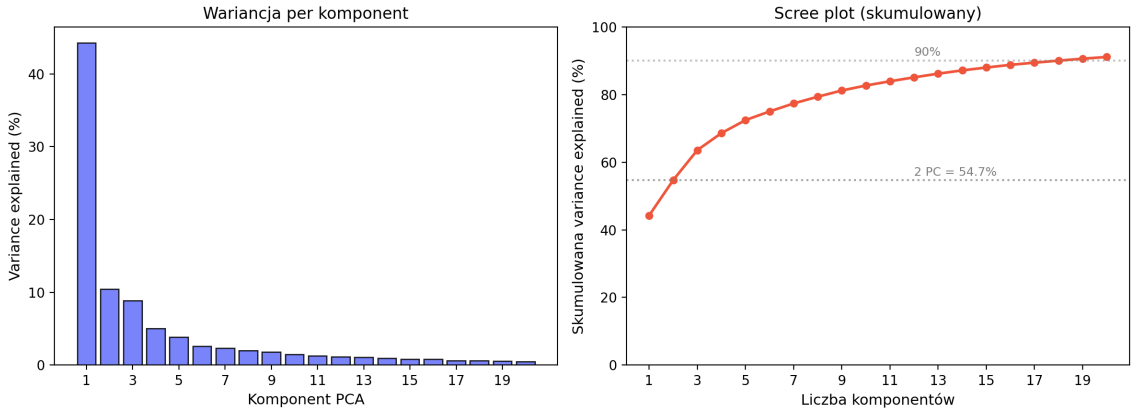

Rysunek 3: Scree plot embeddingów autorów (model fine-tuned). Lewo: wariancja per komponent. Prawo: skumulowana wariancja — 2 komponenty uchwytują 54.7%, 10 komponentów 82.7%.

Przejście z 2D do 3D daje jedynie ∼9 pp dodatkowej wariancji, przy znacznym pogorszeniu interaktywności — wykresy 3D w przeglądarce są trudniejsze do nawigacji.

5.4 Dlaczego PCA a nie t-SNE/UMAP?

Na podstawie analizy Wujca [?], metody nieliniowe (t-SNE, PaCMAP, UMAP) osiągają composite score 0.725–0.745 na 3440 artykułach, podczas gdy PCA jedynie 0.576. Jednak przy 115 punktach (autorach):

1. Variance explained jest znacznie wyższy (54.7% vs 12.2%) — PCA uchwytuje ponad połowę struktury.
2. PCA jest deterministyczne — ten sam wynik za każdym razem.
3. Odległości PCA mają interpretację geometryczną, w odróżnieniu od t-SNE.
4. Metody nieliniowe są zaprojektowane dla tysięcy punktów; przy 115 nie przynoszą istotnych korzyści.

6 Ewaluacja separacji zakładów

6.1 Metryki

Tabela 5: Metryki ewaluacji separacji zakładów.

Metryka	Co mierzy
Mean intra-dept cos-sim	Spójność wewnątrz zakładu
Mean inter-dept cos-sim	Odległość między zakładami
NN@k dept accuracy	% autorów z sąsiadami z tego samego zakładu
NMI	Zgodność K-means z prawdziwymi zakładami
Silhouette (true depts)	Jakość naturalnych grup wg zakładów w 768D

6.2 Wyniki globalne

Porównanie na 92 autorach z 14 zakładów:

Tabela 6: Metryki separacji zakładów: model oryginalny vs fine-tuned.

Metryka	Oryginalny	Fine-tuned	Diff
Mean intra-dept cos-sim	0.858	0.967	+0.109
Mean inter-dept cos-sim	0.756	0.911	+0.156
NN@1 dept accuracy	**0.728**	0.663	−0.065
NN@5 dept accuracy	0.609	0.478	−0.130
NMI	0.672	**0.702**	+0.030
Silhouette (true depts)	0.064	0.060	−0.004

Trade-off lokalny vs globalny. Fine-tuning poprawia globalne uporządkowanie (NMI +0.030), ale „ściska” embeddingi — inter-dept similarity rośnie z 0.756 do 0.911, co sprawia, że lokalne sąsiedztwo (NN@k) staje się szumowe.

Silhouette ≈ 0.06. Zakłady WMI nie tworzą wyraźnych skupisk w przestrzeni embeddingów. Jest to oczekiwane: naukowcy z różnych zakładów często współpracują i badają powiązane tematy.

6.3 Analiza per zakład

Tabela 7: Wyniki per zakład (fine-tuned). Kolumna „Nearest” to cosine similarity do najbliższego innego zakładu.

Zakład	N	Intra (FT)	Najbliższy zakład	Nearest
Z. Teorii Operatorów	7	0.991	Z. Przestrzeni Funkcyjnych	0.996
Z. Przestrzeni Funkcyjnych	5	0.989	Z. Teorii Operatorów	0.996
Z. Analizy Funkcjonalnej	8	0.985	Z. Analizy Matematycznej	0.996
Z. Analizy Nieliniowej	6	0.982	Z. Analizy Matematycznej	0.996
P. Algorytmiki	4	0.981	Z. Teorii Algorytmów	0.976
Z. Analizy Matematycznej	5	0.971	Z. Analizy Funkcjonalnej	0.996
Z. Matematyki Dyskretnej	9	0.971	Z. Teorii Algorytmów	0.985
Z. Algebry i Teorii Liczb	6	0.967	Z. Analizy Nieliniowej	0.986
Z. Sztucznej Inteligencji	21	0.963	P. Logiki i Fil. Informatyki	0.976
Z. Geom. Algebraicznej i Diof.	5	0.953	Z. Arytm. Geom. Algebraicznej	0.993
P. Logiki i Fil. Informatyki	2	0.945	Z. Sztucznej Inteligencji	0.976
Z. Arytm. Geom. Algebraicznej	4	0.941	Z. Geom. Algebraicznej i Diof.	0.993
Z. Teorii Algorytmów	5	0.939	Z. Matematyki Dyskretnej	0.985
Z. Statystyki Mat. i Analizy Danych	5	0.927	P. Logiki i Fil. Informatyki	0.968

Zakłady „bliźniacze” (Analiza Funkcjonalna $\leftrightarrow$ Analiza Matematyczna: 0.996; Geom. Algebraiczna $\leftrightarrow$ Arytm. Geom. Algebraiczna: 0.993) potwierdzają, że embeddingi sensownie uchwytują pokrewieństwo tematyczne. Najmniej spójny jest Zakład Statystyki (0.927), co wynika z wewnętrznej heterogeniczności tej dyscypliny.

7 Ewaluacja fine-tuningu na zbiorze ArXiv

7.1 Metryki klastrowania

Tabela 8: Metryki klastrowania na ArXiv: oryginalny vs fine-tuned.

k	Metryka	Oryginalny	Fine-tuned	Poprawa
8	Main category purity	65.76%	70.49%	+4.74 pp
8	Fuzzy purity	74.18%	80.86%	+6.68 pp
8	Silhouette	0.381	0.438	+0.056
20	Main category purity	67.13%	72.60%	+5.47 pp
118	Main category purity	68.07%	73.76%	+5.69 pp
118	Subcategory purity	13.38%	16.17%	+2.79 pp

7.2 Metryki wyszukiwania

Tabela 9: Multi-label Precision@k na ArXiv (2000 losowych zapytań).

Metryka	Oryginalny	Fine-tuned	Poprawa
P@1	0.740	0.758	+1.80 pp
P@5	0.684	0.713	+2.87 pp
P@10	0.654	0.690	+3.61 pp
P@20	0.625	0.667	+4.29 pp

Poprawa rośnie z k — model po fine-tuningu lepiej organizuje strukturę tematyczną w szerszym sąsiedztwie.

8 Interaktywna wizualizacja

8.1 Wariant Mean Pooling

Wizualizacja przedstawia 115 autorów w układzie side-by-side: lewy panel — model bazowy (33.1%), prawy — fine-tuned (54.7%).

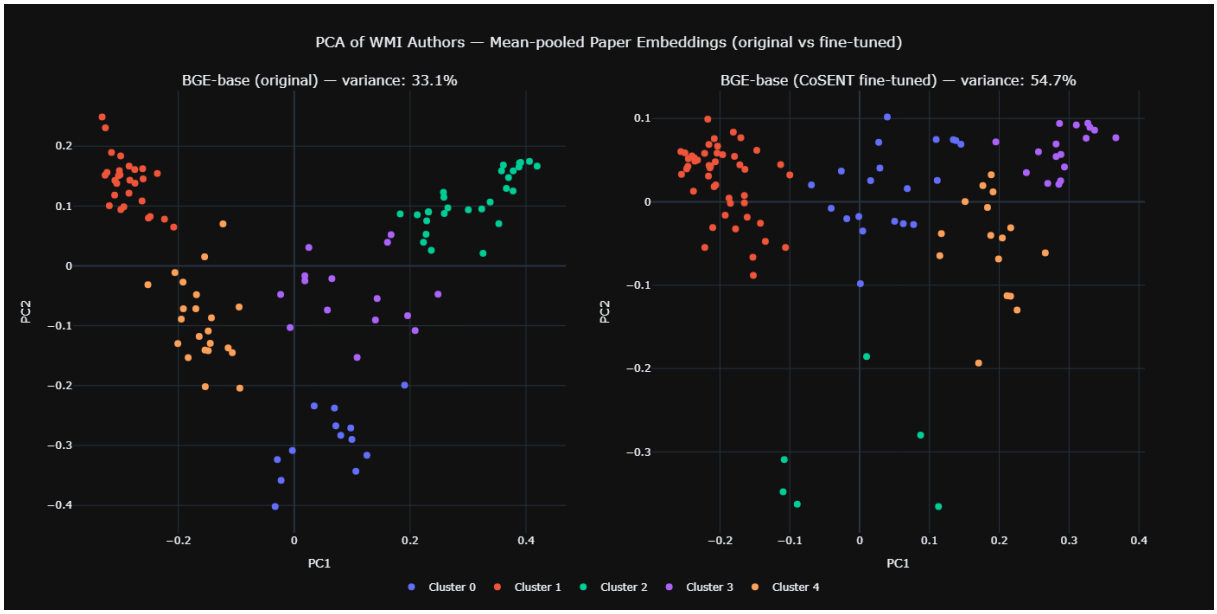

Rysunek 4: PCA mean pooling: porównanie modelu oryginalnego (lewo) i fine-tuned (prawo). Kolory odpowiadają klastrom K-means (k=5).

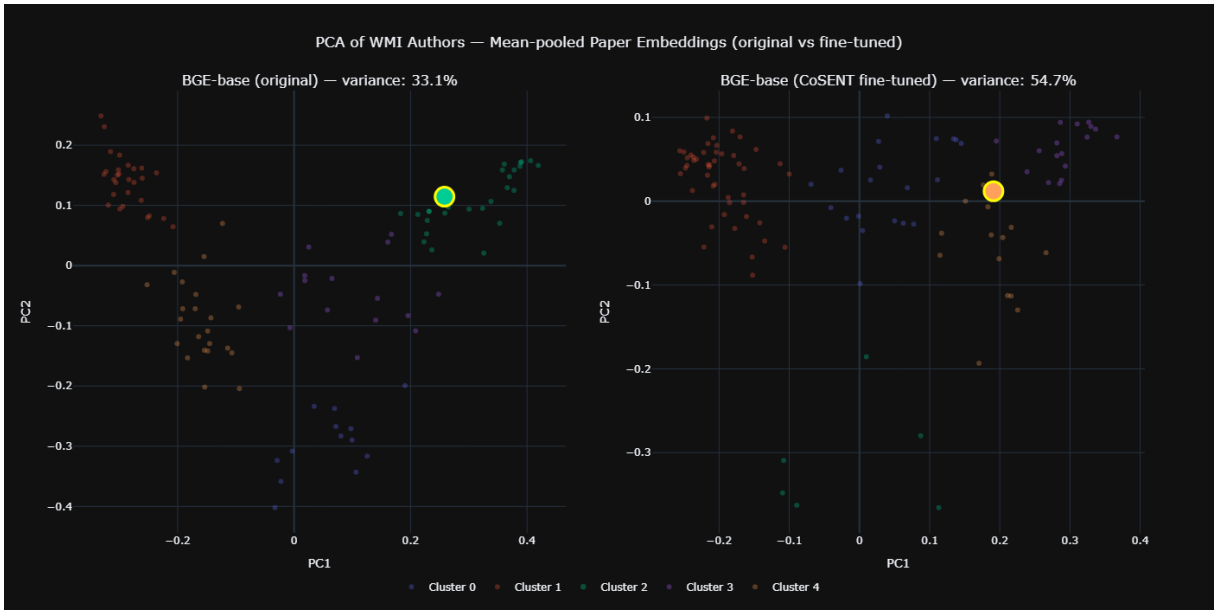

Rysunek 5: Wyszukiwanie autora (prof. Patryk Żywica): podświetlony punkt z żółtą obwódką na obu panelach, pozostałe punkty wygaszone.

8.2 Wariant Multi-Cluster

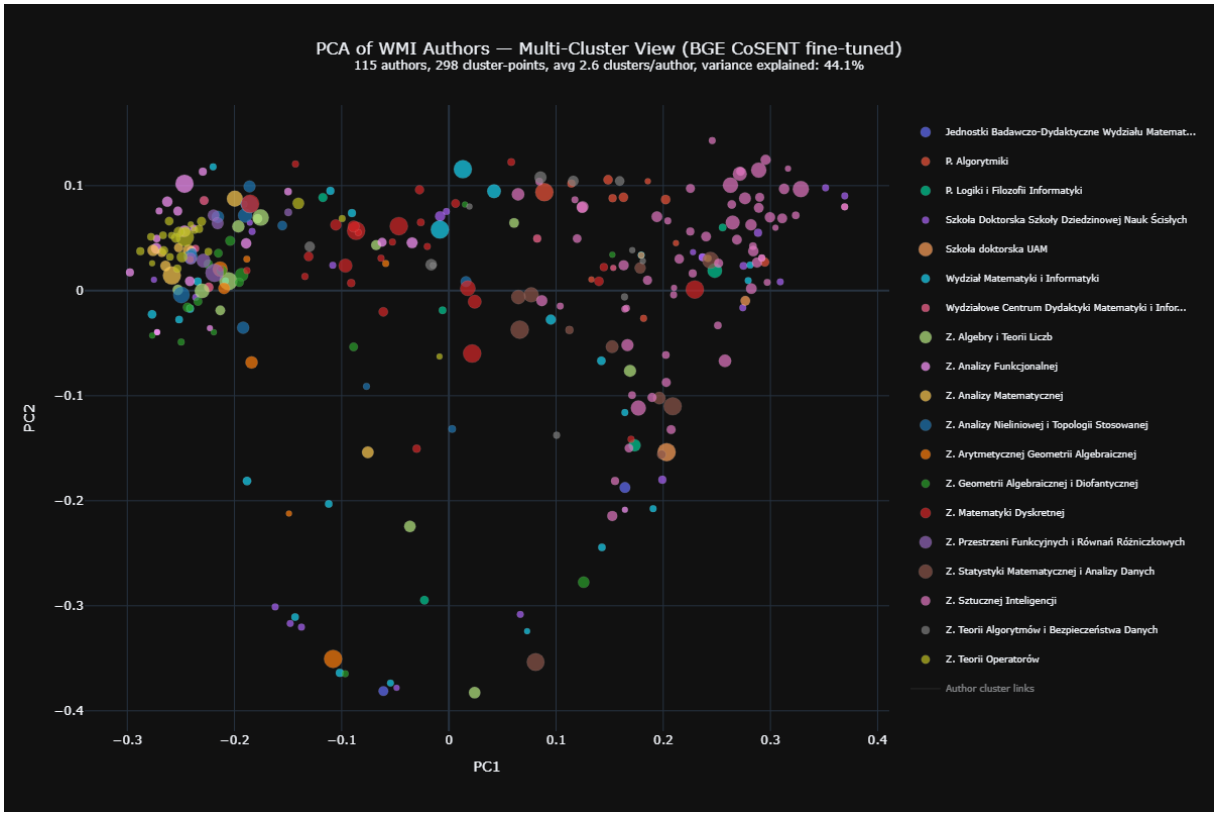

Rysunek 6: Multi-cluster view: 298 cluster-points, kolory wg zakładów. Rozmiar punktu $\propto \sqrt{n_{\text{prac}}}$. Linie łączą klastry tego samego autora.

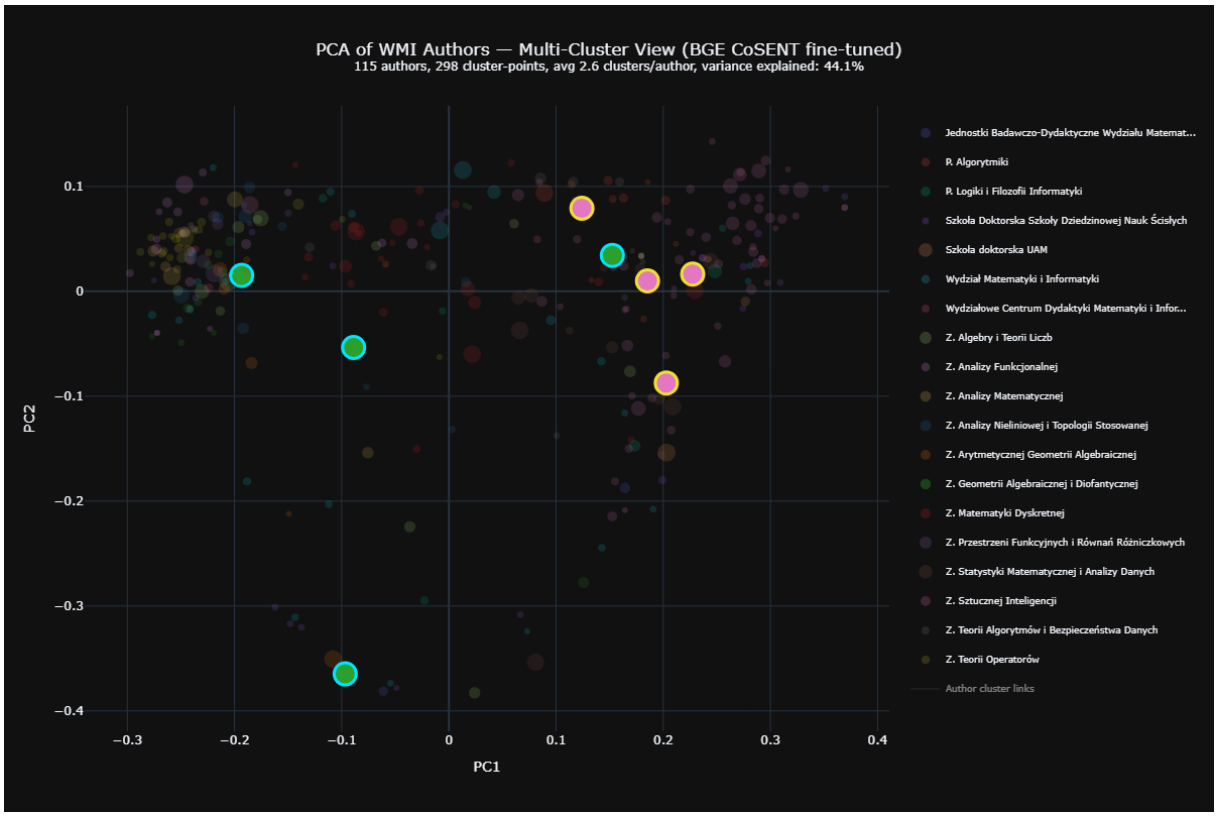

Rysunek 7: Porównanie dwóch naukowców: prof. Patryk Żywica (żółty) vs dr Bartosz Naskręcki (cyan). Pozostałe punkty wygaszone.

8.3 Elementy interaktywne

Obie wizualizacje, generowane jako standalone HTML (Plotly via CDN), oferują:

- **Wyszukiwarka** z autocomplete — podświetla wybranego autora.
- **Porównanie A vs B** (multi-cluster) — podświetlenie dwóch naukowców jednocześnie.
- **Toggle cluster links** — pokazywanie/ukrywanie linii łączących klastry.
- **Checkbox „Show authors with <5 papers"** — włączenie low-confidence autorów.

9 Wyniki i obserwacje

9.1 Fine-tuning poprawia separację kategorii

Fuzzy purity rośnie o 5–7 pp, silhouette o 0.056 (na ArXiv). Na danych WMI variance explained wzrasta z 33% do 55%.

9.2 Zakłady WMI nie tworzą wyraźnych skupisk

Silhouette wg prawdziwych zakładów wynosi ∼0.06. Zakłady o zbliżonej tematyce (Analiza Funkcjonalna ↔ Analiza Matematyczna: cos-sim 0.996) są praktycznie nieodróżnialne — co jest prawidłowe z perspektywy treści badawczej.

9.3 Multi-cluster ujawnia interdyscyplinarność

85% autorów (z ≥5 pracami) ma więcej niż jeden odrębny kierunek badawczy. Linie łączące klastry tworzą na mapie wzór „konstelacji" — autor interdyscyplinarny rozpina się na dużej powierzchni mapy.

9.4 Trade-off fine-tuningu: globalne vs lokalne

Fine-tuning poprawia globalne uporządkowanie (NMI +0.030), ale pogarsza lokalne metryki sąsiedztwa (NN@1 −0.065). W kontekście wizualizacji 2D ten trade-off jest akceptowalny: interesuje nas globalna struktura, a nie dokładna kolejność najbliższych sąsiadów.

9.5 Ograniczenia i przyszłe prace

- **Chronologia:** Mean pooling traktuje prace z 2005 i 2024 równoważnie. Temporal embeddings z ważeniem wykładniczym mogłyby poprawić aktualność profilu.
- **Brak ważenia wg impactu:** Wszystkie prace mają równą wagę. Citation-weighted pooling mógłby poprawić jakość.
- **Collaborative filtering:** Sieć współautorów mogłaby uzupełnić informację z embeddingów tekstowych.
- **Skalowalność:** Rozszerzenie na inne wydziały lub uczelnie.

10 Wnioski

Tabela 10: Podsumowanie wyników.

Co zrobiliśmy	Wynik
Fine-tuning BGE-base z CoSENTLoss	Fuzzy purity 80.9% (k=8), poprawa +6.7 pp
Mean pooling + PCA 2D	54.7% variance explained
Ewaluacja separacji zakładów	NMI = 0.702
Multi-cluster z silhouette	85% autorów z k>1, śr. 2.59 klastrów
Interaktywna wizualizacja	Wyszukiwarka, porównanie A vs B

1. **PCA na zagregowanych embeddingach autorów** jest wystarczające do wizualizacji 115 naukowców — metody nieliniowe nie przynoszą istotnych korzyści przy tak małej liczbie punktów.

2. **Fine-tuning z CoSENTLoss i hierarchiczną odległością kategorii** daje konsystentną poprawę klastrowania (+5 pp purity) i wyszukiwania (+4 pp P@20) bez overfittingu.

3. **Multi-cluster representation** to kluczowe rozszerzenie — pozwala uchwycić interdyscyplinarność naukowców, co jest niemożliwe w podejściu single-point. Stanowi realizację kierunku zaproponowanego przez Rolewskiego [**?**].

4. **Automatyczny dobór** k (silhouette) eliminuje konieczność ręcznego tuningu per autor.

5. **Interaktywne wizualizacje** z wyszukiwarką i porównaniem A vs B pozwalają na eksplorację mapy badawczej WMI w przeglądarce.

Literatura

[1] W. B. Johnson, J. Lindenstrauss, „Extensions of Lipschitz mappings into a Hilbert space," *Contemp. Math.*, vol. 26, pp. 189–206, 1984.

[2] N. Reimers, I. Gurevych, „Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks," *Proceedings of EMNLP-IJCNLP*, pp. 3982–3992, 2019.

[3] Z. Xiao et al., „C-Pack: Packaged Resources To Advance General Chinese Embedding," *arXiv:2309.07597*, 2023.

[4] K. Li, „CoSENT: A more efficient sentence vector scheme than Sentence-BERT," 2022.

[5] P. J. Rousseeuw, „Silhouettes: a graphical aid to the interpretation and validation of cluster analysis," *J. Comp. Appl. Math.*, vol. 20, pp. 53–65, 1987.

[6] I. T. Jolliffe, *Principal Component Analysis*, 2nd ed. Springer, 2002.

[7] Y. Wang, H. Huang, C. Rudin, Y. Shaposhnik, „Understanding how dimension reduction tools work," *JMLR*, vol. 22, no. 201, pp. 1–73, 2021.

[8] M. Wujec, „Dimensionality Reduction and Quality Metrics for Scientific Paper Embeddings," WMiI UAM, 2026.

[9] J. Priem, H. Piwowar, R. Orr, „OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts," *arXiv:2205.01833*, 2022.

[10] M. Rolewski, „SARA," Praca magisterska, WMiI UAM, 2024.

[11] S. P. Lloyd, „Least squares quantization in PCM," *IEEE Trans. Information Theory*, vol. 28, no. 2, pp. 129–137, 1982.

[12] Plotly Technologies Inc., „Collaborative data science," Montréal, QC, 2015.

[13] F. Pedregosa et al., „Scikit-learn: Machine Learning in Python," *JMLR*, vol. 12, pp. 2825–2830, 2011.

A Kluczowe fragmenty kodu

```
def cluster_author_papers(author_embeddings):
    n = len(author_embeddings)
    if n < MIN_PAPERS_FOR_CLUSTERING:
        centroid = author_embeddings.mean(axis=0, keepdims=True)
        centroid /= np.linalg.norm(centroid, axis=1, keepdims=True)
        return 1, np.zeros(n, dtype=int), centroid

    max_k = min(MAX_CLUSTERS, n - 1)
    best_k, best_sil, best_labels = 1, -1, None

    for k in range(2, max_k + 1):
        km = KMeans(n_clusters=k, random_state=42, n_init=10)
        labels = km.fit_predict(author_embeddings)
        if len(set(labels)) < 2: continue
        sil = silhouette_score(author_embeddings, labels)
        if sil > best_sil:
            best_sil, best_k, best_labels = sil, k, labels

    if best_sil < SILHOUETTE_THRESHOLD or best_labels is None:
        centroid = author_embeddings.mean(axis=0, keepdims=True)
        centroid /= np.linalg.norm(centroid, axis=1, keepdims=True)
        return 1, np.zeros(n, dtype=int), centroid

    centroids = []
    for c in range(best_k):
        mask = best_labels == c
        cent = author_embeddings[mask].mean(axis=0)
        centroids.append(cent / np.linalg.norm(cent))
    return best_k, best_labels, np.array(centroids)
```

Listing 1: `cluster_author_papers()` — klasteryzacja prac autora.

```
def embed_and_pool(model_path, texts, paper_orcids, author_orcids):
    model = SentenceTransformer(model_path)
    embeddings = model.encode(texts, batch_size=128,
        normalize_embeddings=True, convert_to_numpy=True)
    author_embeddings = []
    for orcid in author_orcids:
        mask = paper_orcids == orcid
        emb = embeddings[mask].mean(axis=0)
        emb = emb / np.linalg.norm(emb)
        author_embeddings.append(emb)
    return np.array(author_embeddings)
```

Listing 2: `embed_and_pool()` — mean pooling per autor.